
Avaliação Causal de uma Campanha de Marketing

Author: Silvio da Rosa Paula

MARKETING E INFERÊNCIA CAUSAL



{width="1200", height="400"}

Introdução

Vamos supor que uma grande loja do setor de varejo quer avaliar o impacto causal de uma campanha de marketing digital nas conversões (vendas).

.....

Decisão da Empresa

A empresa decidiu testar a campanha de marketing em lojas com maior potencial digital:

- Cidades com maior renda per capita
- População com alta penetração de internet
- Público mais jovem e conectado

Essa decisão, apesar de estratégica, não é aleatória, e isso tem implicações importantes para a análise causal.

.....

Quais são os potenciais problemas?

- **Viés de Seleção:** As lojas que receberam a campanha de marketing não foram escolhidas de forma aleatória. Isso dificulta a construção de um grupo de controle (lojas que não receberam a campanha) com características semelhantes.

- **Endogeneidade:** A decisão de onde aplicar a campanha pode estar relacionada a fatores não observados que também influenciam as vendas, por exemplo, o histórico de desempenho da loja, o engajamento local ou outras ações promocionais simultâneas.
- **Efeito de Contágio (Spillover):** A campanha digital pode alcançar consumidores de outras regiões, afetando indiretamente lojas que não participaram da campanha, violando o um dos pressupostos de inferência causal que é SUTVA (Stable Unit Treatment Value Assumption), esse pressuposto exige que o tratamento aplicado a uma unidade (neste caso, uma loja) não afete o resultado de outras unidades.
- **Tendências Diferenciadas:** As lojas escolhidas podem já apresentar uma tendência natural de crescimento anterior à campanha, levando a uma superestimação do efeito causal.

Simulação dos Dados

Unidades de Análise

- **250 lojas**
- **24 meses** de observação (2 anos)
- **Total: 6.000 observações** (painel balanceado: 250 lojas × 24 meses)

Características das Lojas (Invariantes Temporalmente)

Cada loja possui atributos **fixos** ao longo dos 24 meses:

Variável	Descrição	Intervalo
loja_id	Identificador único	1 a 250
regiao	Região geográfica	Sudeste, Sul, Nordeste, Centro-Oeste
renda_per_capita	Renda média da cidade (R\$)	2.200 a 4.800
penetracao_internet	Proporção da população com internet	50% a 95%
densidade_pop	Habitantes por km ²	1.000 a 50.000
idade_media	Idade média da população (anos)	25 a 45

Variável	Descrição	Intervalo
n_concorrentes	Número de lojas concorrentes próximas	0 a 8

Índice de Potencial Digital

A constrói um índice composto que resume o potencial de crescimento digital:

$$\text{Potencial Digital} = 0.3 \times \text{Renda (padronizada)} + 0.4 \times \text{Internet (padronizada)} - 0.2 \times \text{Idade (padronizada)}$$

Pesos interpretativos: - **Renda:** +30% de contribuição - **Internet:** +40% de contribuição (fator mais importante) - **Idade:** -20% de contribuição (população mais velha reduz potencial)

Mecanismo de Seleção (Não-Aleatório)

A probabilidade de tratamento é função do potencial digital:

$$P(\text{Tratamento}) = \text{logit}^{-1}(0.5 + 0.8 \times \text{Potencial Digital})$$

Potencial Digital	P(Tratamento)	Interpretação
-1.5 (baixo)	~20%	Improvável receber campanha
0.0 (médio)	~62%	Chance moderada
+1.5 (alto)	~88%	Muito provável receber

Composição esperada dos grupos: - Aproximadamente 160 lojas tratadas (~64%) - Aproximadamente 90 lojas controle (~36%) - **Viés de seleção:** Lojas tratadas têm sistematicamente maior potencial digital

Estrutura dos Dados: Painei Longitudinal

Formato Long (6.000 linhas)

Cada linha representa uma **observação loja-período**:

Coluna	Tipo	Descrição
loja_id	Fixo	Identificador da loja (1-250)

Coluna	Tipo	Descrição
periodo	Variável	Mês de observação (1-24)
tratamento	Fixo	1 = recebe campanha, 0 = não recebe
pos	Variável	0 = pré-campanha (mês 1-12), 1 = pós-campanha (mês 13-24)
vendas	Variável	Vendas mensais observadas (R\$)
renda_per_capita	Fixo	Repetida em todos os períodos da mesma loja
penetracao_internet	Fixo	Repetida em todos os períodos da mesma loja
n_concorrentes	Fixo	Repetida em todos os períodos da mesma loja
potencial_crescimento	Fixo	Repetida em todos os períodos da mesma loja
efeito_verdadeiro	Variável	Efeito causal verdadeiro (0 no pré, >0 no pós se tratada)

Timeline do Experimento

Período PRÉ (meses 1-12): - Todas as lojas operam sem campanha - Usado para estabelecer tendências naturais - Crítico para métodos DiD

Período PÓS (meses 13-24): - Lojas tratadas: campanha com influenciadores digitais - Lojas controle: marketing tradicional - Efeito heterogêneo por características da loja

Processo Gerador de Dados (DGP)

Vendas Observadas

$$\text{Vendas}(i,t) = \text{Base}(i) + \text{Tendência}(i) \times t + \text{Tratamento}(i,t) + \text{Sazonalidade}(t) + \text{Ruído}$$

Componentes:

- Base:** Nível inicial de vendas
 - Função de: renda, internet, concorrentes
- Tendência:** Crescimento mensal específico da loja
 - Correlacionado com potencial digital
 - Fonte do viés:** Lojas tratadas crescem mais rápido naturalmente
- Tratamento:** Efeito causal da campanha
 - Zero no pré (meses 1-12)
 - Heterogêneo no pós (função de internet e renda)
- Sazonalidade:** Ciclo anual ($\sin(2\pi t/12)$)

- Amplitude: R\$ 5.000
5. **Ruído:** $\varepsilon \sim N(0, 2.000^2)$

Efeito Heterogêneo do Tratamento

Efeito(i) = 3.000 + 2.000 × Internet(i) + 1.500 × (Renda(i)/3.000)

Intervalo esperado: R4.500 a R 8.500 por mês

Interpretação: - Lojas com alta internet e alta renda: efeito ~R

8.000/mês — Lojas com baixa internet e baixa renda : efeito R 4.500/mês - **Média:** ~R\$ 6.000/mês

```
In [2]: # =====
# PACOTES - INFERÊNCIA CAUSAL E CIÊNCIA DE DADOS
# =====

# Instalar pacotes necessários (apenas se faltar algum)
# install.packages("pacman")

library(pacman)

p_load(

  # --- Manipulação e visualização de dados ---
  tidyverse, # Manipulação e visualização de dados (dplyr, ggplot2, etc.)
  tidyr,     # Transformações entre formatos wide/long
  lubridate, # Manipulação de datas
  plotly,    # Visualizações interativas

  # --- Modelagem econométrica e painel ---
  fixest,    # Modelos lineares com efeitos fixos (rápido e versátil)
  plm,       # Modelos clássicos de painel (efeitos fixos/aleatórios)

  # --- Diferença-em-Diferenças e extensões ---
  did,       # Diferença-em-Diferenças (Callaway & Sant'Anna)
  DIDmultiplegtDYN, # Diferença-em-Diferenças dinâmico (de Chaisemartin & D'H)
  DIDmultiplegtSTAT, # Diferença-em-Diferenças (de Chaisemartin & D'Haultfoeu)
  augsynth,  # Augmented Synthetic Control
  Synth,     # Synthetic Control tradicional

  # --- Balanceamento e Pareamento ---
  MatchIt,   # Pareamento baseado em Propensity Score
  WeightIt,  # Ponderação (IPW, Entropy Balancing, etc.)
  cobalt,    # Diagnóstico de balanceamento
  grf,       # Generalized Random Forest (Causal Forest)
  xgboost,   # modelo xgboost

  # --- Séries Temporais Causais ---
  CausalImpact, # Análise de impacto causal em séries temporais (Google)

  # --- Utilitários ---
  broom,      # Converte resultados de modelos em data frames "arrumados"
```

```

performance, # testes estatísticos
see,         # visualização de diagnósticos
sandwich,    # estimadores de erros padrão robustos
lmtest,      # testes estatísticos
bayesAB,     # Análise bayesiana de experimentos A/B
abpackage,   # Análise clássica de experimentos A/B
did2s,       # Diferença-em-Diferenças com 2 estágios
repr,        # configurar tamanho do plote
gridExtra    # Plote
)

```

Simulação de dados

```

In [3]: # =====
# CRIAR CARACTERÍSTICAS DAS LOJAS
# =====

set.seed(2025)

n_lojas <- 250
n_periodos <- 24
intervencao <- 13

lojas <- data.frame(
  loja_id = 1:n_lojas,
  regioao = sample(c('Sudeste', 'Sul', 'Nordeste', 'Centro-Oeste'),
                    n_lojas, replace = TRUE),
  renda_per_capita = rnorm(n_lojas, 3000, 800),
  penetracao_internet = runif(n_lojas, 0.5, 0.95),
  densidade_pop = runif(n_lojas, 1000, 50000),
  idade_media = rnorm(n_lojas, 35, 5),
  n_concorrentes = rpois(n_lojas, 3)
)

lojas <- lojas %>%
  mutate(
    potencial_crescimento = 0.3 * scale(renda_per_capita)[,1] +
                          0.4 * scale(penetracao_internet)[,1] -
                          0.2 * scale(idade_media)[,1],
    probab_tratamento = plogis(0.5 + 0.8 * potencial_crescimento),
    tratamento = rbinom(n_lojas, 1, probab_tratamento)
  )

# =====
# EFEITO
# =====
# Campanha de influenciadores pode gerar aumento substancial
# Efeito médio esperado: ~R$ 5.000-8.000/mês

efeito_base <- 3000      # efeito mínimo (era 200)
efeito_internet <- 2000  # bônus internet (era 150)
efeito_renda <- 1500     # bônus renda (era 100)

lojas_tratadas <- lojas %>%
  filter(tratamento == 1) %>%
  mutate(
    efeito_individual = efeito_base +

```

```

        efeito_internet * penetracao_internet +
        efeito_renda * (renda_per_capita/3000)
    )

# =====
# SIMULAR VENDAS
# =====

dados <- data.frame()

for(i in 1:n_lojas) {
  loja_info <- lojas[i, ]

  vendas_base <- 50000 +
    10000 * loja_info$renda_per_capita/1000 +
    15000 * loja_info$penetracao_internet -
    2000 * loja_info$n_concorrentes

  tendencia_temporal <- 500 + 300 * loja_info$potencial_crescimento

  for(t in 1:n_periodos) {
    pos <- ifelse(t >= intervencao, 1, 0)

    if(loja_info$tratamento == 1 & pos == 1) {
      efeito_tratamento <- efeito_base +
        efeito_internet * loja_info$penetracao_internet +
        efeito_renda * (loja_info$renda_per_capita/3000)
    } else {
      efeito_tratamento <- 0
    }

    sazonalidade <- 5000 * sin(2*pi*t/12)

    # RUÍDO REDUZIDO: 2000 (era 3000)
    vendas <- vendas_base +
      tendencia_temporal * t +
      efeito_tratamento +
      sazonalidade +
      rnorm(1, 0, 2000)

    dados <- rbind(dados, data.frame(
      loja_id = i,
      periodo = t,
      vendas = vendas,
      tratamento = loja_info$tratamento,
      pos = pos,
      renda_per_capita = loja_info$renda_per_capita,
      penetracao_internet = loja_info$penetracao_internet,
      n_concorrentes = loja_info$n_concorrentes,
      potencial_crescimento = loja_info$potencial_crescimento,
      efeito_verdadeiro = efeito_tratamento
    ))
  }
}

dados_original <- dados

print(paste("Efeito médio simulado:",
  round(mean(dados$efeito_verdadeiro[dados$efeito_verdadeiro > 0]), 2)

```

```
# Selecionar apenas o período pós-intervenção, se for o caso
dados_pos <- dados %>% filter(pos == 1)

# Salvar os dados completos
write.csv(dados, "data/dados_completos.csv", row.names = FALSE)

# Ou salvar apenas os dados pós-tratamento
write.csv(dados_pos, "data/dados_pos.csv", row.names = FALSE)

# print
head(dados)
```

```
[1] "Efeito médio simulado: 6012.28"
```

```
Out[3]:  loja_id periodo  vendas tratamento pos renda_per_capita penetracao_internet
n_concorrentes potencial_crescimento efeito_verdadeiro
1      1      1 84092.27      0 0      2963.987      0.6674432
3      -0.4182928      0
2      1      2 91885.91      0 0      2963.987      0.6674432
3      -0.4182928      0
3      1      3 87215.91      0 0      2963.987      0.6674432
3      -0.4182928      0
4      1      4 87925.44      0 0      2963.987      0.6674432
3      -0.4182928      0
5      1      5 88033.52      0 0      2963.987      0.6674432
3      -0.4182928      0
6      1      6 86577.29      0 0      2963.987      0.6674432
3      -0.4182928      0
```

Características dos nossos dados:

- ✓ 155 lojas tratadas
- ✓ 95 lojas controle
- ✓ 12 meses pré-campanha
- ✓ 12 meses pós-campanha
- ✓ Intervenção única no mês 13

Plote Evolução temporal das vendas médias geral (tratamento vs controle)

```
In [4]: dados %>%
  group_by(periodo, tratamento) %>%
  summarise(vendas_media = mean(vendas), .groups = "drop") %>%
  mutate(grupo = ifelse(tratamento == 1, "Tratadas", "Controle")) %>%
  ggplot(aes(x = periodo, y = vendas_media, color = grupo)) +
  geom_line(linewidth = 1.2) +
  geom_vline(xintercept = intervencao, linetype = "dashed", color = "red", linewidth = 1.2) +
  labs(
    title = "Vendas médias",
    subtitle = "Lojas tratadas vs controle",
    x = "Período",
    y = "Vendas Médias (R$)",
    color = ""
  ) +
  theme_minimal(base_size = 15) +
  theme(
```



```

plot.title = element_text(face = "bold", size = 18),
plot.subtitle = element_text(size = 14),
axis.title = element_text(size = 15),
axis.text = element_text(size = 13),
legend.text = element_text(size = 14),
legend.position = "top"
)

```

Vendas médias

Lojas tratadas vs controle




Gráfico Evolução temporal das vendas médias por região (Tratamento vs Controle)

```

In [4]: dados_reg <- dados %>%
  left_join(lojas %>% select(loja_id, regioao), by = "loja_id")

options(repr.plot.width = 20, repr.plot.height = 8)

dados_reg %>%
  group_by(regiao, periodo, tratamento) %>%
  summarise(vendas_media = mean(vendas), .groups = "drop") %>%
  mutate(grupo = ifelse(tratamento == 1, "Tratadas", "Controle")) %>%
  ggplot(aes(x = periodo, y = vendas_media, color = grupo)) +
  geom_line(linewidth = 1.1) +
  geom_vline(xintercept = intervencao, linetype = "dashed", color = "red", linewidth = 1.1) +
  labs(
    title = "Vendas médias por região",
    subtitle = "Lojas tratadas vs controle",
    x = "Período",
    y = "Vendas médias (R$)",
    color = ""
  ) +

```


```

facet_wrap(~ regiao, ncol = 2, scales = "free_y") +
theme_minimal(base_size = 15) +
theme(
  plot.title = element_text(face = "bold", size = 18),
  plot.subtitle = element_text(size = 14),
  strip.text = element_text(size = 14, face = "bold"),
  axis.title = element_text(size = 15),
  axis.text = element_text(size = 13),
  legend.text = element_text(size = 14),
  legend.position = "top"
)

```

Vendas médias por região

Lojas tratadas vs controle



Estatísticas Descritivas Gerais

In [5]: `stargazer::stargazer(lojas, type="text")`

```

=====
Statistic      N      Mean    St. Dev.    Min      Max
-----
loja_id         250   125.500    72.313      1       250
renda_per_capita 250  3,018.428  792.815   720.606  5,268.535
penetracao_internet 250    0.726    0.124    0.501    0.948
densidade_pop    250 25,817.990 14,615.350 1,391.728 49,973.720
idade_media     250   34.786    4.789    20.296   46.927
n_concorrentes  250    3.024    1.703      0        10
potencial_crescimento 250   -0.000    0.532   -1.334    1.332
prob_tratamento 250    0.618    0.097    0.362    0.827
tratamento      250    0.620    0.486      0         1
=====

```

Estatísticas Descritivas por Grupo (Tratado e Controle)

```
In [6]: # =====
# Estatísticas Descritivas por Grupo
# =====
# Comparação das características (cross-section)
comparacao_grupos <- lojas %>%
  group_by(Grupo = ifelse(tratamento == 1, "Tratadas", "Controle")) %>%
  summarise(
    N = n(),
    Renda_Media = round(mean(renda_per_capita), 0),
    Renda_DP = round(sd(renda_per_capita), 0),
    Internet_Media = round(mean(penetracao_internet), 3),
    Internet_DP = round(sd(penetracao_internet), 3),
    Concorrentes_Media = round(mean(n_concorrentes), 1),
    Potencial_Medio = round(mean(potencial_crescimento), 2),
    Potencial_DP = round(sd(potencial_crescimento), 2)
  )

print(comparacao_grupos)

# Testes de diferença de médias
cat("\n=== TESTES DE BALANCEAMENTO ===\n\n")

cat("Renda per capita:\n")
t_renda <- t.test(renda_per_capita ~ tratamento, data = lojas)
cat("  Diferença:", round(diff(t_renda$estimate), 0), "\n")
cat("  P-valor:", round(t_renda$p.value, 4),
    ifelse(t_renda$p.value < 0.05, "*** DESBALANCEADO\n", "\n"))

cat("\nPenetração Internet:\n")
t_internet <- t.test(penetracao_internet ~ tratamento, data = lojas)
cat("  Diferença:", round(diff(t_internet$estimate), 3), "\n")
cat("  P-valor:", round(t_internet$p.value, 4),
    ifelse(t_internet$p.value < 0.05, "*** DESBALANCEADO\n", "\n"))

cat("\nPotencial Crescimento:\n")
t_potencial <- t.test(potencial_crescimento ~ tratamento, data = lojas)
cat("  Diferença:", round(diff(t_potencial$estimate), 2), "\n")
cat("  P-valor:", round(t_potencial$p.value, 4),
    ifelse(t_potencial$p.value < 0.05, "*** DESBALANCEADO\n", "\n"))

# Vendas PRÉ-tratamento
vendas_pre <- dados %>%
  filter(pos == 0) %>%
  group_by(loja_id, tratamento) %>%
  summarise(vendas_media_pre = mean(vendas), .groups = "drop")

cat("\nVendas PRÉ-tratamento:\n")
t_vendas_pre <- t.test(vendas_media_pre ~ tratamento, data = vendas_pre)
cat("  Diferença:", round(diff(t_vendas_pre$estimate), 0), "\n")
cat("  P-valor:", round(t_vendas_pre$p.value, 4),
    ifelse(t_vendas_pre$p.value < 0.05, "*** DESBALANCEADO\n\n", "\n\n"))
```

```
# A tibble: 2 × 9
  Grupo      N Renda_Media Renda_DP Internet_Media Internet_DP Concorrentes_Med
ia Potencial_Medio Potencial_DP
  <chr>    <int>      <dbl>    <dbl>      <dbl>      <dbl>      <dbl>
1>
1 Controle    95      2977      834      0.694      0.112
2.9      -0.15      0.51
2 Tratadas   155      3044      768      0.745      0.128
3.1        0.09      0.53
```

=== TESTES DE BALANCEAMENTO ===

Renda per capita:

Diferença: 67

P-valor: 0.5273

Penetração Internet:

Diferença: 0.051

P-valor: 0.001 ** DESBALANCEADO

Potencial Crescimento:

Diferença: 0.24

P-valor: 5e-04 ** DESBALANCEADO

Vendas PRÉ-tratamento:

Diferença: 1573

P-valor: 0.2282

Interpretação dos Resultados

Estatísticas Descritivas

- **Tamanho dos grupos:** - Controle: 95 lojas (38%) - Tratadas: 155 lojas (62%) - Grupos desbalanceados em tamanho
- **Renda per capita:** - Tratadas: R3.047(DP : 768)*vs*Controle : R 2.977 (DP: 834) - Diferença absoluta: +R\$ 67 (2% maior)
- **Penetração de Internet:** - Tratadas: 74.5% (DP: 0.128) vs Controle:69.4% (DP: 0.112) - Diferença absoluta: +5.1 pontos percentuais
- **Número de Concorrentes:** - Tratadas: 3.1 vs Controle: 2.9 - Lojas tratadas enfrentam ligeiramente mais competição local
- **Potencial de Crescimento:** - Tratadas: +0.09 (DP: 0.53) vs Controle:-0.15 (DP: 0.51) - Diferença: +0.24 desvios-padrão

Testes de Balanceamento (Teste t)

- **Renda per capita:** - Diferença: R\$ 67 - P-valor: 0.527 - Status: Balanceado (p > 0.05) - Interpretação: Não há evidência estatística de diferença significativa
- **Penetração de Internet:** - Diferença: 5.1 pontos percentuais - P-valor: 0.001 - Status: **DESBALANCEADO** (p < 0.05) - Interpretação: Lojas tratadas estão em mercados com penetração de internet significativamente maior

- **Potencial de Crescimento:** - Diferença: 0.24 desvios-padrão - P-valor: < 0.001 - Status: **DESBALANCEADO** ($p < 0.05$) - Interpretação: Lojas tratadas têm potencial de crescimento sistematicamente maior
- **Vendas PRÉ-tratamento:** - Diferença: R\$ 1.573 - P-valor: 0.228 - Status: Balanceado ($p > 0.05$) - Interpretação: Não há diferença estatisticamente significativa nos níveis de vendas pré-campanha

Conclusões e Implicações

Problemas identificados:

Os grupos apresentam desbalanceamento significativo em duas dimensões críticas: 1.

Penetração de internet significativamente diferente ($p = 0.001$) 2. **Potencial de crescimento** significativamente diferente ($p < 0.001$)

Consequências para inferência causal:

Por exemplo: o Teste A/B simples será viesado porque não consegue separar: - Efeito verdadeiro da campanha - Vantagem estrutural de lojas em mercados mais digitalizados - Tendência natural de crescimento das lojas com maior potencial

O crescimento observado pós-campanha pode refletir características intrínsecas das lojas (maior potencial digital, mercados com mais usuários de internet) e não necessariamente o impacto da intervenção.

Ponto positivo: As vendas PRÉ-tratamento estão balanceadas ($p = 0.228$), indicando que os grupos partem de níveis similares. O desbalanceamento concentra-se nas variáveis que influenciam a **trajetória** de crescimento, não o nível inicial.

Métodos de Balanceamento

Podemos notar que as lojas apresentam características distintas, o que pode levar a um viés na avaliação de impacto causal. Para abordar esse desafio e conseguir isolar o Efeito verdadeiro da campanha das vantagens estruturais (como lojas em mercados mais digitalizados ou lojas com maior potencial intrínseco de crescimento), existem Métodos de Pareamento.

Esses métodos buscam criar grupos de tratamento e controle mais comparáveis, ajustando as diferenças observadas entre as lojas antes da intervenção. O objetivo é garantir que o crescimento observado após a campanha seja atribuível à intervenção e não a características pré-existentes ou tendências naturais de crescimento.

Os métodos de pareamento minimizam as diferenças entre os grupos de tratamento e controle com base em características observáveis (variáveis explicativas), criando um cenário mais próximo de um experimento aleatório. Dessa forma, é possível estimar o

efeito médio do tratamento de maneira menos enviesada, especialmente quando a randomização não é viável.

Existem diversos métodos para gerar pesos ou emparelhamentos que equilibram os grupos, sendo os principais e mais utilizados:

Propensity Score Matching (PSM):

- Baseia-se na probabilidade estimada de cada unidade receber o tratamento, dada suas características observáveis. O método emparelha unidades tratadas e não tratadas com propensões semelhantes, reduzindo o viés de seleção. É simples de implementar e amplamente usado em estudos aplicados de economia, saúde e ciências sociais.

Entropy Balancing (EB):

- Em vez de emparelhar diretamente, o método atribui pesos ótimos às unidades de controle para que as médias (e opcionalmente variâncias e momentos superiores) das covariáveis fiquem idênticas às do grupo tratado. Garante balanceamento perfeito das covariáveis observáveis e mantém todo o conjunto de dados (sem descarte de observações). É especialmente útil em amostras pequenas ou quando há muitas variáveis de controle.

Outros métodos relacionados incluem:

- Inverse Probability Weighting (IPW): usa o inverso do propensity score como peso. O IPW dá mais peso aos indivíduos que receberam um tratamento "improvável" dado o seu perfil.
- Covariate Balancing Propensity Score (CBPS): ajusta simultaneamente o modelo de propensão e o balanceamento das covariáveis.
- Genetic Matching: otimiza o balanceamento via algoritmos evolutivos, sem depender apenas do propensity score.
- Podemos utilizar qualquer modelo que gere probabilidades, por exemplo xgboost, logit, probit, random forest etc.

Em resumo, esses métodos buscam corrigir o viés de seleção em dados observacionais, permitindo inferências causais mais robustas quando a aleatorização não é possível.

Entropy Balancing (EB)

```
In [16]: #-----  
# Estimar pesos por Entropy Balancing  
#-----  
  
modelo_entropy <- weightit(  
  formula = tratamento ~ renda_per_capita + penetracao_internet +
```

```

        n_concorrentes + potencial_crescimento,
data = lojas,
method = "ebal",
estimand = "ATT"
)

lojas_weighted <- lojas %>%
  mutate(peso = modelo_entropy$weights)

#-----
# Função auxiliar para gerar tabela de balanceamento
#-----

teste_balance <- function(data, pesos = NULL, periodo) {
  vars <- c("renda_per_capita", "penetracao_internet", "n_concorrentes", "potenc
  resultados <- data.frame()

  for (v in vars) {
    if (is.null(pesos)) {
      # Sem pesos
      ttest <- t.test(data[[v]] ~ data$tratamento)
      medias <- data %>%
        group_by(tratamento) %>%
        summarise(media = mean(.data[[v]])) %>%
        pull(media)
      pval <- ttest$p.value
    } else {
      # Com pesos - usar regressão ponderada para p-valor
      d <- data.frame(x = data[[v]], tr = data$tratamento, w = pesos)
      medias <- d %>%
        group_by(tr) %>%
        summarise(media = weighted.mean(x, w)) %>%
        pull(media)

      # P-valor via regressão ponderada
      modelo <- lm(x ~ tr, data = d, weights = w)
      pval <- summary(modelo)$coefficients["tr", "Pr(>|t|)"]
    }

    resultados <- rbind(resultados, data.frame(
      Período = periodo,
      Variável = v,
      Média_Control = round(medias[1], 3),
      Média_Tratadas = round(medias[2], 3),
      Diferença = round(medias[2] - medias[1], 3),
      P_valor = round(pval, 4)
    ))
  }
  return(resultados)
}

#-----
# Gerar tabelas antes e depois
#-----

tabela_antes <- teste_balance(lojas, pesos = NULL, periodo = "Antes")
tabela_depois <- teste_balance(lojas_weighted, pesos = lojas_weighted$peso, peri

# Empilhar
tabela_final <- rbind(tabela_antes, tabela_depois)

```

```
#-----
# Exibir
#-----

print(tabela_final, row.names = FALSE)
```

Período	Variável	Média_Control	Média_Tratadas	Diferença	P_valor
Antes	renda_per_capita	2977.007	3043.816	66.809	0.5273
Antes	penetracao_internet	0.694	0.745	0.051	0.0010
Antes	n_concorrentes	2.895	3.103	0.208	0.3494
Antes	potencial_crescimento	-0.147	0.090	0.237	0.0005
Depois	renda_per_capita	3043.815	3043.816	0.001	1.0000
Depois	penetracao_internet	0.745	0.745	0.000	1.0000
Depois	n_concorrentes	3.103	3.103	0.000	1.0000
Depois	potencial_crescimento	0.090	0.090	0.000	1.0000

Interpretação do Balanceamento com Entropy Balancing

O Método Escolhido: Entropy Balancing

Utilizamos **Entropy Balancing** (Hainmueller, 2012) que repondera o grupo controle para que suas médias das covariáveis sejam exatamente iguais às do grupo tratado. O método resolve um problema de otimização: encontrar pesos que minimizem a distância de entropia (mantendo pesos próximos de 1) enquanto satisfazem restrições de balanceamento perfeito nas médias.

Vantagens demonstradas:

Balanceamento exato alcançado (diferença = 0.000 em todas as variáveis) - Mantém toda a amostra (não descarta unidades) - Procedimento automático, sem escolhas arbitrárias

Balanceamento perfeito alcançado:

Todas as variáveis apresentam diferença ≈ 0.000 - Todos os p-valores = 1.000 - Médias do grupo controle (ponderado) são idênticas às médias do grupo tratado

Interpretação:

O Entropy Balancing foi bem-sucedido em: 1. Eliminar completamente o desbalanceamento no potencial de crescimento (problema crítico) 2. Garantir balanceamento exato nas médias de todas as covariáveis 3. Criar um grupo controle "sintético" que é estatisticamente indistinguível do grupo tratado em termos de características observáveis

Implicação:

Agora podemos comparar tratados vs controles ponderados com confiança de que diferenças nos resultados refletem o efeito da campanha, não diferenças pré-existentes nas características das lojas. O teste A/B aplicado aos dados ponderados deve fornecer estimativa menos viesada do efeito causal.

Teste A/B

O que é Teste A/B?

Um **Teste A/B** é um experimento onde você:

1. **Sorteia aleatoriamente** unidades em dois grupos (Primeiro problema nesse exercício)
 2. **Grupo A** não recebe a intervenção (controle)
 3. **Grupo B** recebe a intervenção (tratamento)
 4. **Compara** os resultados usando **teste t de diferenças de médias**
-

Teste t de Diferenças de Médias

- O **teste t** verifica se a diferença entre os grupos é estatisticamente significativa:

Hipóteses:

- **H₀** (nula): Média_tratamento = Média_controle (não há efeito)
- **H₁** (alternativa): Média_tratamento $\neq$ Média_controle (há efeito)

Interpretação:

- Se **p-valor** < **0.05**: Rejeitamos H₀ → Efeito é real
- Se **p-valor** $\geq$ **0.05**: Não rejeitamos H₀ → Não há evidência de efeito

Conclusão: $p < 0.05$ → Campanha aumentou vendas significativamente!

Qual o pressuposto principal do A/B test que garante a validade dos resultados?

- **Randomização** garante que os grupos sejam idênticos em TODAS as características (renda, localização, tamanho, etc).
- A única diferença = tratamento\
- Teste t detecta se essa diferença é real ou apenas variação aleatória\
- Qualquer diferença significativa = efeito causal

Quando NÃO funciona?

- **Não há randomização** empresa escolhe as lojas que irão receber a campanha de marketing\
- **Grupos já são diferentes** antes do tratamento\
- **Unidades interferem umas nas outras** (efeito viral)\
- **Teste t detecta diferença, mas não sabemos se é da campanha ou de características pré-existentes**

O pressuposto Principal: a atribuição do tratamento deve vir de um processo randomizado

Teste A/B Ingênuo

O Teste A/B Ingênuo desconsidera as covariáveis

```
In [17]: # =====
# TESTE A/B Ingênuo ou Simples
# =====

# PASSO 1: Agregar vendas pós-tratamento por Loja
# Por quê? A unidade de tratamento é a LOJA, não Loja-período
# Precisamos de 1 observação por Loja (50 obs), não 600 (50 Lojas x 12 meses)
# Nesse caso específico não faria diferença o resultado com as 600 observações

vendas_pos_agregado <- dados %>%
  filter(pos == 1) %>%           # Apenas período pós-campanha
  group_by(loja_id, tratamento) %>% # Agrupar por Loja
  summarise(vendas_media = mean(vendas), # Média de vendas nos 12 meses pós
            .groups = "drop")

# PASSO 2: Teste t com N = 50 Lojas
teste_ab <- t.test(vendas_media ~ tratamento, data = vendas_pos_agregado)

# PASSO 3: Extrair resultados
efeito_ab <- diff(teste_ab$estimate)
efeito_verdadeiro <- mean(dados$efeito_verdadeiro[dados$efeito_verdadeiro > 0])

# PASSO 4: Resultados
cat("Efeito estimado (A/B):", round(efeito_ab, 2), "\n")
cat("P-valor:", formatC(teste_ab$p.value, format = "f", digits = 4), "\n")
cat("\nEfeito verdadeiro:", round(efeito_verdadeiro, 2), "\n")
cat("Viés:", round(efeito_ab - efeito_verdadeiro, 2), "\n")
cat("Erro relativo:", round(100 * (efeito_ab - efeito_verdadeiro) / efeito_verdadeiro, 2), "%")
```

Efeito estimado (A/B): 8310.23

P-valor: 0.0000

Efeito verdadeiro: 6012.28

Viés: 2297.95

Erro relativo: 38.2 %

Interpretação dos Resultados

- **Efeito estimado:** R\$ 8.310,23
- **P-valor:** < 0.0001 (altamente significativo)
- **Efeito verdadeiro:** R\$ 6.012,28
- **Viés:** R\$ 2.297,95 (38.2% de superestimação)

O que o Teste A/B Nos Diz

Significância Estatística: O teste detectou uma diferença real e substancial entre os grupos ($p < 0.001$). Isso significa que a diferença observada dificilmente ocorreria por acaso. Com uma amostra de 250 lojas, o teste tem alto poder estatístico para detectar diferenças.

Validade Causal: Apesar da significância estatística, o efeito está **superestimado em 38%**. O teste A/B está capturando mais do que apenas o efeito da campanha.

Decomposição do Efeito Observado

O valor estimado pelo A/B (R\$ 8.310) contém:

1. **Efeito causal real da campanha:** R\$ 6.012
2. **Viés de seleção (diferenças pré-existentes):** R\$ 2.298
3. **Total observado:** R\$ 8.310

Proporção do viés: 28% do efeito observado não vem da campanha, mas sim de características estruturais das lojas tratadas.

Por Que Há Viés?

Problema identificado: As lojas tratadas eram sistematicamente diferentes ANTES da campanha:

- **Maior penetração de internet** (74.5% vs 69.4%, $p = 0.001$)
- **Maior potencial de crescimento** (+0.09 vs -0.15 d.p., $p < 0.001$)
- **Mercados mais digitalizados** → naturalmente crescem mais rápido

Consequência: O teste A/B simples confunde: - Efeito da campanha (R 6.012) $\leftarrow$ *oquequeremosmedir* - *Vantagemestruturaldaslojastratadas* (R 2.298) $\leftarrow$ viés de seleção

Conclusão

Significância $\neq$ Causalidade

- O p-valor baixo confirma que há diferença estatística entre os grupos
- Mas **NÃO** confirma que essa diferença vem exclusivamente da campanha
- Parte substancial do efeito (38%) é artefato de seleção não-aleatória

Teste A/B com Balanciamento de Covariáveis

O Problema do Teste A/B Simples (Sem variáveis de Controle)

No exercício anterior realizamos um teste A/B simples pós-tratamento, desconsideramos totalmente as características das lojas, ou seja, ignoramos que os grupos NÃO são comparáveis porque a empresa escolheu lojas estrategica

Consequência:

- Lojas tratadas **já vendiam mais** antes da campanha
- Lojas tratadas **já cresciam mais rápido** antes da campanha
- O teste A/B confunde efeito da campanha com diferenças pré-existent

```
In [18]: # =====
# TESTE A/B COM ENTROPY BALANCING
# =====

# PASSO 1: Agregar vendas pós-tratamento (igual ao teste simples)
vendas_pos_agregado <- dados %>%
  filter(pos == 1) %>%
  group_by(loja_id, tratamento) %>%
  summarise(vendas_media = mean(vendas), .groups = "drop")

# PASSO 2: Adicionar pesos do Entropy
vendas_pos_weighted <- vendas_pos_agregado %>%
  left_join(lojas_weighted %>% select(loja_id, peso), by = "loja_id")

# PASSO 3: Calcular efeito com médias ponderadas
# ATT = média(tratadas) - média_ponderada(controles)
efeito_entropy <- mean(vendas_pos_weighted$vendas_media[vendas_pos_weighted$tratamento == 1]) -
  weighted.mean(vendas_pos_weighted$vendas_media[vendas_pos_weighted$tratamento == 0],
    vendas_pos_weighted$peso[vendas_pos_weighted$tratamento == 0])

# PASSO 4: Bootstrap para p-valor
set.seed(123)
efeitos_boot <- replicate(1000, {
  idx <- sample(nrow(vendas_pos_weighted), replace = TRUE)
  dados_boot <- vendas_pos_weighted[idx, ]

  mean(dados_boot$vendas_media[dados_boot$tratamento == 1]) -
    weighted.mean(dados_boot$vendas_media[dados_boot$tratamento == 0],
      dados_boot$peso[dados_boot$tratamento == 0])
})

pvalor <- 2 * min(mean(efeitos_boot <= 0), mean(efeitos_boot >= 0))

# PASSO 5: Resultados
cat("\nEfeito estimado (Entropy):", round(efeito_entropy, 2), "\n")
cat("P-valor (bootstrap):", formatC(pvalor, format = "f", digits = 4), "\n")
cat("\nEfeito verdadeiro:", round(efeito_verdadeiro, 2), "\n")
cat("Viés:", round(efeito_entropy - efeito_verdadeiro, 2), "\n")
cat("Erro relativo:", round(100 * (efeito_entropy - efeito_verdadeiro) / efeito_
```

Efeito estimado (Entropy): 5981.77
P-valor (bootstrap): 0.0000

Efeito verdadeiro: 6012.28
Viés: -30.52
Erro relativo: -0.5 %

Interpretação dos resultados

Resultados

- **Efeito estimado:** R\$ 5.981,77
- **P-valor:** < 0.001 (altamente significativo)
- **Efeito verdadeiro:** R\$ 6.012,28
- **Viés:** -R\$ 30,52 (erro relativo: -0.5%)

Análise

Precisão da estimativa:

O Entropy Balancing produziu estimativa **praticamente perfeita** do efeito causal. Com viés de apenas -R\$30,52 em um efeito real de R\$ 6.012, o erro relativo é de 0.5% - essencialmente desprezível. Isso demonstra que o balanceamento das covariáveis foi extremamente eficaz em remover o viés de seleção de R\$ 2.298 identificado no teste A/B simples.

Significância estatística:

O teste alcançou alta significância estatística ($p < 0.001$), confirmando que o efeito observado é real e não fruto de variação aleatória.

Sucesso do balanceamento:

A tabela mostra que o Entropy Balancing eliminou completamente os desbalanceamentos críticos: - **Penetração de internet:** diferença de 0.051 ($p = 0.001$) → 0.000 ($p = 1.000$) - **Potencial de crescimento:** diferença de 0.237 ($p < 0.001$) → 0.000 ($p = 1.000$)

Todas as covariáveis apresentam diferença exatamente zero após ponderação, com p-valores = 1.000.

Comparação: A/B Simples vs Entropy

Método	Efeito	P-valor	Viés	Erro Relativo	Conclusão
A/B Simples	R\$ 8.310	< 0.001	+R\$ 2.298	+38.2%	Significativo mas VIESADO
A/B Entropy	R\$ 5.982	< 0.001	-R\$ 31	-0.5%	Significativo e PRECISO
Verdadeiro	R\$ 6.012	-	0	0%	-

Contraste fundamental:

- **A/B simples:** Detecta efeito significativo, mas superestima em 38% devido ao viés de seleção
 - **Entropy:** Detecta efeito significativo com precisão quase perfeita (erro < 1%)
-

Implicações Práticas

Decisão de negócio baseada em A/B simples: > "Campanha gera R\$ 8.310/mês por loja → ROI de 300% → expandir para todas as lojas!"

Realidade (revelada pelo Entropy): > "Campanha gera R\$ 5.982/mês por loja → ROI de 220% → ainda excelente, mas 28% menor que o projetado"

Impacto financeiro:

Expandindo para 500 lojas da rede: - **Projeção A/B simples:** $R8.310 \times 500 = R4.155.000/\text{mês}$ - **Realidade (Entropy):** $R5.982 \times 500 = R2.991.000/\text{mês}$ - **Diferença:** R\$ 1.164.000/mês de expectativa inflacionada (38% de erro)

Por Que Entropy Funcionou?

Mecanismo:

1. Identificou desbalanceamento crítico em penetração de internet ($p = 0.001$) e potencial de crescimento ($p < 0.001$)
2. Reponderou grupo controle para torná-lo estatisticamente idêntico ao grupo tratado nessas dimensões
3. Comparação pós-balanceamento isola apenas o efeito da campanha, removendo vantagens estruturais das lojas tratadas

Resultado:

- Viés de R2.298 ($A/B \text{ simples}$) → Viés de R 31 (Entropy)
 - **Redução de 98.7% no viés**
-

Lição Principal

Entropy Balancing demonstrou:

- **Precisão:** Remove viés quase completamente (erro de apenas 0.5%)
- **Poder estatístico:** Mantém significância estatística ($p < 0.001$)
- **Eficiência:** Usa toda a amostra (não descarta unidades como PSM faria)
- **Confiabilidade:** Fornece estimativa precisa para decisões de negócio

Conclusão:

A campanha realmente gera retorno de $\sim R6.000/mês$ por loja, não os $R 8.310$ sugeridos pelo teste A/B simples. Esta diferença de 38% é crítica para planejamento financeiro e decisões de expansão. O Entropy Balancing corrigiu o viés de seleção, permitindo decisões baseadas no efeito causal verdadeiro.

Teste A/B PrePost Bayesiano

O Teste A/B do `abpackage` em R implementa o método ``PrePost``, uma abordagem Bayesiana para a estimação do efeito de tratamento em testes A/B.

O que ele faz?

O pacote `abpackage` em R implementa o método `PrePost`, uma abordagem Bayesiana para a estimação do efeito de tratamento em testes A/B. Quando há dados disponíveis do período anterior ao experimento (pré-período), o método os utiliza para obter uma estimativa mais precisa do efeito do tratamento.

Como funciona?

Para cada métrica, os nomes "pre" e "post" indicam, respectivamente, os períodos antes e depois do início do experimento. Os nomes "control" e "treatment" indicam os dois grupos de condição.

Primeiro, o método estima a média e a variância da métrica no pré-período. Em seguida, estima as médias e variâncias no pós-período, condicionalmente à estimativa da média no pré-período.

Para cada métrica, o `PrePost` retorna a estimativa da variação percentual entre a média do grupo de tratamento e a média do grupo de controle no pós-período. Além disso, o `PrePost` também calcula a diferença absoluta entre as médias do grupo de tratamento e do grupo de controle no pós-período.

1. O que ele NÃO faz

O `PrePost` não reamostra, não repondera e não emparelha (match) unidades do grupo de controle e tratamento. Ou seja, ele não altera os dados brutos nem tenta "forçar" o equilíbrio das médias no pré-período.

2. Resumo do que ele faz

Ele estima a relação entre o pré e o pós-período (via correlação ρ) e condiciona a distribuição posterior do pós-período à média observada no pré. Matematicamente, isso

equivale a ajustar o pós-período levando em conta a variação que já existia antes do tratamento.

Intuição por trás do método

- Se o grupo de tratamento já estava um pouco acima (ou abaixo) do controle antes do experimento, o PrePost desconta essa diferença ao estimar o efeito real.

Preparar dados

```
In [19]: # preparar dataframe
df_ab <- dados %>%
  group_by(loja_id, tratamento) %>%
  summarise(
    pre = mean(vendas[periodo < intervencao]),
    post = mean(vendas[periodo >= intervencao]),
    .groups = "drop"
  ) %>%
  mutate(
    condition = factor(ifelse(tratamento == 1, "treatment", "control")),
    metric = "vendas"
  ) %>%
  select(pre, post, condition, metric)

cat("\n=== ESTRUTURA DOS DADOS ===\n")
print(head(df_ab, 10))
cat("\nResumo por condição:\n")
print(df_ab %>% group_by(condition) %>% summarise(n = n(), media_post = mean(post)))

=== ESTRUTURA DOS DADOS ===
# A tibble: 10 × 4
      pre    post condition metric
  <dbl> <dbl> <fct>    <chr>
1 85635.  90599. control  vendas
2 79174.  90094. treatment vendas
3 86867. 101431. treatment vendas
4 78310.  89495. treatment vendas
5 89504. 102327. treatment vendas
6 93351.  97904. control  vendas
7 87400.  98950. treatment vendas
8 72847.  81095. treatment vendas
9 79034.  81793. control  vendas
10 85436.  89018. control  vendas

Resumo por condição:
# A tibble: 2 × 3
  condition     n media_post
  <fct>    <int>    <dbl>
1 control     95    92804.
2 treatment  155   101115.
```

```
In [20]: # =====
# Análise 1: SEM correção pré-período
# =====
resultado_sem_correcao <- PrePost(dplyr::select(df_ab, -pre))

# =====
```



```

# Análise 2: COM correção pré-período
# =====
resultado_com_correcao <- PrePost(df_ab)

# =====
# Análise 3: COM correção Benjamini-Hochberg
# =====
resultado_bh_correcao <- PrePost(df_ab, p.method = "BH")

# =====
# Extrair resultados
# =====

extrair_resultado <- function(resultado, nome) {
  if(is.null(resultado$cis)) return(NULL)

  # Mudança absoluta (difference)
  diff <- resultado$cis[resultado$cis$type == "difference", ]

  data.frame(
    Metodo = nome,
    Efeito = round(diff$median, 2),
    IC_Lower = round(diff$lower, 2),
    IC_Upper = round(diff$upper, 2),
    P_valor = round(diff$p.value, 4)
  )
}

# =====
# Tabela comparativa
# =====

tabela_prepost <- rbind(
  extrair_resultado(resultado_sem_correcao, "Sem correção pré"),
  extrair_resultado(resultado_com_correcao, "Com correção pré"),
  extrair_resultado(resultado_bh_correcao, "Benjamini-Hochberg")
)

tabela_prepost$Vies <- tabela_prepost$Efeito - 6012
tabela_prepost$Erro_Pct <- round((tabela_prepost$Vies / 6012) * 100, 1)

cat("\n=== RESULTADOS PREPOST ===\n\n")
print(tabela_prepost, row.names = FALSE)
cat("\nEfeito Verdadeiro: R$ 6012\n")

```

=== RESULTADOS PREPOST ===

	Metodo	Efeito	IC_Lower	IC_Upper	P_valor	Vies	Erro_Pct
	Sem correção pré	8310.23	5382.44	11238.02	0	2298.23	38.2
	Com correção pré	6513.59	6092.88	6934.88	0	501.59	8.3
	Benjamini-Hochberg	6513.59	6092.88	6934.88	0	501.59	8.3

Efeito Verdadeiro: R\$ 6012

Análise dos Resultados: abpackage PrePost

Comparação dos Métodos

Método	Efeito	IC 95%	Viés	Erro Relativo
Sem correção pré	R\$ 8.310	[5.382, 11.238]	+R\$ 2.298	+38.2%
Com correção pré	R\$ 6.514	[6.093, 6.935]	+R\$ 502	+8.3%
Benjamini-Hochberg	R\$ 6.514	[6.093, 6.935]	+R\$ 502	+8.3%
Efeito Verdadeiro	R\$ 6.012	-	0	0%

Principais Conclusões

1. Correção pré-período é ESSENCIAL:

- Sem correção: viés de **+38%** - resultado completamente distorcido
- Com correção: viés de **+8%** - melhora dramática
- Redução do viés:** 78% (de 2.298 para 502)

2. Intervalos de confiança:

- Sem correção: IC muito amplo [5.382, 11.238] - incerteza de ~R\$ 6.000
- Com correção: IC estreito [6.093, 6.935] - incerteza de ~R\$ 850
- Precisão aumenta 7x** com correção pré-período

3. Benjamini-Hochberg:

- Idêntico à correção pré (ambos R\$ 6.514)
- BH ajusta p-valores para múltiplos testes
- Como temos apenas 1 métrica, não há ajuste adicional

4. Por que a correção funciona:

- Tratados e controles tinham **diferenças iniciais** (pré-tratamento)
- Sem correção: atribui diferenças pré ao tratamento (viés de seleção)
- Com correção: remove diferenças iniciais, isola efeito real

5. Comparação com outros métodos:

- TWFE + Cov×Período:** R\$ 6.015 (erro de 0.05%)
- C&S Doubly Robust:** R\$ 6.394 (erro de 6.4%)
- PrePost com correção:** R\$ 6.514 (erro de 8.3%)

PrePost com correção tem desempenho comparável aos métodos mais sofisticados.

Resultados modelos Teste A/B

Tabela: Ranking Modelos de Teste A/B

Ranking	Método	ATT (R\$)	Viés (R\$)	Erro %
1º	A/B + Entropy Balancing	5.981,77	-30,52	-0,5%
2º	PrePost Com Correção Pré	6.513,59	+501,59	+8,3%
3º	PrePost Benjamini-Hochberg	6.513,59	+501,59	+8,3%
4º	A/B Simples (Ingênuo)	8.310,23	+2.297,95	+38,2%
5º	PrePost Sem Correção Pré	8.310,23	+2.298,23	+38,2%

Diferença-em-Diferenças (canônico 2x2)

A estrutura canônica é baseada em dois períodos de tempo e dois grupos

No nosso caso , temos dois períodos principais:

1. **Período PRÉ** (meses 1-12): Antes da campanha
2. **Período PÓS** (meses 13-24): Depois da campanha

Embora tenhamos 24 meses de dados, o DiD canônico essencialmente agrega a análise em: (Média do período pré-tratamento - Média do período pós-tratamento)

Modelo Estatístico de Diferença em Diferenças (canônico)

$$\text{Vendas} = \beta_0 + \beta_1 \cdot \text{Tratamento} + \beta_2 \cdot \text{Pós} + \beta_3 \cdot (\text{Tratamento} \times \text{Pós}) + \varepsilon$$

Interpretação dos Coeficientes

Coeficiente	Nome	O que mede
β_0	Intercepto	Vendas médias do grupo controle no período PRÉ
β_1	Tratamento	Diferença entre grupos ANTES da campanha (viés de seleção!)
β_2	Pós	Mudança temporal para o grupo CONTROLE (tendência natural, sazonalidade)
β_3	Tratamento × Pós	EFEITO DiD Mudança ADICIONAL do grupo tratado

Por que β_3 é o efeito causal?

β_3 captura a mudança **além** do que já aconteceria naturalmente:

$$\beta_3 = (\text{Tratadas_pós} - \text{Tratadas_pré}) - (\text{Controle_pós} - \text{Controle_pré})$$

- Remove a diferença pré-existente (β_1)
- Remove a tendência temporal comum (β_2)
- **Isola** o efeito da campanha

Pressupostos do modelo DiD canônico (2x2)

Para que β_3 possa ser interpretado como efeito causal, precisamos assumir:

1. Tendências paralelas (Parallel Trends)

- Na ausência de tratamento, a diferença média entre tratadas e controle **se manteria constante ao longo do tempo**.
- Em termos práticos: o grupo controle é um bom contrafactual para o grupo tratado.

2. Ausência de choques específicos ao grupo tratado (Time-varying confounders)

- Não pode haver outro evento/política que afete **apenas** o grupo tratado **no mesmo período** da campanha.
- Se houver uma segunda intervenção só nas tratadas no mesmo "Pós", o β_3 mistura os dois efeitos.

3. Não antecipação (No Anticipation)

- As lojas **não mudam comportamento antes do tratamento** por já saberem que serão tratadas.
- Se os lojistas "se prepararem" para a campanha (estocarem mais, mudarem preços antes, etc.), o período PRÉ já fica contaminado.

4. Composição estável (Stable Composition)

- A população de lojas tratadas e controle **não muda de forma sistemática** entre PRÉ e PÓS.
- Entradas/saídas seletivas (por exemplo, só lojas fracas fechando em um grupo) podem distorcer o β_3 .

5. Ausência de efeitos de transbordamento (SUTVA / No Spillovers)

- O tratamento de uma loja **não deve afetar diretamente** o resultado de outra loja do grupo controle.
- Ex.: campanha em uma loja que "rouba" clientes de lojas-controle próximas → contamina o contrafactual.

6. Tratamento bem definido e aplicado no tempo correto

- O indicador **Pós** realmente captura o momento em que a campanha começou a valer.

- A adesão ao tratamento deve ser clara (quem é tratado e quando).

Em resumo: **se tendências paralelas forem plausíveis e os demais pressupostos não forem grosseiramente violados**, o coeficiente β_3 pode ser lido como uma boa aproximação do **efeito causal médio** da campanha sobre as vendas.

Diferença-em-Diferenças Canônico (2x2)

```
In [21]: # =====
# DIFERENÇA-EM-DIFERENÇAS (DiD) CANÔNICO (COM E SEM PESOS)
# =====

# Adicionar pesos aos dados Longitudinais
dados_weighted <- dados %>%
  left_join(lojas_weighted %>% select(loja_id, peso), by = "loja_id")

#.....
# DiD básico
#.....
modelo_did <- lm(vendas ~ tratamento + pos + tratamento:pos, data = dados)

#.....
# DiD com controles
#.....
modelo_did_cov <- lm(vendas ~ tratamento + pos + tratamento:pos + renda_per_capi
  data = dados)

#.....
# DiD com controles e pesos
#.....
modelo_did_weighted <- lm(vendas ~ tratamento + pos + tratamento:pos + renda_per
  data = dados_weighted, # pesos
  weights = peso
)

#.....
# Tabela comparativa
#.....
stargazer::stargazer(modelo_did, modelo_did_cov, modelo_did_weighted,
  type = "text",
  column.labels = c("DiD Simples", "DiD + Covariáveis", "DiD + Cov + Pesos"),
  model.numbers = FALSE
)

#.....
# Extrair efeitos
#.....
efeito_did <- coef(modelo_did)["tratamento:pos"]
efeito_did_cov <- coef(modelo_did_cov)["tratamento:pos"]
efeito_did_weighted <- coef(modelo_did_weighted)["tratamento:pos"]
efeito_verdadeiro <- mean(dados$efeito_verdadeiro[dados$efeito_verdadeiro > 0])

#.....
# Resumo dos efeitos
#.....
```

```

cat("\n=== RESUMO DOS EFEITOS ESTIMADOS ===\n\n")
cat("DiD Simples:           ", round(efeito_did, 2), "\n")
cat("DiD + Covariáveis:      ", round(efeito_did_cov, 2), "\n")
cat("DiD + Covariáveis + Pesos: ", round(efeito_did_weighted, 2), "\n")
cat("Efeito Verdadeiro:       ", round(efeito_verdadeiro, 2), "\n\n")

cat("Viés DiD Simples:        ", round(efeito_did - efeito_verdadeiro, 2),
    " (", round(100*(efeito_did - efeito_verdadeiro)/efeito_verdadeiro, 1), "%)\n")
cat("Viés DiD + Covariáveis:   ", round(efeito_did_cov - efeito_verdadeiro, 2),
    " (", round(100*(efeito_did_cov - efeito_verdadeiro)/efeito_verdadeiro, 1),
cat("Viés DiD + Cov + Pesos:   ", round(efeito_did_weighted - efeito_verdadeiro, 2),
    " (", round(100*(efeito_did_weighted - efeito_verdadeiro)/efeito_verdadeiro, 2), "%)\n")

#.....
# Gráfico 2x2
#.....
# Médias agregadas por grupo e período (2x2)
did_agregado <- dados %>%
  group_by(tratamento, pos) %>%
  summarise(vendas_media = mean(vendas), .groups = "drop") %>%
  mutate(
    grupo = ifelse(tratamento == 1, "Tratadas", "Controle"),
    periodo = factor(ifelse(pos == 0, "Pré", "Pós"),
                     levels = c("Pré", "Pós"))
  )

ggplot(did_agregado, aes(x = periodo, y = vendas_media, group = grupo, color = grupo)) +
  geom_line(linewidth = 1.3) +
  geom_point(size = 3) +
  labs(
    title = "Vendas médias agregadas (DiD 2x2)",
    subtitle = "Média por grupo e período (Pré → Pós)",
    x = "Período",
    y = "Vendas médias (R$)",
    color = ""
  ) +
  theme_minimal(base_size = 15) +
  theme(
    plot.title = element_text(face = "bold", size = 18),
    plot.subtitle = element_text(size = 14),
    axis.title = element_text(size = 15),
    axis.text = element_text(size = 13),
    legend.text = element_text(size = 14),
    legend.position = "top"
  )

```

Dependent variable:			
		vendas	
	DiD Simples	DiD + Covariáveis	D
iD + Cov + Pesos			
tratamento	1,572.921***	-165.248	
93.055	(415.246)	(132.063)	
(129.687)			
pos	5,493.211***	5,493.211***	
6,341.832***	(462.399)	(145.371)	
(144.413)			
renda_per_capita		11.421***	
11.420***		(0.057)	
(0.057)			
penetracao_internet		27,171.190***	
27,056.600***		(368.754)	
(369.558)			
n_concorrentes		-2,007.025***	
-2,007.066***		(26.522)	
(26.630)			
tratamento:pos	6,737.312***	6,737.312***	
5,888.690***	(587.247)	(184.622)	
(183.405)			
Constant	87,311.200***	40,267.280***	
40,095.960***	(326.965)	(331.848)	
(349.118)			
Observations	6,000	6,000	
6,000			
R2	0.207	0.922	
0.922			
Adjusted R2	0.207	0.922	
0.922			
Residual Std. Error	11,039.620 (df = 5996)	3,470.695 (df = 5993)	3,4
47.825 (df = 5993)			
F Statistic	521.946*** (df = 3; 5996)	11,752.370*** (df = 6; 5993)	11,76
9.130*** (df = 6; 5993)			

Note:

*p<0.

1; **p<0.05; ***p<0.01


=== RESUMO DOS EFEITOS ESTIMADOS ===

DiD Simples:	6737.31
DiD + Covariáveis:	6737.31
DiD + Covariáveis + Pesos:	5888.69
Efeito Verdadeiro:	6012.28

Viés DiD Simples:	725.03	(12.1 %)
Viés DiD + Covariáveis:	725.03	(12.1 %)
Viés DiD + Cov + Pesos:	-123.59	(-2.1 %)

Vendas médias agregadas (DiD 2x2)

Média por grupo e período (Pré → Pós)



Validação do Modelo: Testes de Diagnóstico

```
In [22]: # Testes de diagnóstico
model <- modelo_did_cov
test_autocor <- check_autocorrelation(model)
test_collinea <- check_collinearity(model)
test_hetero <- check_heteroscedasticity(model)
test_outlier <- check_outliers(model)

# Print simples com cat()
cat("\n===== DIAGNÓSTICOS DO MODELO =====\n")

cat("\nAutocorrelação:\n")
print(test_autocor)

cat("\nColinearidade:\n")
print(test_collinea)

cat("\nHeteroscedasticidade:\n")
```



```
print(test_hetero)

cat("\nOutliers / Influência:\n")
print(test_outlier)
```

===== DIAGNÓSTICOS DO MODELO =====

Autocorrelação:

Warning: Autocorrelated residuals detected (p < .001).

Colinearidade:

Check for Multicollinearity

Low Correlation

Term	VIF	VIF 95% CI	adj. VIF	Tolerance	Tolerance 95% CI
tratamento	2.05	[1.97, 2.13]	1.43	0.49	[0.47, 0.51]
pos	2.63	[2.53, 2.74]	1.62	0.38	[0.36, 0.40]
renda_per_capita	1.01	[1.00, 1.14]	1.00	0.99	[0.87, 1.00]
penetracao_internet	1.04	[1.02, 1.08]	1.02	0.96	[0.92, 0.98]
n_concorrentes	1.01	[1.00, 1.11]	1.01	0.99	[0.90, 1.00]
tratamento:pos	3.63	[3.48, 3.79]	1.91	0.28	[0.26, 0.29]

Heteroscedasticidade:

OK: Error variance appears to be homoscedastic (p = 0.059).

Outliers / Influência:

OK: No outliers detected.

- Based on the following method and threshold: cook (0.9).

- For variable: (Whole model)

Interpretação dos testes de ajuste do modelo

Os diagnósticos do modelo indicam que os resíduos apresentam autocorrelação significativa, algo comum em dados de painel, o que sugere a necessidade de erros-padrão robustos agrupados por loja para garantir inferência válida. A análise de colinearidade mostra VIFs baixos, indicando ausência de multicolinearidade relevante entre as covariáveis, o que torna as estimativas estáveis. O teste de heteroscedasticidade não encontrou evidências fortes de variância desigual dos resíduos, sugerindo homocedasticidade, embora em aplicações de painel ainda seja recomendável o uso de erros robustos. Por fim, a verificação de outliers e pontos influentes não identificou observações problemáticas, indicando que o modelo não está sendo distorcido por casos extremos.

Análise dos Resultados do DID

Modelo 1: DiD Simples (sem covariadas e sem pesos)

$$\text{vendas} = \beta_0 + \beta_1 \cdot \text{tratamento} + \beta_2 \cdot \text{pos} + \beta_3 \cdot (\text{tratamento} \times \text{pos}) + \varepsilon$$

- **Efeito DiD:** R\$ 6.737 (p < 0.001)
- **Viés:** +12.1% de superestimação
- **R²:** 0.207 (baixo poder explicativo)

- **Interpretação:** Controla diferenças em níveis (β_1) e tendências comuns (β_2), mas não captura tendências específicas de grupo

Por que ainda há viés? O DiD assume **tendências paralelas** no período pré-tratamento, Se tratados e controles têm trajetórias naturalmente diferentes, DiD simples pode falhar

Modelo 2: DiD + Covariáveis

+ renda_per_capita + penetracao_internet + n_concorrentes

- **Efeito DiD:** R\$ 6.737 (idêntico ao modelo 1!)
- **Viés:** +12.1% (não mudou)
- **R²:** 0.922 (excelente ajuste geral do modelo)

Coeficientes

O coeficiente de `tratamento:pos` **não mudou absolutamente nada** ao adicionar covariáveis. Por quê?

1. **Covariáveis são fixas no tempo:** renda, internet, concorrentes não variam ao longo dos 24 meses
2. **DiD já remove efeitos fixos:** O termo `tratamento` já captura diferenças de nível associadas a características fixas
3. **Covariáveis melhoram precisão, não removem viés:** R² subiu de 0.207 → 0.922, erro padrão caiu (587 → 185), mas o viés permaneceu

Lição: Em DiD, covariáveis fixas **não corrigem viés** se o problema for tendências divergentes no tempo.

Modelo 3: DiD + Covariáveis + Pesos (Entropy)

- **Efeito DiD:** R\$ 5.889 ($p < 0.001$)
- **Viés:** -2.1% (praticamente eliminado!)
- **Redução do viés:** De +12.1% → -2.1% = 85% de melhoria

Por que os pesos funcionaram?

O Entropy Balancing: 1. Reponderou o grupo controle para ter **mesmas características médias** que o tratado 2. Garantiu que tendências específicas relacionadas ao potencial digital fossem balanceadas 3. Criou contrafactual mais válido para o grupo tratado

Insights Importantes

1. Limitações do DiD:

DiD controla diferenças de nível pré-existent, mas não garante correção total se houver: - Tendências divergentes entre grupos - Violação da suposição de tendências paralelas

2. Covariáveis fixas em DiD:

Adicionar covariáveis que não variam no tempo: - Melhora precisão (reduz SE) - Melhora ajuste do modelo (R^2 maior) - NÃO remove viés se o problema for tendências diferentes

3. Entropy + DiD = Combinação Poderosa:

- Entropy: garante grupos balanceados em características
- DiD: controla diferenças de nível e tendências comuns
- Juntos: reduzem viés de 12% para 2%

Conclusão

O modelo **DiD + Covariáveis + Pesos** produziu estimativa mais precisa (viés -2.1%), mas ainda inferior ao **A/B Entropy cross-sectional** (viés -0.5%).

Possível explicação: DiD com painel usa dados pré e pós, o que adiciona estrutura temporal complexa. Se houver pequenas violações de tendências paralelas mesmo após balanceamento, algum viés residual pode permanecer.

Recomendação: Ambos os métodos (A/B Entropy e DiD+Entropy) convergem para efeito $\sim R$

5.900 – 6.000, *fornecendo evidência robusta de que o efeito causal verdadeiro está nesse*
8.310 do teste A/B ingênuo.

Diferença-em-Diferenças com Efeitos Fixos Bidirecionais (TWFE)

O que é DID Two-Way Fixed Effects (TWFE)?

TWFE é uma extensão do DiD canônico que permite n períodos e inclui:

- **Efeitos Fixos de Loja (α_i):** Controla todas as características fixas de cada loja. Cada loja tem seu próprio intercepto. Remove diferenças permanentes entre lojas.
- **Efeitos Fixos de Período (λ_t):** Controla choques comuns que afetam todas as lojas simultaneamente. Cada mês tem seu próprio intercepto. Remove sazonalidade e tendências gerais do mercado.

Modelo:

$$\text{vendas} = \text{efeitos_de_loja} + \text{efeitos_de_tempo} + \beta \cdot \text{tratamento} + \text{erro}$$

Em suma, o modelo de Diferença-em-Diferenças com Efeitos Fixos Bidirecionais é uma generalização do DiD canônico para painéis com múltiplos grupos e múltiplos períodos, controlando simultaneamente efeitos fixos de grupo e de tempo.

Como funciona o DID-TWFE

Controle de efeitos fixos: O modelo TWFE estima o efeito de um tratamento em um **painel de dados** (observações repetidas no tempo para cada loja) incluindo efeitos fixos para cada unidade e efeitos fixos para cada período.

O que ele faz: A regressão compara as mudanças no resultado ao longo do tempo entre as lojas tratadas e não tratadas, enquanto controla:

- por características não observadas e constantes de cada loja (efeitos fixos de loja),
- por choques, sazonalidade e tendências que afetam todas as lojas simultaneamente (efeitos fixos de tempo).

Assim, a identificação vem **da variação dentro das lojas ao longo do tempo**, após remover efeitos fixos bidirecionais.

Limitações do TWFE

- **Efeitos heterogêneos no tempo:** O TWFE é enviesado quando o efeito do tratamento varia entre lojas ou períodos. Ex.: algumas lojas recebem uma campanha mais intensa que outras.
- **Ponderação negativa:** O estimador TWFE é uma média ponderada dos efeitos individuais, podendo atribuir **pesos negativos**, produzindo coeficientes com sinal oposto ao verdadeiro.
- **Adoção escalonada:** Quando o tratamento começa em momentos diferentes para cada loja (staggered adoption), o TWFE pode gerar resultados enviesados. Ex.: campanha não iniciando ao mesmo tempo para todas as lojas.
- **Comparações proibidas:** O TWFE pode comparar lojas tratadas com lojas já-tratadas ou com lojas que serão tratadas futuramente, gerando comparações inválidas que não existem no DiD 2x2 clássico. Ex.: loja entra e sai da campanha; TWFE faz comparações inapropriadas com períodos de "tratamento futuro".

Pressupostos para Validade do DID-TWFE

Os pressupostos abaixo generalizam os requisitos do DiD 2x2 para o caso com múltiplos períodos e múltiplos grupos:

1. Tendências Paralelas Condicionais (Parallel Trends)

Na ausência do tratamento, **todas as lojas deveriam evoluir de forma paralela**, após controlar pelos efeitos fixos de loja e tempo. É o pressuposto central. Se tendências prévias forem diferentes, o β estará enviesado.

2. Ausência de Choques Específicos ao Grupo Tratado

Não pode haver outro evento ou política que afete apenas as lojas tratadas no mesmo período. Choques simultâneos específicos quebram a identificação.

3. Tratamento Exógeno Condicionalmente aos EF

A decisão de tratar ou quando tratar deve ser independente dos choques não observados, **após controlar por α_i e λ_t** .

4. Composição Estável

A população de lojas deve permanecer comparável ao longo do tempo (sem entradas/saídas seletivas que alterem tendências).

5. SUTVA / Ausência de Spillovers

O tratamento de uma loja não deve afetar a venda de outra loja não tratada. (Ex.: uma loja tratada não pode “roubar” demanda de uma loja controle próxima.)

6. Ausência de Efeitos Antecipatórios

As lojas não podem mudar seu comportamento **antes** do período de tratamento em antecipação à campanha.

7. Efeito Constante (A hipótese problemático do TWFE)

O TWFE implicitamente assume que o efeito do tratamento é constante entre lojas e ao longo do tempo. Se houver heterogeneidade de efeito, o estimador pode ser severamente enviesado (como demonstrado em Goodman-Bacon 2020).

Diferença-em-Diferenças TWFE

```
In [23]: # =====
# Preparar dados
# =====

# Dados para TWFE
dados_twfe <- dados %>%
  mutate(treated = tratamento * pos) %>%
  left_join(lojas_weighted %>% select(loja_id, peso), by = "loja_id")

# Dados para Sun & Abraham
dados_sa <- dados %>%
  mutate(
    cohort = ifelse(tratamento == 1, intervencao, 0),
    rel_time = ifelse(tratamento == 1, periodo - intervencao, -1000)
  ) %>%
  left_join(lojas_weighted %>% select(loja_id, peso), by = "loja_id")

# =====
# Estimar modelos TWFE
# =====

# TWFE sem covariadas
modelo_twfe <- feols(vendas ~ treated |
  loja_id + periodo, # efeitos fixos
  data = dados_twfe, # painel de dados
  cluster = c("loja_id", "periodo") # erros padrão clusterizados
)

# TWFE com covariadas
```

```

modelo_twfe_cov <- feols(vendas ~ treated + renda_per_capita + penetracao_internet
  loja_id + periodo, # efeitos fixos
  data = dados_twfe, # painel de dados
  cluster = c("loja_id", "periodo") # erros padrão clusterizados
)

# TWFE com covariadas (interagindo com tempo)
modelo_twfe_cov_int <- feols(vendas ~ treated + renda_per_capita*periodo + penet
  loja_id + periodo, # efeitos fixos
  data = dados_twfe, # painel de dados
  cluster = c("loja_id", "periodo") # erros padrão clusterizados
)

# TWFE com covariadas e pesos
modelo_twfe_weighted <- feols(vendas ~ treated + renda_per_capita + penetracao_i
  loja_id + periodo, # efeitos fixos
  data = dados_twfe, # painel de dados
  weights = ~peso, # pesos do Entropy Balancing
  cluster = c("loja_id", "periodo") # erros padrão clusterizados
)

# =====
# Resultados
# =====
etable(modelo_twfe, modelo_twfe_cov, modelo_twfe_cov_int, modelo_twfe_weighted,
  signif.code = c(`***` = 0.01, `**` = 0.05, `*` = 0.1),
  digits = 3,
  headers = c("TWFE ", "TWFE + Cov", "TWFE + Cov*Periodo", "TWFE + Cov + Pe
  title = "Impacto da campanha nas vendas - Modelos TWFE")

```

The variables 'renda_per_capita', 'penetracao_internet' and 'n_concorrentes' have been removed because of collinearity (see \$collin.var).
 The variables 'renda_per_capita', 'periodo', 'penetracao_internet' and 'n_concorrentes' have been removed because of collinearity (see \$collin.var).
 The variables 'renda_per_capita', 'penetracao_internet' and 'n_concorrentes' have been removed because of collinearity (see \$collin.var).

```

In [15]: # Comparação dos modelos
comparacao <- data.frame(
  Modelo = c("TWFE", "TWFE + Cov", "TWFE + Cov*Per", "TWFE + Pesos", "Verdadeiro
  Efeito = c(
    coef(modelo_twfe)["treated"],
    coef(modelo_twfe_cov)["treated"],
    coef(modelo_twfe_cov_int)["treated"],
    coef(modelo_twfe_weighted)["treated"],
    6012
  )
)

comparacao$Vies <- comparacao$Efeito - 6012
comparacao$Erro_Pct <- round((comparacao$Vies / 6012) * 100, 3)

comparacao

```

```

Out[15]:
      Modelo  Efeito      Vies  Erro_Pct
1      TWFE 6737.312  725.311854   12.064
2 TWFE + Cov 6737.312  725.311854   12.064
3 TWFE + Cov*Per 6014.735    2.734784    0.045
4 TWFE + Pesos 5888.690 -123.309563   -2.051
5  Verdadeiro 6012.000    0.000000    0.000

```

Análise dos Resultados: TWFE (Two-Way Fixed Effects)

Efeitos Estimados

Modelo	Efeito	Viés	Erro Relativo
TWFE Simples	R\$ 6.737	+R\$ 725	+12.1%
TWFE + Covariáveis	R\$ 6.737	+R\$ 725	+12.1%
TWFE + Cov × Período	R\$ 6.015	+R\$ 3	+0.05%
TWFE + Cov + Pesos (Entropy)	R\$ 5.889	-R\$ 123	-2.1%
Efeito Verdadeiro	R\$ 6.012	0	0%

Observação Importante: Colinearidade

Por que covariáveis foram removidas?

The variables 'renda_per_capita', 'penetracao_internet' and 'n_concorrentes' have been removed because of collinearity

Explicação simples:

As covariáveis (renda, internet, concorrentes) **não mudam ao longo do tempo** para cada loja. Os efeitos fixos de loja já capturam tudo que é constante. Portanto:

- Efeito fixo da loja 1 = já inclui que ela tem renda X, internet Y, etc.
- Tentar adicionar renda separadamente = redundante

Resultado: TWFE e TWFE + Covariáveis são **exatamente iguais** (ambos R\$ 6.737).

Análise dos Modelos Estimados

1. TWFE Simples (sem pesos):

- **Efeito:** R\$ 6.737 (superestimado em 12%)
- **Por quê?** Mesmo com efeitos fixos, TWFE assume que tratados e controles teriam trajetórias paralelas sem a campanha
- **Problema:** Lojas tratadas têm maior potencial digital → crescem mais rápido naturalmente
- **Resultado:** Parte do efeito observado vem dessa diferença de trajetória, não da campanha

2. TWFE + Covariáveis × Período:

- **Efeito:** R\$ 6.015 (erro de apenas +0.05% - **melhor estimativa**)
- **O que faz:** Permite que covariadas tenham efeitos diferentes ao longo do tempo
- **Coeficientes significativos:**

- Renda × Período: +0.122*** (lojas com maior renda crescem mais)
- Internet × Período: +1.019*** (maior penetração digital acelera crescimento)
- Concorrentes × Período: -0.964 (não significativo)
- **Por quê funciona?** Captura as tendências específicas que diferenciavam\ tratados e controles
- **Resultado:** Praticamente elimina o viés (R^2 within aumenta de 33.6%\ para 48.8%)

3. TWFE + Covariáveis + Pesos (Entropy):

- **Efeito:** R\$ 5.889 (subestimado em -2.1%)
- **Por quê?** Entropy Balancing reponderou os controles para terem características similares aos tratados
- **Limitação:** Pesos balanceiam níveis das covariadas, mas não capturam\ completamente as tendências divergentes
- **Resultado:** Melhora substancial vs TWFE simples, mas não tão preciso\ quanto modelo com interações

Comparação Entre Abordagens

Abordagem	R^2 Within	Viés	Principais Vantagens
TWFE Simples	33.6%	+12.1%	Simples, controla características fixas
TWFE + Cov × Período	48.8%	+0.05%	Captura tendências heterogêneas
TWFE + Pesos	28.0%	-2.1%	Balanceia covariadas, não assume forma

Conclusão

TWFE controla:

- Diferenças fixas entre lojas (características constantes)
- Choques temporais comuns (sazonalidade, tendências)

TWFE NÃO controla automaticamente:

- Tendências específicas divergentes entre grupos

Soluções disponíveis:

- **Interações com período:** Captura tendências explicadas por covariadas\ observáveis - **melhor performance** (erro de apenas 0.05%)
- **Pesos (Entropy):** Balanceia características entre grupos, reduz viés\ para -2.1%

Resultado prático:

- **Modelo com interações foi o mais preciso** - praticamente acertou o\ efeito verdadeiro
- Renda e penetração digital explicam as trajetórias divergentes entre\ grupos
- Modelo com pesos também reduz viés substancialmente, mas assume que\ balanceamento de níveis é suficiente

Diferença-em-Diferenças - Sun & Abraham (2021): Interaction-Weighted Estimator

TWFE vs S&A

O TWFE que acabamos de rodar assume que o efeito do tratamento é **constante** para todas as lojas em todos os períodos. Mas e se:

- O efeito da campanha **cresce ao longo do tempo**
- O efeito é **diferente entre lojas** (algumas se beneficiam mais)?
- Há **múltiplos momentos de tratamento** (adoção escalonada)?

Problema crítico do TWFE:

Quando há heterogeneidade de efeitos, TWFE pode:

1. **Comparar tratados com tratados** (em vez de tratados vs controles)
2. **Atribuir pesos negativos** a alguns períodos
3. **Produzir estimativas viesadas** mesmo quando tendências paralelas são válidas

Esse é o famoso problema das "comparações proibidas" (Goodman-Bacon, 2021).

Como o DID de Sun & Abraham Resolve?

Ideia central:

Em vez de estimar um efeito médio único, Sun & Abraham:

1. **Agrupa por cohort** (momento de entrada no tratamento)
 - No nosso caso: cohort 13 (lojas tratadas no mês 13)
 - Never-treated (lojas nunca tratadas)
2. **Estima efeitos separados** para cada período relativo ao tratamento
 - Mês 0 (primeiro mês pós): qual o efeito?
 - Mês 1, 2, 3... qual o efeito em cada?
3. **Usa apenas never-treated como controle**
 - Evita comparações entre tratados em momentos diferentes
 - Comparação limpa: tratados vs nunca-tratados
4. **Agrega com ponderação apropriada**
 - Combina efeitos por período para obter ATT (Average Treatment on Treated)

Modelo Sun & Abraham:

$$\text{vendas} = \alpha_i + \lambda_t + \sum \beta_r \cdot 1\{\text{cohort}=c, \text{rel_time}=r\} + \varepsilon$$

Onde: - β_r = efeito específico para cada período relativo ($r = 0, 1, 2, \dots$) - Permite que efeito varie ao longo do tempo - Cada cohort tem sua própria trajetória de efeitos

Vantagens do DID Sun & Abraham

Aspecto	TWFE	Sun & Abraham
Efeito estimado	Um único β	Múltiplos β_r (por período)
Heterogeneidade	Assume efeito constante	Permite efeito variável no tempo
Comparações	Usa todos vs todos	Apenas tratados vs never-treated
Pesos	Podem ser negativos	Sempre não-negativos
Viés	Possível com heterogeneidade	Robusto à heterogeneidade
Interpretação	Efeito médio global	Efeito por "tempo desde tratamento"

Quando Usar Sun & Abraham?

Use Sun & Abraham quando:

- Suspeita de efeitos heterogêneos ao longo do tempo\
- Múltiplos momentos de tratamento (staggered adoption)\
- Quer entender dinâmica temporal do efeito\
- Precisa de estimativa robusta à heterogeneidade

TWFE ainda é OK quando:

- Tratamento único, simultâneo (nosso caso!)\
- Efeito razoavelmente constante no tempo\
- Foco em efeito médio simples

No caso deste exemplo:

- Tratamento único no mês 13
- Todas as lojas tratadas ao mesmo tempo
- Efeito pode variar ao longo dos 12 meses pós-campanha

Pressupostos Necessários para Validade do DID Sun & Abraham

- Os pressupostos são semelhantes ao DiD tradicional, mas adaptados ao caso com múltiplos períodos e dinâmica de efeitos.

1. Tendências Paralelas Condicionais por Cohort

- Para cada cohort, na ausência de tratamento, a trajetória de vendas teria evoluído paralelamente à dos never-treated. É o pressuposto mais importante.

2. Ausência de Choques Específicos ao Cohort

- Não pode existir, no mesmo período da campanha, outra intervenção que afete apenas as lojas tratadas. Choques específicos por cohort quebram a identificação.

3. Não Antecipação do Tratamento

- As lojas não podem ajustar comportamento **antes** do tratamento por expectativa da campanha.
- Violação gera efeitos falsos em períodos pré.

4. SUTVA / Ausência de Spillovers

- O tratamento em uma loja não deve afetar diretamente vendas de outra loja do grupo controle (never-treated).
- Se houver deslocamento de demanda, o contrafactual é corrompido.

5. Efeito Bem Definido ao Longo do Tempo

- O S&A permite heterogeneidade, mas exige que cada loja tenha **uma única data de entrada** no tratamento (não pode entrar, sair e reentrar).

6. Erros Independentes Condicionalmente aos Efeitos Fixos

- Após controlar por α_i (loja) e λ_t (tempo), os erros devem ser serialmente independentes dentro de cohort.

7. Identificação via Never-Treated

- Para cada período relativo ao tratamento, deve existir um número suficiente de lojas nunca tratadas para compor o controle válido.

```
In [16]: # =====
# Sun & Abraham
# =====

# Sun & Abraham sem covariadas e sem pesos
modelo_sa <- feols(vendas ~ sunab(cohort, periodo) |
  loja_id + periodo, # efeitos fixos
  data = dados_sa, # painel de dados
  cluster = c("loja_id", "periodo") # erros padrão clusterizados
)

# Sun & Abraham com covariadas e sem pesos
modelo_sa_cov <- feols( vendas ~ sunab(cohort, periodo) + renda_per_capita + per
  loja_id + periodo, # efeitos fixos
  data = dados_sa, # painel de dados
  cluster = c("loja_id", "periodo") # erros padrão clusterizados
)

# Sun & Abraham com covariadas x períodos e sem pesos
modelo_sa_cov_int <- feols( vendas ~ sunab(cohort, periodo) + renda_per_capita*p
  loja_id + periodo, # efeitos fixos
  data = dados_sa, # painel de dados
  cluster = c("loja_id", "periodo") # erros padrão clusterizados
)
```

```
# Sun & Abraham com pesos
modelo_sa_weighted <- feols(vendas ~ sunab(cohort, periodo) |
  loja_id + periodo, # efeitos fixos
  data = dados_sa, # painel de dados
  weights = ~peso, # pesos do Entropy Balancing
  cluster = c("loja_id", "periodo") # erros padrão clusterizados
)
```

Variance contained negative values in the diagonal and was 'fixed' (a la Cameron, Gelbach & Miller 2011).

The variables 'renda_per_capita', 'penetracao_internet' and 'n_concorrentes' have been removed because of collinearity (see \$collin.var).

Variance contained negative values in the diagonal and was 'fixed' (a la Cameron, Gelbach & Miller 2011).

The variables 'renda_per_capita', 'periodo', 'penetracao_internet' and 'n_concorrentes' have been removed because of collinearity (see \$collin.var).

Variance contained negative values in the diagonal and was 'fixed' (a la Cameron, Gelbach & Miller 2011).

Variance contained negative values in the diagonal and was 'fixed' (a la Cameron, Gelbach & Miller 2011).

Resultados ATT Agregado

```
In [17]: # Resultados S&A (ATT agregado)
etable(modelo_sa, modelo_sa_cov, modelo_sa_cov_int, modelo_sa_weighted,
  signif.code = c(`***` = 0.01, `**` = 0.05, `*` = 0.1),
  digits = 3,
  headers = c("TWFE ", "TWFE + Cov", "TWFE + Cov*Periodo", "TWFE + Cov + Pe
  agg = "ATT",
  title = "Impacto da campanha nas vendas - Modelos S&A")
```

```

Out[17]:

```

	modelo_sa	modelo_sa_cov	modelo_sa_weighted
Periodo TWFE + Cov + Pesos	TWFE	TWFE + Cov	TWFE + Cov*
Dependent Var.: vendas	vendas	vendas	vendas
ATT	6,667.6*** (127.3)	6,667.6*** (127.3)	6,276.6*** (57.2)
renda_per_capita x periodo			0.122*** (0.025)
periodo x penetracao_internet			1,017.7*** (44.4)
periodo x n_concorrentes			-0.981 (5.15)
Fixed-Effects:	-----	-----	-----
loja_id	Yes	Yes	Yes
periodo	Yes	Yes	Yes
S.E.: Clustered & peri. by: loja. & peri.	by: loja. & peri.	by: loja. & peri.	by: loja. & peri.
Observations	6,000	6,000	6,000
R2	0.96575	0.96575	0.96561
Within R2	0.33928	0.33928	0.28339
Signif. codes: 0 '***' 0.01 '**' 0.05 '*' 0.1 '.' 1			

Resultados ATT Coortes

```

In [18]: # Resultados S&A (ATT Cohort)
etabale(modelo_sa, modelo_sa_cov, modelo_sa_cov_int, modelo_sa_weighted,
        signif.code = c('***' = 0.01, '**' = 0.05, '*' = 0.1),
        digits = 3,
        headers = c("TWFE ", "TWFE + Cov", "TWFE + Cov*Periodo", "TWFE + Cov + Pe",
        agg = "cohort",
        title = "Impacto da campanha nas vendas - Modelos S&A")

```

```

Out[18]:

```

	modelo_sa	modelo_sa_cov	modelo_sa_weighted
cov_int			
Periodo	TWFE	TWFE + Cov	TWFE + Cov*
Dependent Var.:	vendas	vendas	vendas
cohort = 13	6,667.6*** (127.3)	6,667.6*** (127.3)	6,276.6*** (57.2)
renda_per_capita x periodo			0.122*** (0.025)
periodo x penetracao_internet			1,017.7*** (44.4)
periodo x n_concorrentes			-0.981 (5.15)
Fixed-Effects:	-----	-----	-----
loja_id	Yes	Yes	Yes
periodo	Yes	Yes	Yes
S.E.: Clustered & peri. by: loja. & peri.			
Observations	6,000	6,000	6,000
R2	0.96575	0.96575	0.96561
Within R2	0.33928	0.33928	0.28339
Signif. codes: 0 '***' 0.01 '**' 0.05 '*' 0.1 '.' 1			

Gráfico Event Study


Nota O TWFE também permite rodar o Event Study

```

In [19]: # Event study com Legenda
ipplot(
  list(
    "S&A Simples" = modelo_sa,
    "S&A + Covariáveis" = modelo_sa_cov,
    "S&A + Covariáveis*periodos" = modelo_sa_cov_int,
    "S&A + Pesos" = modelo_sa_weighted),
  ref = "all",
  main = "Event Study: Sun & Abraham",
  xlab = "Períodos Relativos ao Tratamento",
  ylab = "Efeito Estimado (R$)"
)

legend("bottomright",
  col = c(1, 2, 3, 4),
  pch = c(20, 17, 15, 3),
  legend = c("S&A Simples",
    "S&A + Covariáveis",
    "S&A + Covariáveis*periodos",
    "S&A + Pesos"))

```



Análise dos Resultados: DiD Sun & Abraham

Efeitos Estimados (ATT)

Modelo	ATT	SE	Viés	Erro Relativo
S&A Simples	R\$ 6.667,60	288.0	+R\$ 655	+10,9%
S&A + Covariáveis	R\$ 6.667,60	288.0	+R\$ 655	+10,9%
S&A + Cov × Período	R\$ 6.276,60	261.2	+R\$ 264	+4,4%
S&A + Pesos	R\$ 6.351,80	301.5	+R\$ 340	+5,6%
Efeito Verdadeiro	R\$ 6.012,28	—	0	0%

1. Covariáveis fixas não fazem diferença

Assim como no TWFE, adicionar covariáveis **sem interação com o tempo** não muda nada:

- **S&A Simples = S&A + Covariáveis = R\$ 6.667,60**

Por quê? As covariáveis (renda, internet, concorrentes) são **fixas no tempo** e os efeitos fixos de loja já capturam toda essa variação entre unidades. Resultado: o modelo detecta colinearidade e remove essas variáveis; por isso, o ATT permanece idêntico.

2. Modelo S&A + Covariáveis × Período: capturando tendências diferentes

Quando permitimos que as covariáveis mudem de efeito ao longo do tempo (interações com `periodo`), o resultado melhora claramente:

- **ATT = R\$ 6.276,60**, com viés de **apenas +4,4%**
- Erro-padrão cai para 261,2 (mais precisão)

Os coeficientes:

- `renda_per_capita × periodo` : 0,122*** — sugere que lojas em áreas mais ricas vão crescendo mais ao longo do tempo.
- `periodo × penetracao_internet` : 1.017,7*** — lojas com maior penetração digital acumulam crescimento adicional mês a mês.
- `periodo × n_concorrentes` : próximo de zero — concorrência não gera tendência diferenciada relevante no seu DGP simulado.

Intuição: Esse modelo permite que **tendências de vendas dependam das covariáveis**.

Ou seja, você deixa que renda e internet expliquem parte das trajetórias diferentes ao longo do tempo, reduzindo o viés do ATT de 10,9% para 4,4%.

3. Sun & Abraham vs TWFE (sem pesos)

Método	Efeito	Viés
TWFE Simples	R\$ 6.737	+12,1%
S&A Simples	R\$ 6.668	+10,9%
S&A + Cov×t	R\$ 6.277	+4,4%

Resumo:

- S&A simples já melhora um pouco o TWFE ao evitar comparações proibidas.
- S&A + Cov×Período melhora ainda mais, pois permite que parte da heterogeneidade dinâmica seja explicada por renda e internet.

Insights Importantes

1. Covariáveis fixas não ajudam; Covariáveis com tendência ajudam muito O ganho real vem quando você permite que as covariáveis expliquem **diferenças de trajetória**, não apenas níveis.

2. S&A é naturalmente mais robusto que o TWFE “puro” Mesmo sem pesos, ele reduz viés porque não faz comparações tratadas vs tratados em momentos diferentes.

3. TWFE + Pesos ainda é o campeão neste DGP Com tratamento único e efeito relativamente estável, TWFE + Entropy produz a estimativa mais próxima do verdadeiro efeito.

Conclusão

No seu exercício:

- **S&A Simples** melhora um pouco o TWFE,
- **S&A + Cov×Período** melhora bastante o S&A Simples,

Todos os métodos, porém, convergem para a mesma ordem de grandeza (R\$ 6.000), o que reforça a robustez da inferência.

Diferença-em-Diferenças - Callaway & Sant'Anna (2021)

Evolução dos Métodos DiD

Vimos até agora:

- **TWFE:** Assume efeito constante, pode ter viés com heterogeneidade
- **Sun & Abraham:** Permite efeito variável no tempo, usa interaction-weighting
- **Callaway & Sant'Anna** vai além e resolve múltiplos problemas simultaneamente.

O Problema que Callaway & Sant'Anna Resolve

Cenários complexos no mundo real:

1. **Adoção escalonada:** Lojas entram no tratamento em momentos diferentes
2. **Efeitos dinâmicos:** O impacto evolui ao longo do tempo (aumenta/diminui)
3. **Heterogeneidade entre grupos:** Efeito diferente para cada cohort
4. **Comparações problemáticas:** TWFE compara tratados entre si (viés!)

Exemplo (hipotético):

- Região Sul: campanha inicia em janeiro
- Região Sudeste: campanha inicia em março
- Região Nordeste: campanha inicia em junho
- Algumas lojas nunca recebem campanha

TWFE trataria isso incorretamente. Callaway & Sant'Anna trata corretamente.

Como Callaway & Sant'Anna Funciona

Estratégia em 3 passos:

1. Agrupa por cohort (g):

- Cohort 1: lojas que entraram no tratamento no mês 13

- Cohort 2: lojas que entraram no mês 15
- Never-treated: lojas que nunca foram tratadas

2. Calcula ATT(g,t) separadamente:

- Para cada cohort g, em cada período t
- Usa apenas **never-treated** ou **not-yet-treated** como controle
- Evita comparar tratados entre si

3. Agrega com ponderação apropriada:

- **ATT(g)**: Efeito médio para cohort g
- **ATT global**: Efeito médio agregando todos os cohorts
- **Event-study**: Efeito por "tempo desde tratamento"

Inovação chave:

$$ATT(g, t) = E[Y_t - Y_{\{g-1\}} \mid G=g] - E[Y_t - Y_{\{g-1\}} \mid G=never]$$

Compara mudanças do cohort g vs mudanças dos never-treated, período por período.

Vantagens do Callaway & Sant'Anna

Aspecto	TWFE	Sun & Abraham	Callaway & Sant'Anna
Heterogeneidade temporal	Não	Sim	Sim
Heterogeneidade entre cohorts	Não	Parcial	Sim
Staggered adoption	Viesado	Sim	Sim
Flexibilidade de controles	Limitada	Limitada	Never/not-yet
Inferência robusta	Bootstrap manual	Padrão	Multiplier bootstrap
Agregações flexíveis	Uma só	ATT	ATT, group-time, event-study
Testes de pré-tendências	Manual	Manual	Integrado

Tipos de Agregação

Callaway & Sant'Anna permite múltiplas formas de agregar resultados:

1. ATT Global (overall):

- Efeito médio para todas as unidades tratadas em todos os períodos pós

2. ATT por Grupo (group):

- Efeito médio para cada cohort separadamente
- Útil se efeito varia entre grupos

3. Event Study (dynamic):

- Efeito por "evento relativo" (t-g)
- Mostra evolução: -3, -2, -1, 0, +1, +2...

4. ATT por Período (calendar):

- Efeito médio em cada período de calendário
- Útil para entender dinâmica temporal

Quando Usar Callaway & Sant'Anna?

- **Adoção escalonada** (tratamento em momentos diferentes)
- **Suspeita de heterogeneidade** de efeitos entre grupos
- **Quer análise de robustez completa** (pré-tendências, placebo)
- **Precisa de event-study confiável** com ICs apropriados
- **Incerteza sobre qual controle usar** (never vs not-yet)

Outras opções são OK quando:

- Tratamento único e simultâneo (nosso caso) - TWFE/S&A suficientes
- Efeito homogêneo esperado - TWFE simples
- Foco apenas em ATT médio - Métodos mais simples

Nossa Situação

Cenário atual:

- Tratamento único no mês 13
- Todas as lojas tratadas simultaneamente
- Grupo never-treated disponível

O que Callaway & Sant'Anna nos dará:

1. **ATT robusto:** Com inferência apropriada (multiplier bootstrap)
2. **Event study:** Evolução do efeito mês a mês pós-campanha
3. **Teste de pré-tendências:** Valida suposição de tendências paralelas
4. **Comparação:** Podemos escolher never-treated vs not-yet-treated
5. **Propensity score automático** O package did já implemente o PSW nativamente

DID Callaway & Sant'Anna (2021)

```
In [20]: # =====  
# Callaway & Sant'Anna (2021)  
# =====  
  
# Preparar dados no formato esperado  
dados_cs <- dados %>%  
  mutate(  
    # G = período em que a unidade foi tratada (0 se nunca tratada)  
    G = ifelse(tratamento == 1, intervencao, 0)  
  )
```

```

dados_cs <- dados_cs %>%
  group_by(loja_id) %>%
  mutate(
    renda_trend = renda_per_capita * (periodo - min(periodo)),
    internet_trend = penetracao_internet * (periodo - min(periodo)),
    concorrentes_trend = n_concorrentes * (periodo - min(periodo))
  ) %>%
  ungroup()

# =====
# MODELO 1: C&S REG (SEM COVARIÁVEIS)
# =====

resultado_reg_cs <- att_gt(
  yname = "vendas", # variável de resultado
  tname = "periodo", # variável de tempo
  idname = "loja_id", # id da unidade
  gname = "G", # período de tratamento
  data = dados_cs, # painel de dados
  control_group = "nevertreated", # grupo controle nunca tr
  est_method = "reg" # outcome regression simples
)

# =====
# MODELO 2: C&S REG (COM COVARIÁVEIS)
# =====

resultado_reg_cs_cov <- att_gt(
  yname = "vendas", # variável de resultado
  tname = "periodo", # variável de tempo
  idname = "loja_id", # id da unidade
  panel = FALSE, # vamos colocar falso para obter a
  xformula = ~ renda_per_capita + penetracao_interne
  gname = "G", # período de tratamento
  data = dados_cs, # painel de dados
  control_group = "nevertreated", # grupo controle
  est_method = "reg" # outcome regression simples
)

# =====
# MODELO 3: C&S IPW (COM COVARIÁVEIS)
# =====

resultado_ipw_cs_cov <- att_gt(
  yname = "vendas",
  tname = "periodo",
  idname = "loja_id",
  gname = "G",
  xformula = ~ renda_per_capita + penetracao_internet +
  data = dados_cs,
  control_group = "nevertreated",
  est_method = "ipw" # inverse probability weighting
)

# =====
# MODELO 4: C&S DR (COM COVARIÁVEIS)
# =====

```

```

resultado_cs_dr_cov <- att_gt(
  yname = "vendas",
  tname = "periodo",
  idname = "loja_id",
  gname = "G",
  xformula = ~ renda_per_capita + penetracao_internet
  data = dados_cs,
  control_group = "nevertreated",
  est_method = "dr" # doubly robust
)

# =====
# MODELO 5: C&S DR (COM COVARIÁVEIS X PERIODO)
# =====

resultado_cs_dr_cov_int <- att_gt(
  yname = "vendas",
  tname = "periodo",
  idname = "loja_id",
  gname = "G",
  xformula = ~ renda_trend + internet_trend + con
  data = dados_cs,
  control_group = "nevertreated",
  est_method = "dr" # doubly robust
)

```

Warning message:

In compute.att_gt(dp) :

Not enough control units for group 13 in time period 2 to run specified regression

Resultado do Teste de Tendências paralelas Pré-tratamento

```

In [21]: # =====
# Resultados C&S (REG COM COVARIÁVEIS)
# =====
resultado_reg_cs_cov

```

```
Out[21]: Call:
att_gt(yname = "vendas", tname = "periodo", idname = "loja_id",
       gname = "G", xformula = ~renda_per_capita + penetracao_internet +
       n_concorrentes, data = dados_cs, panel = FALSE, control_group = "nevert
reated",
       est_method = "reg")
```

Reference: Callaway, Brantly and Pedro H.C. Sant'Anna. "Difference-in-Differences with Multiple Time Periods." Journal of Econometrics, Vol. 225, No. 2, pp. 200-230, 2021. <<https://doi.org/10.1016/j.jeconom.2020.12.001>>, <<https://arxiv.org/abs/1803.09015>>

Group-Time Average Treatment Effects:

Group	Time	ATT(g,t)	Std. Error	[95% Simult. Conf. Band]
13	2	450.2562	1053.989	-2695.852 3596.364
13	3	257.8861	1120.396	-3086.442 3602.214
13	4	-9.2598	1151.478	-3446.369 3427.849
13	5	248.8666	1078.199	-2969.506 3467.239
13	6	-12.8821	1130.490	-3387.342 3361.578
13	7	-461.9958	1177.356	-3976.348 3052.357
13	8	727.2964	1143.775	-2686.817 4141.410
13	9	-529.8091	1060.284	-3694.705 2635.087
13	10	-338.5017	1211.950	-3956.117 3279.113
13	11	593.7423	1249.978	-3137.383 4324.868
13	12	-543.9581	1191.468	-4100.434 3012.518
13	13	5993.9420	1273.356	2193.035 9794.849 *
13	14	6638.4502	1253.452	2896.956 10379.944 *
13	15	6644.0943	1226.100	2984.243 10303.945 *
13	16	5915.4362	1276.131	2106.244 9724.629 *
13	17	6391.5729	1250.996	2657.409 10125.737 *
13	18	6610.4960	1199.446	3030.207 10190.785 *
13	19	6573.8815	1363.458	2504.024 10643.739 *
13	20	6050.9880	1242.013	2343.637 9758.339 *
13	21	6630.3649	1306.687	2729.965 10530.764 *
13	22	6745.1401	1383.737	2614.751 10875.529 *
13	23	6221.5551	1332.891	2242.937 10200.173 *
13	24	6120.8180	1307.095	2219.200 10022.436 *

Signif. codes: `*' confidence band does not cover 0

P-value for pre-test of parallel trends assumption: 0.99881

Control Group: Never Treated, Anticipation Periods: 0

Estimation Method: Outcome Regression

```
In [22]: # =====
# Calcular ATT simples para cada modelo (com tratamento de erros)
# =====

calcular_att_seguro <- function(resultado, nome) {
  tryCatch({
    att <- aggte(resultado, type = "simple", na.rm = TRUE)
    list(
      efeito = att$overall.att,
      se = att$overall.se,
      p_valor = 2 * pnorm(-abs(att$overall.att / att$overall.se)),
      sucesso = TRUE
    )
  }, error = function(e) {
    message(paste("Erro em", nome, ":", e$message))
    list(efeito = NA, se = NA, p_valor = NA, sucesso = FALSE)
  })
}
```

```

    })
  }

# =====
# Aplicar para cada modelo
# =====

resultados <- list(
  reg_cs      = calcular_att_seguro(resultado_reg_cs,      "Regressão CS Sim",
  reg_cs_cov  = calcular_att_seguro(resultado_reg_cs_cov, "Regressão CS + C",
  ipw_cs_cov  = calcular_att_seguro(resultado_ipw_cs_cov, "IPW + Cov"),
  cs_dr_cov   = calcular_att_seguro(resultado_cs_dr_cov,  "Doubly Robust"),
  cs_dr_cov_int = calcular_att_seguro(resultado_cs_dr_cov_int, "DR + Cov×Período",
)

# =====
# Tabela comparativa
# =====

tabela_cs <- data.frame(
  Metodo = c(
    "Regressão CS Simples",
    "Regressão CS + Covariáveis",
    "IPW + Covariáveis",
    "Doubly Robust",
    "Doubly Robust + Cov×Período"
  ),
  ATT = sapply(resultados, function(x) x$efeito),
  SE = sapply(resultados, function(x) x$se),
  P_valor = sapply(resultados, function(x) x$p_valor)
)

tabela_cs$Vies <- tabela_cs$ATT - 6012
tabela_cs$Erro_Pct <- round((tabela_cs$Vies / 6012) * 100, 1)

# Formatar números
tabela_cs$ATT <- round(tabela_cs$ATT, 2)
tabela_cs$SE <- round(tabela_cs$SE, 2)
tabela_cs$P_valor <- round(tabela_cs$P_valor, 4)
tabela_cs$Vies <- round(tabela_cs$Vies, 2)

tabela_cs

# =====
# Diagnóstico: verificar estrutura dos objetos
# =====

cat("\n=== Diagnóstico dos objetos resultado ===\n")
cat("Classe resultado_reg_cs:", class(resultado_reg_cs), "\n")
cat("Nomes em resultado_reg_cs:", names(resultado_reg_cs)[1:5], "... \n")

=== Diagnóstico dos objetos resultado ===
Classe resultado_reg_cs: MP
Nomes em resultado_reg_cs: group t att V_analytical se ...

```

Resultados de outras agregações

```

In [23]: # =====
# Agregações Alternativas

```

```
# =====

suppressWarnings({
  att_simple <- aggte(resultado_cs_dr_cov, type = "simple", na.rm = TRUE)
  att_dinamico <- aggte(resultado_cs_dr_cov, type = "dynamic", na.rm = TRUE)
  att_group <- aggte(resultado_cs_dr_cov, type = "group", na.rm = TRUE)
  att_calendar <- aggte(resultado_cs_dr_cov, type = "calendar", na.rm = TRUE)
})

# =====
# Extrair ATTs
# =====

efeito_simple <- att_simple$overall.att
efeito_dinamico <- att_dinamico$overall.att
efeito_group <- att_group$overall.att
efeito_calendar <- att_calendar$overall.att

efeito_verdadeiro <- 6012

# =====
# Tabela Comparativa por Tipo de Agregação
# =====

tabela_agregacoes <- data.frame(
  Agregacao = c(
    "Simple (ATT médio geral)",
    "Dynamic (Event study)",
    "Group (Por coorte)",
    "Calendar (Por período)"
  ),
  ATT = c(efeito_simple, efeito_dinamico, efeito_group, efeito_calendar),
  Vies = c(
    efeito_simple - efeito_verdadeiro,
    efeito_dinamico - efeito_verdadeiro,
    efeito_group - efeito_verdadeiro,
    efeito_calendar - efeito_verdadeiro
  )
)

tabela_agregacoes$Erro_Pct <- round((tabela_agregacoes$Vies / efeito_verdadeiro)
tabela_agregacoes$ATT <- round(tabela_agregacoes$ATT, 2)
tabela_agregacoes$Vies <- round(tabela_agregacoes$Vies, 2)

cat("\n=== AGREGAÇÕES: CALLAWAY & SANT'ANNA (DOUBLY ROBUST) ===\n\n")
print(tabela_agregacoes, row.names = FALSE)
cat("\nEfeito Verdadeiro: R$", efeito_verdadeiro, "\n")
```

=== AGREGAÇÕES: CALLAWAY & SANT'ANNA (DOUBLY ROBUST) ===

	Agregacao	ATT	Vies	Erro_Pct
	Simple (ATT médio geral)	6393.97	381.97	6.4
	Dynamic (Event study)	6393.97	381.97	6.4
	Group (Por coorte)	6393.97	381.97	6.4
	Calendar (Por período)	6393.97	381.97	6.4

Efeito Verdadeiro: R\$ 6012

Análise dos Resultados: Callaway & Sant'Anna (2021)

Teste de Tendências Paralelas

Resultado do teste formal:

- **P-valor:** 0.999
- **Conclusão:** ✓ **Tendências paralelas válidas**
- **Interpretação:** Não há evidência estatística de diferenças sistemáticas no período pré-tratamento

O que isso significa:

- Tratados e controles seguiam trajetórias paralelas antes da intervenção
- A suposição fundamental do método DiD é satisfeita
- Os efeitos estimados podem ser interpretados causalmente
- A estratégia de identificação é apropriada para este cenário

Implicações para os resultados:

- Estimativas ATT são **confiáveis** sob a identificação DiD
- Diferenças observadas no pós-tratamento podem ser atribuídas à campanha
- Viés remanescente (~6%) não vem de violação de tendências paralelas
- Possíveis fontes do viés: covariadas não observadas ou má especificação

Efeitos Estimados por Método

Método	ATT	Erro Padrão	Viés	Erro Relativo
Regressão Simples	R\$ 6.668	285.02	+R\$ 656	+10.9%
Regressão + Covariáveis	R\$ 6.378	273.81	+R\$ 366	+6.1%
IPW + Covariáveis	R\$ 6.406	271.81	+R\$ 394	+6.6%
Doubly Robust + Covariáveis	R\$ 6.394	259.55	+R\$ 382	+6.4%
Doubly Robust + Trends	R\$ 6.394	265.41	+R\$ 382	+6.4%
Efeito Verdadeiro	R\$ 6.012	-	0	0%

Métodos de Estimação

1. Regressão Simples (REG):

- **O que faz:** Estima $ATT(g,t)$ via regressão de outcome nos controles
- **Vantagem:** Simples e direto
- **Limitação:** Sensível a má especificação do modelo de outcome
- **Resultado:** R\$ 6.668 - maior viés entre todos os métodos

2. Regressão + Covariáveis (REG + Cov):

xformula = ~ renda_per_capita + penetracao_internet + n_concorrentes

- **O que faz:** Controla por características observáveis das lojas
- **Covariadas incluídas:** Renda per capita, penetração de internet, \ número de concorrentes
- **Melhoria:** Viés reduz de 10.9% para 6.1%
- **Interpretação:** Covariáveis capturam parte das diferenças entre \ tratados e controles

3. Inverse Probability Weighting (IPW + Cov):

- **O que faz:** Estima propensity score e repondera observações
- **Vantagem:** Não assume forma funcional para outcome
- **Limitação:** Sensível a má especificação do propensity score
- **Resultado:** R\$ 6.406 (viés de 6.6%) - ligeiramente pior que REG + Cov
- **Nota:** Erro padrão levemente menor (271.81 vs 273.81)

4. Doubly Robust (DR + Cov):

- **O que faz:** Combina regressão de outcome E propensity score
- **Grande vantagem:** Consistente se **pelo menos um** dos modelos \ estiver correto
- **Resultado:** R\$ 6.394 (viés de 6.4%)
- **Melhor erro padrão:** 259.55 - o mais baixo de todos os métodos
- **Por que usar:** Proteção dupla contra má especificação

5. Doubly Robust + Trends:

xformula = ~ renda_trend + internet_trend + concorrentes_trend

- **O que faz:** Inclui interações das covariadas com tempo
- **Objetivo:** Capturar tendências heterogêneas específicas a cada loja
- **Criação das trends:** $\text{renda_trend} = \text{renda_per_capita} \times (t - t_0)$
- **Resultado:** R\$ 6.394 (idêntico ao DR sem trends)
- **Interpretação:** Tendências heterogêneas não eram fonte importante \ de viés neste caso

Tipos de Agregação

Callaway & Sant'Anna permite diferentes formas de agregar os ATT(g,t):

Agregação	ATT	Descrição
Simple (ATT médio geral)	R\$ 6.394	Média ponderada de todos ATT(g,t)
Dynamic (Event study)	R\$ 6.394	Efeito por tempo relativo ao tratamento
Group (Por coorte)	R\$ 6.394	Efeito médio para cada coorte separadamente
Calendar (Por período)	R\$ 6.394	Efeito médio em cada período de calendário

Por que todos os valores são iguais?

- Nosso cenário tem **uma única coorte** (todas tratadas no período 13)

- Não há heterogeneidade entre grupos
- As diferentes agregações colapsam para o mesmo valor
- Em cenários com **adoção escalonada**, esses valores seriam diferentes

Comparação dos Métodos

Performance dos estimadores:

Ranking por viés (menor para maior):

1. REG + Covariáveis:	6.1%	
2. Doubly Robust:	6.4%	← RECOMENDADO
3. IPW:	6.6%	
4. REG Simples:	10.9%	

Performance por erro padrão:

Ranking por precisão (menor SE):

1. Doubly Robust:	259.55	← MAIS PRECISO
2. IPW:	271.81	
3. REG + Cov:	273.81	
4. REG Simples:	285.02	

Análise das Covariáveis

Impacto de adicionar covariáveis:

- Sem covariáveis: viés de +10.9%
- Com covariáveis: viés de +6.1% a +6.6%
- **Redução do viés:** ~40-45%

Covariáveis incluídas:

- **Renda per capita:** Captura poder de compra local
- **Penetração de internet:** Proxy para maturidade digital
- **Número de concorrentes:** Contexto competitivo

Por que covariáveis ajudam:

- Lojas tratadas têm características diferentes dos controles
- Covariáveis tornam grupos mais comparáveis
- Reduzem viés de seleção

Interações com Tempo (Trends)

Modelo com trends:

$\text{renda_trend} = \text{renda_per_capita} \times (\text{periodo} - \text{periodo_inicial})$

O que captura:

- Tendências específicas relacionadas às características das lojas
- Exemplo: lojas com maior renda crescem mais rápido ao longo do tempo

Resultado observado:

- DR + Trends = DR sem trends (ambos R\$ 6.394)
- **Interpretação:** Tendências heterogêneas não eram problema neste caso
- Balanceamento via propensity score já resolveu diferenças de trajetória

Recomendação de Método

Método recomendado: Doubly Robust + Covariáveis

Razões:

1. **Menor erro padrão** (259.55) - maior precisão
2. **Proteção dupla** contra má especificação
3. **Viés moderado** (6.4%) - segundo melhor desempenho
4. **Robusto** a diferentes especificações

Quando usar cada método:

- **REG + Cov:** Se confiante na forma funcional do outcome
- **IPW:** Se preocupado com especificação de outcome
- **DR:** Quando quer robustez máxima (recomendado)
- **DR + Trends:** Suspeita de tendências heterogêneas

Conclusão

Resultados principais:

- Efeito estimado: R\$ 6.394 (Doubly Robust)
- Todos os efeitos são significativos ($p < 0.001$)
- Covariáveis reduzem viés em ~40%
- Doubly Robust oferece melhor precisão

Limitações observadas:

- Viés remanescente de ~6% sugere:
 - Covariáveis observadas não capturam todas as diferenças
 - Possível violação residual de tendências paralelas
 - Necessidade de métodos adicionais (ex: Entropy Balancing)

**Diferença-em-diferenças Two-Stage -
Gardner (2022)**

Evolução dos Métodos DiD

Vimos até agora:

- **TWFE:** Assume efeito constante, viés com heterogeneidade temporal
- **Sun & Abraham:** Interaction-weighting, corrige viés de heterogeneidade
- **Callaway & Sant'Anna:** Group-time ATTs, agregações flexíveis
- **Gardner (2022):** Solução computacionalmente eficiente e teoricamente robusta

0 Problema que Gardner Resolve

Desafio central:

TWFE em designs com adoção escalonada sofre de **viés de ponderação negativa**:

- Compara unidades já tratadas com as recém-tratadas
- Atribui pesos negativos a alguns ATT(g,t)
- Estimador viesado mesmo com tendências paralelas válidas

Exemplo do problema:

- Grupo 1 tratado em $t=10$, efeito cresce ao longo do tempo
- Grupo 2 tratado em $t=15$
- TWFE usa Grupo 1 ($t \geq 15$) como controle para Grupo 2
- Resultado: subestima efeito real

Outros problemas resolvidos:

1. **Heterogeneidade de efeitos:** Efeitos variam por grupo e tempo
2. **Eficiência computacional:** Rápido mesmo com muitas unidades/períodos
3. **Covariadas variantes no tempo:** Fácil incorporação

Como Gardner Funciona

Estratégia em 2 estágios:

Estágio 1: Estimação de Efeitos Fixos

- Estima efeitos fixos de unidade (μ_i) e tempo (λ_t) usando **apenas dados não tratados**
- Garante que efeitos fixos não sejam contaminados pelo tratamento
- Remove variação sistemática não relacionada ao tratamento

$$Y_{it} = \mu_i + \lambda_t + \varepsilon_{it} \quad [\text{apenas para } D_{it} = 0]$$

Estágio 2: Regressão do Resíduo

- Calcula resíduos: $\tilde{Y}_{it} = Y_{it} - \hat{\mu}_i - \hat{\lambda}_t$
- Regride resíduos no indicador de tratamento
- Estimador final: ATT livre de viés de heterogeneidade

$$\tilde{Y}_{it} = \tau \cdot D_{it} + v_{it}$$

Inovação chave:

Ao usar apenas controles no Estágio 1, Gardner elimina o problema de "bad controls" que afeta TWFE tradicional.

Vantagens do Gardner

Aspecto	TWFE	Callaway & Sant'Anna	Gardner (2S-DiD)
Adoção escalonada	Viesado	✓ Correto	✓ Correto
Heterogeneidade temporal	Viesado	✓ Permite	✓ Permite
Velocidade computacional	Rápido	Lento (bootstrap)	✓ Muito rápido
Covariadas variantes no tempo	Sim	Limitado	✓ Sim
Interpretação	ATT	ATT(g,t) → ATT	ATT
Implementação	Simples	Complexa	✓ Simples
Agregações flexíveis	Não	Sim	Limitado

Principais vantagens:

1. **Eficiência:** Escalável para grandes datasets (milhões de observações)
2. **Simplicidade:** Dois passos claros, fácil de implementar
3. **Robustez:** Não sofre de vies de ponderação negativa
4. **Flexibilidade:** Aceita covariadas variantes no tempo naturalmente

Quando Usar Gardner?

Use Gardner quando:

- **Adoção escalonada** com muitas unidades/períodos
- **Performance computacional** é importante (big data)
- **Covariadas variantes no tempo** são relevantes
- **Interpretação simples** de ATT agregado é suficiente
- **Quer evitar bootstrap** (C&S pode ser lento)

Use Callaway & Sant'Anna quando:

- Precisa de **agregações flexíveis** (group, calendar, event-study)
- Quer **testar pré-tendências** formalmente (integrado)
- Necessita **ATT(g,t) individuais** para análise detalhada
- Suspeita de **heterogeneidade complexa** entre coortes

Use TWFE quando:

- Tratamento único e simultâneo
- Efeito homogêneo esperado
- Dataset pequeno, simplicidade máxima

Nossa Situação

Cenário atual:

- Tratamento único no período 13
- Todas as lojas tratadas simultaneamente
- Sem adoção escalonada (1 coorte apenas)

O que Gardner nos dará:

1. **ATT robusto:** Livre de vies de ponderação (embora nosso caso não tenha esse problema)
2. **Estimação rápida:** Mesmo com 6.000 observações
3. **Comparação metodológica:** Validar resultados de C&S e TWFE
4. **Flexibilidade:** Fácil adicionar covariadas variantes no tempo se necessário

Pressupostos Necessários para Validade do Two-Stage DiD (Gardner)

Os pressupostos são semelhantes ao DiD tradicional, mas com ênfase na **separação entre estágios** e na qualidade da estimação de efeitos fixos.

1. Tendências Paralelas Condicionais

Na ausência de tratamento, unidades tratadas e controles teriam evoluído paralelamente **após remoção dos efeitos fixos**.

Formulação:

$$E[Y_{0it} - \mu_i - \lambda_t \mid D_{it}=1] = E[Y_{0it} - \mu_i - \lambda_t \mid D_{it}=0]$$

Crítico: Gardner assume que efeitos fixos capturam **toda** heterogeneidade sistemática entre grupos.

2. Efeitos Fixos Bem Especificados no Primeiro Estágio

Os efeitos fixos de unidade (μ_i) e tempo (λ_t) devem ser suficientes para remover diferenças sistemáticas entre tratados e controles.

Implicação prática:

- Se houver tendências específicas por grupo não capturadas por $\mu_i + \lambda_t$, o método falha
- Pode ser necessário adicionar interações ou tendências lineares específicas

3. Dados Não Tratados Suficientes no Primeiro Estágio

Deve haver observações **não tratadas** suficientes (unidades×períodos) para estimar efeitos fixos com precisão.

Problema: Com adoção escalonada completa (todos eventualmente tratados), pode haver poucos controles no Estágio 1.

4. Não Antecipação do Tratamento

Unidades não ajustam comportamento **antes** do tratamento real por expectativa da intervenção.

Violação: Gera efeitos pré-tratamento espúrios que contaminam estimação de efeitos fixos.

5. SUTVA (Stable Unit Treatment Value Assumption)

O tratamento de uma unidade não afeta o outcome de outras unidades.

Exemplos de violação:

- Spillovers geográficos (loja tratada afeta vendas de controles próximos)
- Efeitos de equilíbrio geral (preços, competição)
- Realocação de demanda entre unidades

6. Tratamento Irreversível (Staggered Adoption)

Uma vez tratada, a unidade permanece tratada ($D_{it} \leq D_{it+1}$).

Nota: Gardner não foi projetado para tratamentos intermitentes (on-off-on).

7. Erros Independentes Condicionalmente aos Efeitos Fixos

Após controlar por μ_i e λ_t , os erros são independentes:

$$E[\varepsilon_{it} \mid \mu_i, \lambda_t, D_{it}] = 0$$

Implicação: Permite inferência correta com clustering apropriado.

8. Separação Limpa entre Controles e Tratados no Estágio 1

O Estágio 1 usa **apenas observações não tratadas** ($D_{it} = 0$).

Crítico: Se houver erro na definição de D_{it} , efeitos fixos serão contaminados e o Estágio 2 viesado.

9. Homogeneidade do ATT ou Agregação Válida

Gardner estima um **único ATT agregado**. Se efeitos forem muito heterogêneos entre grupos/tempo, pode mascarar padrões importantes.

Contraste com C&S: Callaway & Sant'Anna permite ATT(g,t) flexíveis; Gardner sacrifica isso por eficiência.

10. Ausência de Choques Específicos ao Grupo Tratado

Não pode haver eventos contemporâneos ao tratamento que afetem apenas tratados (ou apenas controles).

Exemplo de violação: Campanha de marketing coincide com mudança regulatória que afeta apenas lojas tratadas.

```
In [24]: # =====
# Preparar dados para Gardner
# =====

# Gardner usa apenas indicador de tratamento (não precisa de cohort)
dados_gardner <- dados %>%
  mutate(treated = tratamento * pos) %>%
  left_join(lojas_weighted %>% select(loja_id, peso), by = "loja_id")

# =====
# MODELO 1: Gardner sem covariadas e sem pesos
# =====

modelo_gardner <- did2s(
  data = dados_gardner,
  yname = "vendas",
  first_stage = ~ 0 | loja_id + periodo,
  second_stage = ~ treated,
  treatment = "treated",
  cluster_var = "loja_id"
)

# =====
# MODELO 2: Gardner com covariadas e sem pesos
# =====

modelo_gardner_cov <- did2s(
  data = dados_gardner,
  yname = "vendas",
  first_stage = ~ 0 | loja_id + periodo,
  second_stage = ~ treated + renda_per_capita + penetr
  treatment = "treated",
  cluster_var = "loja_id"
)

# =====
# MODELO 3: Gardner com covariadas x período
# =====

modelo_gardner_cov_int <- did2s(
  data = dados_gardner,
  yname = "vendas",
  first_stage = ~ 0 | loja_id + periodo,
  second_stage = ~ treated + renda_per_capita*peri
  treatment = "treated",
  cluster_var = "loja_id"
)

# =====
# MODELO 4: Gardner com pesos
# =====
```

```

modelo_gardner_weighted <- did2s(
  data = dados_gardner,
  yname = "vendas",
  first_stage = ~ 0 | loja_id + periodo,
  second_stage = ~ treated,
  treatment = "treated",
  weights = "peso", # Nome da coluna como string
  cluster_var = "loja_id",
)

# =====
# Resultados
# =====
etable(modelo_gardner, modelo_gardner_cov, modelo_gardner_cov_int, modelo_gardner_weighted,
  signif.code = c(`***` = 0.01, `**` = 0.05, `*` = 0.1),
  digits = 3,
  headers = c("Gardner ", "Gardner + Cov", "Gardner + Cov*Periodo", "Gardner + Cov*Periodo*Peso"),
  title = "Impacto da campanha nas vendas - Modelos TWFE")

```

Running Two-stage Difference-in-Differences

- first stage formula `~ 0 | loja_id + periodo`
- second stage formula `~ treated`
- The indicator variable that denotes when treatment is on is `treated`
- Standard errors will be clustered by `loja_id`

Running Two-stage Difference-in-Differences

- first stage formula `~ 0 | loja_id + periodo`
- second stage formula `~ treated + renda_per_capita + penetracao_internet + n_concorrentes`
- The indicator variable that denotes when treatment is on is `treated`
- Standard errors will be clustered by `loja_id`

Running Two-stage Difference-in-Differences

- first stage formula `~ 0 | loja_id + periodo`
- second stage formula `~ treated + renda_per_capita * periodo + penetracao_internet * periodo + n_concorrentes * periodo`
- The indicator variable that denotes when treatment is on is `treated`
- Standard errors will be clustered by `loja_id`

Running Two-stage Difference-in-Differences

- first stage formula `~ 0 | loja_id + periodo`
- second stage formula `~ treated`
- The indicator variable that denotes when treatment is on is `treated`
- Standard errors will be clustered by `loja_id`

```

Out[24]:
ardner_c..      modelo_gardner_w..      modelo_gardner      modelo_gardner_cov      modelo_g
ov*Periodo      Gardner + Cov + Pesos      Gardner      Gardner + Cov      Gardner + C
Dependent Var.:      vendas      vendas      vendas
vendas      vendas

treated      6,737.3*** (279.4)      6,614.7*** (275.7)      6,181.0*
** (160.1)      5,888.7*** (291.3)
renda_per_capita      0.078 (0.064)      -0.200
** (0.096)
penetracao_internet      313.5 (296.3)      -39
7.2 (445.1)
n_concorrentes      -112.7*** (30.8)      190.4
*** (52.9)
periodo      -525.6
*** (31.9)
renda_per_capita x periodo      0.071*
** (0.009)
periodo x penetracao_internet      530.4
*** (46.8)
periodo x n_concorrentes      -12.8
*** (3.90)

-----
S.E. type      Custom      Custom
Custom      Custom
Observations      6,000      6,000
6,000      6,000
R2      0.61074      0.61414
0.69253      0.54723
Adj. R2      0.61074      0.61395
0.69217      0.54723
---
Signif. codes: 0 '***' 0.01 '**' 0.05 '*' 0.1 ' ' 1

```

Resultados: Gardner Two-Stage DiD

Resumo dos Modelos

Modelo	Efeito	Viés	Erro (%)
Gardner Simples	R\$ 6.737	+R\$ 725	+12.1%
Gardner + Cov	R\$ 6.615	+R\$ 603	+10.0%
Gardner + Cov×Per	R\$ 6.181	+R\$ 169	+2.8%
Gardner + Pesos	R\$ 5.889	-R\$ 123	-2.0%
Efeito Verdadeiro	R\$ 6.012	0	0%

Principais Conclusões

1. Gardner + Cov×Período é o MELHOR estimador

- Erro de apenas **2.8%** - praticamente acerta o efeito verdadeiro
- $R^2 = 69\%$ (vs 61% sem interações)

- Captura tendências heterogêneas entre grupos

2. Interações explicam diferenças de trajetória:

- **Renda × Período = +0.071***** → Lojas ricas crescem 71 reais/mês a mais por R\$ 1.000 de renda
- **Internet × Período = +530.4***** → Alta penetração acelera crescimento em R\$ 530/mês
- **Concorrentes × Período = -12.8***** → Cada concorrente reduz crescimento em R\$ 13/mês

3. Por que covariadas simples não funcionam:

- Gardner + Cov: erro de 10% (ainda alto)
- Covariadas **fixas** capturam níveis, mas não **trajetórias divergentes**
- Interações com tempo resolvem isso

4. Pesos (Entropy) funcionam bem:

- Erro de -2.0% (subestima levemente)
- Balanceia grupos, mas não captura tendências tão bem quanto interações

5. Gardner = TWFE neste caso:

- Com 1 coorte única, Gardner converge para TWFE
- Resultados idênticos: Gardner Simples = TWFE Simples (ambos R\$ 6.737)

Ranking Final

- | | | |
|---------------------------|--------|----------|
| 1. Gardner + Cov×Período: | +2.8% | ← MELHOR |
| 2. Gardner + Pesos: | -2.0% | |
| 3. Gardner + Cov: | +10.0% | |
| 4. Gardner Simples: | +12.1% | |

Recomendação: Use **Gardner + Cov×Período** quando suspeitar de tendências heterogêneas.

Diferença-em-Diferenças - De Chaisemartin & D'Haultfoeuille (2024)

O Problema que De Chaisemartin & D'Haultfoeuille (2024) Resolve

Enquanto Callaway & Sant'Anna foca em tratamentos binários (0/1) permanentes, **de Chaisemartin & D'Haultfoeuille (2020, 2024)** vai além e permite:

1. **Tratamentos reversíveis:** Loja entra e sai da campanha
2. **Doses variáveis:** Intensidade do tratamento muda ao longo do tempo
3. **Múltiplos tratamentos:** Diferentes tipos de intervenção
4. **Switching in/out:** Unidades podem alternar entre tratado/controle

Exemplo (hipotético):

- Mês 13: Loja recebe campanha (D=1)
- Mês 18: Campanha é pausada (D=0)
- Mês 20: Campanha retorna com intensidade dobrada (D=2)

TWFE, S&A e C&S não lidam bem com isso. DID_MULTIPLEGT_DYN sim.

O que o Método Faz

did_multiplegt (versão básica):

- Estima efeito médio instantâneo do tratamento
- Mostra os pesos que TWFE atribui a cada observação
- **Diagnóstico:** Identifica quando TWFE é problemático (pesos negativos)

did_multiplegt_dyn (versão dinâmica):

- Estima efeitos que evoluem ao longo do tempo desde o tratamento
- Permite até L períodos de defasagem (lags)
- Permite até F períodos de antecipação (leads/placebo)
- Testa pré-tendências automaticamente

Inovações Principais

1. Transparência sobre TWFE

O método calcula explicitamente:

$$\beta_{TWFE} = \sum w_{gt} \times ATT(g, t)$$

E mostra:

- Quantos pesos são negativos?
- Qual a proporção de pesos problemáticos?
- $ATT(g, t)$ com pesos negativos vs positivos são diferentes?

Diagnóstico automático: "TWFE é confiável nestes dados?"

2. Efeitos Dinâmicos Flexíveis

$$ATT_{\ell} = \text{Efeito } \ell \text{ períodos após começar o tratamento}$$

Permite perguntas como:

- Efeito imediato ($\ell=0$)?
- Efeito cresce ao longo do tempo ($\ell=1,2,3\dots$)?
- Quanto tempo até o efeito estabilizar?
- Há dissipação do efeito?

3. Placebo Tests Integrados

Testa períodos PRÉ-tratamento ($\ell < 0$):

- Se efeitos pré são diferentes de zero → violação de tendências paralelas
- Fornece evidência formal da validade da suposição

4. Tratamentos Complexos

Característica	TWFE	C&S	Gardner	did_multiplegt
Tratamento binário	Sim	Sim	Sim	Sim
Tratamento contínuo	Sim	Não	Sim	Sim
Reversível (on/off)	Problemático	Não	Não	Sim
Múltiplas doses	Não	Não	Não	Sim
Diagnóstico TWFE	Não	Não	Não	Sim
Velocidade	Rápido	Lento	Rápido	Lento
Covariáveis	Sim	Complexo	Simples	Limitado

Estrutura dos outputs

Outputs principais:

- `Effect_0` : Efeito imediato (primeiro período tratado)
- `Effect_1` : Efeito 1 período depois
- `Effect_ℓ` : Efeito ℓ períodos depois
- `Placebo_1` : "Efeito" 1 período antes (deve ser ≈ 0)
- `N_switchers_in` : Quantas unidades entraram no tratamento
- `N_switchers_out` : Quantas saíram do tratamento

Vantagens sobre Outros Métodos

vs TWFE:

- **Transparência:** Mostra quando TWFE falha (pesos negativos)
- **Robustez:** Funciona mesmo com heterogeneidade e switching
- **Diagnóstico:** Testa se TWFE é apropriado para seus dados

vs Gardner:

- **Switching reversível:** Gardner não lida com tratamentos on/off

- **Doses variáveis:** Gardner é binário; did_multplegt aceita doses
- **Diagnóstico explícito:** Mostra pesos negativos do TWFE
- **Desvantagem:** Mais lento computacionalmente

vs Callaway & Sant'Anna:

- **Flexibilidade:** Tratamentos reversíveis, doses variáveis
- **Diagnóstico TWFE:** C&S assume TWFE é ruim; did_multplegt testa
- **Efeitos dinâmicos:** Mais flexível (permite mais lags/leads)

vs Sun & Abraham:

- **Generalidade:** Não requer tratamento permanente
- **Pesos explícitos:** Mostra exatamente como TWFE pondera
- **Switching:** Lida com unidades que entram/saem do tratamento

Limitações

1. Computacionalmente intensivo:

- Bootstrap para inferência pode ser lento com muitos períodos/unidades
- did_multplegt_dyn especialmente com effects/placebo grandes

2. Requer switching:

- Precisa de variação temporal no tratamento para identificar efeitos
- Se todos são tratados simultaneamente (nosso caso), adiciona pouco vs C&S

3. Interpretação complexa:

- Múltiplos efeitos dinâmicos podem ser difíceis de comunicar
- Stakeholders podem preferir um ATT único

4. Sensível a especificação:

- Escolha de número de lags/leads é importante
- Muitos períodos dinâmicos = perda de observações

Quando Usar did_multplegt_dyn?

Use quando:

- **Tratamento varia ao longo do tempo** (não permanente)
- **Doses diferentes** de tratamento para diferentes unidades
- **Switching complexo** (entradas e saídas múltiplas)
- **Quer diagnóstico de TWFE** (saber se TWFE é confiável)
- **Efeitos dinâmicos são foco** (trajetória temporal importa)
- **Precisa de placebo tests rigorosos**

Conclusão

did_multiplegt_dyn é poderoso quando:

- Tratamentos são complexos (switching, doses)
- Precisa diagnosticar se TWFE é apropriado
- Efeitos dinâmicos são de interesse substantivo

Para nosso problema (tratamento simples):

- Não adiciona muito sobre C&S Doubly Robust
- Seria útil principalmente para validação e event study detalhado
- Métodos mais simples (C&S, Entropy) são suficientes e mais eficientes

```
In [26]: # =====
# PREPARAR DADOS
# =====

dados_dyn <- dados_twfe %>%
  mutate(renda_periodo = renda_per_capita * periodo,
         internet_periodo = penetracao_internet * periodo,
         concorrentes_periodo = n_concorrentes * periodo) %>%
  mutate(D = as.numeric(tratamento == 1 & periodo >= intervencao)) %>%
  arrange(loja_id, periodo) %>%
  mutate(loja_id = as.numeric(as.factor(loja_id)),
         periodo = as.numeric(periodo))

controls = c("renda_periodo", "internet_periodo", "concorrentes_periodo")

# =====
# MODELO 1: did_multiplegt_dyn sem covariadas e sem pesos
# =====

modelo_didm_1 <- did_multiplegt_dyn(
  df = dados_dyn,
  outcome = "vendas",
  group = "loja_id",
  time = "periodo",
  treatment = "D",
  effects = 5,
  placebo = 2,
  cluster = "loja_id",
  graph_off = TRUE
)

summary(modelo_didm_1)

# =====
# MODELO 2: did_multiplegt_dyn com pesos
# =====

modelo_didm_2 <- did_multiplegt_dyn(
  df = dados_dyn,
  outcome = "vendas",
  group = "loja_id",
  time = "periodo",
  treatment = "D",
  weight = "peso",
  effects = 5,
  placebo = 2,
  cluster = "loja_id",
```



```

graph_off = TRUE
)

summary(modelo_didm_2)

# =====
# MODELO 3: did_multiplegt_stat com pesos
# =====

modelo_stat_1 <- did_multiplegt_stat(
  df = dados_dyn,
  Y = "vendas",
  ID = "loja_id",
  T = "periodo",
  D = "D",
  order = 2,
  estimator = c("aoss", "waoss"),
  estimation_method = "dr",
  aoss_vs_waoss = TRUE,
  placebo = TRUE,
  noextrapolation = TRUE
)

summary(modelo_stat_1)

```

```

-----
                Estimation of treatment effects: Event-study effects
-----
      Estimate   SE       LB CI       UB CI       N   Switchers
Effect_1    6,088.9120 380.6683 5,342.8159 6,835.0081 250 155
Effect_2    6,697.4847 345.0606 6,021.1785 7,373.7910 250 155
Effect_3    6,731.9517 400.6443 5,946.7033 7,517.2000 250 155
Effect_4    6,173.2471 365.9221 5,456.0530 6,890.4413 250 155
Effect_5    6,594.6235 341.0565 5,926.1650 7,263.0820 250 155

Test of joint nullity of the effects : p-value = 0.0000
-----
                Average cumulative (total) effect per treatment unit
-----
      Estimate   SE       LB CI       UB CI       N   Switchers
6,457.2438    278.0267 5,912.3215 7,002.1661    1,250    775
Average number of time periods over which a treatment effect is accumulated: 3.00
00

-----
                Testing the parallel trends and no anticipation assumptions
-----
      Estimate   SE       LB CI       UB CI       N   Switchers
Placebo_1    398.0060 387.1550 -360.8038 1,156.8157 250 155
Placebo_2   -131.5358 390.2594 -896.4301 633.3586   250 155

Test of joint nullity of the placebos : p-value = 0.3685

The development of this package was funded by the European Union.
ERC REALLYCREDIBLE - GA N. 101043899

-----
                Estimation of treatment effects: Event-study effects
-----
      Estimate   SE       LB CI       UB CI       N   Switchers N.w Switcher
s.w
Effect_1    6,060.6900 387.7933 5,300.6291 6,820.7510 250 155    250 155
Effect_2    6,688.1610 380.1232 5,943.1332 7,433.1889 250 155    250 155
Effect_3    6,534.7306 428.8080 5,694.2824 7,375.1788 250 155    250 155
Effect_4    5,918.7238 392.3963 5,149.6412 6,687.8063 250 155    250 155
Effect_5    6,403.0726 355.2931 5,706.7109 7,099.4344 250 155    250 155

Test of joint nullity of the effects : p-value = 0.0000
-----
                Average cumulative (total) effect per treatment unit
-----
      Estimate   SE       LB CI       UB CI       N   Switchers
N.w Switchers.w
6,321.0756    285.1531 5,762.1859 6,879.9653    1,250    775    1,2
50    775
Average number of time periods over which a treatment effect is accumulated: 3.00
00

-----
                Testing the parallel trends and no anticipation assumptions
-----
      Estimate   SE       LB CI       UB CI       N   Switchers N.w Switchers.
w
Placebo_1    671.1107 401.5071 -115.8287 1,458.0501 250 155    250 155

```

Placebo_2 -101.6634 399.5107 -884.6899 681.3631 250 155 250 155

Test of joint nullity of the placebos : p-value = 0.1252

The development of this package was funded by the European Union.
ERC REALLYCREDIBLE - GA N. 101043899

N = 250
WAOSS Method = Doubly Robust
Polynomial Order = 2
Common Support = No Extrapolation

Estimation of AOSS(s)						
	Estimate	SE	LB CI	UB CI	Switchers	Stayers
AOSS	6,088.9120	379.6957	5,344.7084	6,833.1156	155	95

Estimation of AOSS(s) - Placebo						
	Estimate	SE	LB CI	UB CI	Switchers	Stayers
AOSS	-398.0060	386.2099	-1,154.9773	358.9654	155	95

Estimation of WAOSS(s)						
	Estimate	SE	LB CI	UB CI	Switchers	Stayers
WAOSS	6,088.9120	379.6957	5,344.7084	6,833.1156	155	95

Estimation of WAOSS(s) - Placebo						
	Estimate	SE	LB CI	UB CI	Switchers	Stayers
WAOSS	-398.0060	386.2099	-1,154.9773	358.9654	155	95

Difference test: AOSS and WAOSS						
H0: AOSS = WAOSS						
	Estimate	SE	LB CI	UB CI	t stat.	pval.
Diff.	0.00000	0.00000	0.00000	0.00000	-0.70444	0.48116

Análise dos Resultados: DiD De Chaisemartin & D'Haultfoeuille (2024) + AOSS/WAOSS

Efeitos Estimados (ATT)

Modelo	ATT Médio	SE	Viés	Erro Relativo
AOSS/WAOSS (Doubly Robust)	R\$ 6.088,91	379.7	+R\$ 77	+1,3%

Modelo	ATT Médio	SE	Viés	Erro Relativo
DCD&H Com Pesos	R\$ 6.321,08	285.2	+R\$ 309	+5,1%
DCD&H Sem Pesos	R\$ 6.457,24	278.0	+R\$ 445	+7,4%
Efeito Verdadeiro	R\$ 6.012,28	–	0	0%

Efeitos Dinâmicos (DCD&H)

Período	Sem Pesos	Com Pesos	Interpretação
Effect_1	R\$ 6.089	R\$ 6.061	Efeito imediato (+1%)
Effect_2	R\$ 6.697	R\$ 6.688	Pico (+11%)
Effect_3	R\$ 6.732	R\$ 6.535	Mantém alto (+9%)
Effect_4	R\$ 6.173	R\$ 5.919	Queda temporária (-2%)
Effect_5	R\$ 6.595	R\$ 6.403	Recuperação (+7%)
Média	R\$ 6.457	R\$ 6.321	Efeito médio

Trajetória temporal: Efeito cresce até período 2-3, tem leve queda no período 4, depois recupera.

Teste de Tendências Paralelas

Modelo	Placebo_1	Placebo_2	p-value conjunto	Conclusão
DCD&H Sem Pesos	R\$ 398	-R\$ 132	0.3685	✓ Válido (robusto)
DCD&H Com Pesos	R\$ 671	-R\$ 102	0.1252	✓ Válido (moderado)
AOSS/WAOSS	-R\$ 398	–	IC cruza zero	✓ Válido (robusto)

Insights:

- **Magnitude idêntica:** AOSS (-R\$ 398) = DCD&H (+R\$ 398) em valor absoluto → Consistência metodológica
- **Pesos pioram ligeiramente:** p-value cai de 0.37 para 0.13 (ainda válido)
- **Todos validam identificação causal:** ICs cruzam zero, não há efeitos pré-tratamento

AOSS/WAOSS - Descoberta Metodológica

Estimador	Efeito	SE	Switchers	Stayers
AOSS	R\$ 6.088,91	379.7	155	95
WAOSS	R\$ 6.088,91	379.7	155	95

AOSS = WAOSS exatamente (p = 0.481) → Pesos já perfeitamente balanceados

AOSS ≡ DCD&H Effect_1:

- Mesma estimativa: R\$ 6.088,91
- SE quase idêntico: 379.7 vs 380.7
- **Implicação:** AOSS estima efeito instantâneo via doubly robust, equivalente ao DCD&H Effect_1

Insights Importantes

1. Efeito dinâmico não é constante

Variação de -1,6% a +12% ao redor da média (R\$ 6.012). Sugere dinâmica temporal mesmo em tratamento "simples".

2. Pesos reduzem viés principalmente nos períodos tardios

Período	Diferença	Impacto
Effect_1	-0,5%	Mínimo
Effect_4	-4,1%	Máximo
Média	-2,1%	Reduz viés de 7,4% para 5,1%

3. Sensibilidade a pesos nos testes de placebo

Método	Ganho com Pesos no ATT
TWFE	-10,3%
DCD&H	-2,1%
Gardner	-0,7%
C&S	-0,4%

DCD&H é o **2º mais sensível** a pesos.

Conclusão

Use cada método para:

Objetivo	Método Recomendado	Por quê
ATT preciso de longo prazo	TWFE+Entropy, C&S, Gardner	Viés < 1%
Efeito instantâneo	AOSS ou DCD&H Effect_1	Viés 1,3%, numericamente idênticos
Dinâmica temporal	DCD&H com pesos	Trajetória período a período
Validação de identificação	DCD&H placebos	p-value 0.37 (robusto)

Convergência robusta: Todos apontam para **R\$ 6.000-6.300**.

Validação causal: Todos os testes de placebo ($p > 0.10$) confirmam que efeitos são genuinamente causais

Outros Modelos de Diferença-em-Diferenças que podem ser testados

- De Chaisemartin & D’Haultfoeuille (2020); De Chaisemartin & D’Haultfoeuille (2021)
- Goodman-Bacon (2021)
- Clarke & Tapia-Schythe (2022)
- Rambachan & Roth (2023)
- Borusyak, Jaravel, Spiess (2024)

Quer saber mais sobre variantes dos modelos DID e seus Packages para Python, R e Stata veja no link <https://asjadnaqvi.github.io/DiD/>

Resultados modelos de Diferença-em-Diferenças

Tabela: Ranking Modelos de Diferença-em-Diferenças

Ranking	Método	ATT (R\$)	Viés(R\$)	Erro %	SE	Modelo
1º	TWFE + Cov×Período	6.015,00	+3,00	+0,05%	258,0	TWFE
2º	C&S Doubly Robust	6.040,40	+28,00	+0,5%	302,5	C&S
3º	TWFE + Entropy Pesos	6.046,60	+34,32	+0,6%	261,1	TWFE
4º	Gardner + Cov×Período	6.052,00	+40,00	+0,7%	258,0	Gardner
5º	AOSS/WAOSS (DR)	6.088,91	+76,63	+1,3%	379,7	DCD&H
6º	Gardner + Pesos	6.181,00	+168,72	+2,8%	–	Gardner
7º	S&A + Cov×Período	6.276,60	+264,32	+4,4%	261,2	S&A
8º	DCD&H Com Pesos	6.321,08	+308,80	+5,1%	285,2	DCD&H
9º	S&A + Pesos	6.351,80	+339,52	+5,6%	301,5	S&A
10º	C&S IPW + Cov	6.394,00	+381,72	+6,4%	259,6	C&S
11º	DCD&H Sem Pesos	6.457,24	+444,96	+7,4%	278,0	DCD&H

Ranking	Método	ATT (R\$)	Viés(R\$)	Erro %	SE	Modelo
12º	Gardner + Cov	6.615,00	+602,72	+10,0%	–	Gardner
13º	S&A + Cov	6.667,60	+655,32	+10,9%	288,0	S&A
14º	S&A Simples	6.667,60	+655,32	+10,9%	288,0	S&A
15º	C&S Reg Simples	6.667,60	+655,32	+10,9%	302,4	C&S
16º	TWFE + Cov	6.737,31	+725,03	+12,1%	297,0	TWFE
17º	TWFE Simples	6.737,31	+725,03	+12,1%	297,0	TWFE
18º	Gardner Simples	6.737,00	+724,72	+12,1%	–	Gardner

Gráficos Event Study

```
In [27]: df_event_study <- dados %>%
  mutate(
    # g = período de tratamento (NA para never-treated)
    g = ifelse(tratamento == 1, intervencao, NA)
  ) %>%
  as.data.frame()

# Rodar todos os estimadores
multiple_estimates <- did2s::event_study(
  data = df_event_study,
  gname = "g",
  idname = "loja_id",
  tname = "periodo",
  yname = "vendas",
  estimator = "all"
)

# Ver resultados
did2s::plot_event_study(multiple_estimates)
```

Note these estimators rely on different underlying assumptions. See Table 2 of [https://arxiv.org/abs/2109.05913`](https://arxiv.org/abs/2109.05913) for an overview.

Estimating TWFE Model


Estimating using Gardner (2021)

Estimating using Callaway and Sant'Anna (2020)

Estimating using Sun and Abraham (2020)

Estimating using Borusyak, Jaravel, Spiess (2021)

Estimating using Roth and Sant'Anna (2021)



Bayesian structural time-series models - BSTS (CausalImpact)

Bayesian structural time-series models - BSTS

O Bayesian structural time-series models - BSTS é uma abordagem de inferência causal desenvolvida por (Brodersen et al., 2015) no Google, operacionalizado no package **CausalImpact**, que estima o efeito causal de uma intervenção usando modelagem de séries temporais. Diferente dos métodos DiD tradicionais, o BSTS não requer um grupo de controle explícito, mas sim **séries temporais de controle** (covariáveis) para construir um contrafactual sintético. Em outras palavras, você treina o modelos de Séries temporais e faz a predição do grupo de controle com base nas covariadas ou na variável de desfeitos dos grupos de controles se tiver disponível

A Abordagem do CausalImpact

- Comparação: Observado vs Predito (série temporal)
- Estrutura: Série temporal da unidade tratada + covariáveis
- Identificação: Relação estável entre série tratada e covariáveis pré-intervenção

Como CausalImpact Funciona

1. Período Pré-Intervenção (Treinamento)

No período antes da campanha (meses 1-12):

- Modela a relação entre vendas da loja tratada e variáveis preditoras
- Usa Bayesian Structural Time Series (BSTS)
- Aprende padrões, tendências, sazonalidade e correlações

Onde X são:

- Vendas de lojas não-tratadas (controles)
- Variáveis macroeconômicas
- Indicadores de mercado
- Qualquer variável correlacionada com vendas ou até mesmo as vendas de um grupo de controle se tiver disponível

2. Período Pós-Intervenção (Previsão)

No período após a campanha (meses 13-24):

- **Sem campanha:** Usa modelo treinado para prever vendas contrafactuais
- **Com campanha:** Observa vendas reais
- **Efeito causal:** Diferença entre real e predito

3. Inferência Bayesiana

- Gera distribuição posterior do efeito
- Calcula intervalos de credibilidade (não confiança)
- Probabilidade de efeito causal positivo
- Quantifica incerteza de forma natural

Diferenças Fundamentais vs DiD

Aspecto	DiD Tradicional	CausalImpact
Estrutura de controle	Grupo de unidades não-tratadas	Séries temporais correlacionadas
Comparação	Entre grupos	Dentro da mesma unidade ao longo do tempo
Suposição chave	Tendências paralelas entre grupos	Relação estável com covariáveis
Inferência	Frequentista (ICs, p-valores)	Bayesiana (intervalos de credibilidade)
Output	Efeito médio (ATT)	Série temporal completa do efeito
Flexibilidade temporal	Efeito constante ou dinâmico	Efeito pode variar livremente período a período
Número de tratados	Múltiplos grupos	Tipicamente uma unidade

Vantagens do CausalImpact

1. Não requer grupo de controle tradicional

Em vez de lojas não-tratadas, usa:

- Séries temporais de vendas agregadas do mercado
- Indicadores econômicos (PIB, desemprego)
- Dados de Google Trends
- Qualquer variável correlacionada com vendas

Útil quando:

- Todos receberam tratamento (não há controles puros)
- Controles não são comparáveis
- Dados agregados disponíveis

2. Modela estrutura temporal complexa

- **Tendências:** Crescimento de longo prazo
- **Sazonalidade:** Padrões mensais, trimestrais, anuais
- **Ciclos:** Padrões recorrentes não-sazonais
- **Choques:** Eventos únicos no tempo

3. Inferência bayesiana natural

- **Probabilidade posterior:** $P(\text{efeito} > 0 \mid \text{dados}) = 95\%$
- **Intervalos de credibilidade:** "95% de probabilidade de efeito estar entre X e Y"
- **Incorpora incerteza:** Sobre parâmetros e previsões
- **Interpretação direta:** Mais intuitiva que p-valores

4. Visualização rica

CausalImpact produz automaticamente:

- Série observada vs predita (contrafactual)
- Efeito pontual ao longo do tempo
- Efeito cumulativo
- Intervalos de credibilidade

5. Flexibilidade do efeito

- Efeito pode variar livremente período a período
- Não assume efeito constante como TWFE
- Captura dinâmica temporal naturalmente

Suposição Identificadora

CausalImpact: Relação estável entre tratada e covariáveis

- Se não houvesse intervenção, a relação pré-tratamento entre Y_{tratada} e $X_{\text{controles}}$ continuaria válida no período pós

Validação:

- Ajuste do modelo no período pré (R^2 , MSE)
- Análise de resíduos (autocorrelação, normalidade)
- Testes de estabilidade estrutural
- Previsões out-of-sample no período pré

Violação ocorre se:

- Choque específico à unidade tratada não relacionado à intervenção
- Mudança estrutural na relação Y-X (além da intervenção)
- Covariáveis X também são afetadas pela intervenção

Quando Usar CausalImpact

- **Uma única unidade tratada** (ou agregação de unidades)
- **Série temporal suficientemente longa** no pré-período (mínimo 20-30 obs)
- **Boas covariáveis disponíveis** (correlacionadas com outcome)
- **Intervenção única e clara** no tempo
- **Não há grupo de controle adequado**
- **Quer visualizar evolução temporal** do efeito

Não use quando:

- Painel com múltiplos grupos e períodos → Use DiD tradicional
- Tratamento escalonado complexo → Use C&S ou S&A
- Poucas observações pré (<20) → Use métodos de painel
- Sem covariáveis correlacionadas → CausalImpact perde poder

Limitações

1. Requer boas covariáveis

- Precisam ser correlacionadas com outcome
- Não podem ser afetadas pela intervenção
- Quanto mais/melhores, melhor o contrafactual

2. Sensível a especificação do modelo

- Escolha de covariáveis importa
- Número de componentes sazonais
- Estrutura de tendência

3. Não lida naturalmente com múltiplos tratados

- Projetado para uma série tratada
- Extensões possíveis mas não padrão

4. Assume relação linear (geralmente)

- Pode ser relaxado, mas aumenta complexidade

- Métodos não-lineares (ML) também possíveis

Nossa Situação

Características dos nossos dados:

- 155 lojas tratadas (podemos agregar)
- 95 lojas controle (servem como covariáveis)
- 12 meses pré-campanha (período de treino)
- 12 meses pós-campanha (período de avaliação)
- Intervenção única no mês 13

Abordagens possíveis:

Opção 1: Agregar lojas tratadas

- Y_t = vendas médias das 155 lojas tratadas
- X_t = vendas médias das 95 lojas controle
- Controles adicionais: renda, internet, concorrentes agregados

Opção 2: CausalImpact por loja individual

Para cada loja tratada:

Y_t = vendas da loja i

X_t = vendas médias de lojas controle similares

Depois agregar efeitos

O que CausalImpact nos dará:

1. **Contrafactual sintético:** Vendas preditas sem campanha
2. **Efeito período a período:** Como efeito evolui mês 13-24
3. **Efeito cumulativo:** Impacto total acumulado
4. **Probabilidade posterior:** $P(\text{efeito} > 0 \mid \text{dados})$
5. **Intervalos de credibilidade:** Quantificação de incerteza

Valor agregado do CausalImpact:

- **Complementaridade:** Abordagem diferente para validação cruzada
- **Visualização:** Gráficos intuitivos para stakeholders
- **Flexibilidade:** Não assume estrutura rígida do efeito
- **Inferência bayesiana:** Probabilidades diretas para tomada de decisão

Referência

Brodersen, K. H., Gallusser, F., Koehler, J., Remy, N., & Scott, S. L. (2015). **Inferring causal impact using Bayesian structural time-series models.** *Annals of Applied Statistics*, 9(1), 247-274.

Nota

Existem variações desse design de inferência causal que usam modelos mais flexíveis para estimar o contrafactual, incluindo redes neurais. Você pode adaptá-lo ao seu caso empregando o algoritmo que melhor se ajusta ao seu problema — como XGBoost, abordagens zero-shot, entre outros modelos avançados.

CausalImpact: BSTS

In [108...

```
# =====
# PREPARAR DADOS BASE
# =====

# Agregação: vendas médias por período para tratados e controles
dados_ci_base <- dados %>%
  group_by(período, tratamento) %>%
  summarise(
    vendas_media = mean(vendas),
    renda_media = mean(renda_per_capita),
    internet_media = mean(penetração_internet),
    concorrentes_media = mean(n_concorrentes),
    .groups = "drop"
  ) %>%
  tidyr::pivot_wider(
    names_from = tratamento,
    values_from = c(vendas_media, renda_media, internet_media, concorrentes_media),
    names_glue = "{.value}_{tratamento}"
  ) %>%
  dplyr::rename(
    vendas_tratadas = vendas_media_1,
    vendas_controle = vendas_media_0,
    renda_tratadas = renda_media_1,
    renda_controle = renda_media_0,
    internet_tratadas = internet_media_1,
    internet_controle = internet_media_0,
    concorrentes_tratadas = concorrentes_media_1,
    concorrentes_controle = concorrentes_media_0
  )

# Definir períodos
pre_period <- c(1, 12)
post_period <- c(13, 24)

# Efeito verdadeiro para comparação
efeito_verdadeiro <- mean(dados$efeito_verdadeiro[dados$efeito_verdadeiro > 0])
```

Modelo tradicional utilizando variáveis de controle, somente do grupo tratado

In [110...

```
# =====
# MULTIVARIADO (COVARIÁVEIS SOMENTE DO GRUPO DE TRATADO)
# =====

cat("\n=== ABORDAGEM: CAUSALIMPACT MULTIVARIADO ===\n\n")
cat("Modelo: Série das tratadas + múltiplas covariáveis\n")
cat("Covariáveis: renda + internet + concorrentes\n\n")

ts_multivariado <- zoo(
```

```

dados_ci_base %>%
  dplyr::select(
    vendas_tratadas,      # Série tratada (Y) variável de r
    renda_tratadas,       # Covariável 1 tratados
    internet_tratadas,    # Covariável 2 tratados
    concorrentes_tratadas# Covariável 3 tratados
  ),
  order.by = dados_ci_base$periodo
)

# Rodar modelo
impacto_multi <- CausalImpact(ts_multivariado, pre_period, post_period)

# Resultados
print(summary(impacto_multi))
plot(impacto_multi)

# Extrair métricas
efeito_multi      <- impacto_multi$summary$AbsEffect[1]
efeito_multi_lower <- impacto_multi$summary$AbsEffect.lower[1]
efeito_multi_upper <- impacto_multi$summary$AbsEffect.upper[1]
prob_multi        <- impacto_multi$summary$p[1]

cat("\n--- RESUMO MULTIVARIADO ---\n")
cat("Efeito médio:      R$", round(efeito_multi, 2), "\n")
cat("IC 95%:           [", round(efeito_multi_lower, 2), ", ",
    round(efeito_multi_upper, 2), "]\n")
cat("Probabilidade:     ", round(prob_multi * 100, 2), "%\n")
cat("Viés vs real:      R$", round(efeito_multi - efeito_verdadeiro, 2),
    " (", round(100 * (efeito_multi - efeito_verdadeiro) / efeito_verdadeiro, 1)

```

=== ABORDAGEM: CAUSALIMPACT MULTIVARIADO ===

Modelo: Série das tratadas + múltiplas covariáveis

Covariáveis: renda + internet + concorrentes

Posterior inference {CausalImpact}

	Average	Cumulative
Actual	101115	1213376
Prediction (s.d.)	88871 (596)	1066450 (7156)
95% CI	[87639, 89987]	[1051665, 1079839]
Absolute effect (s.d.)	12244 (596)	146926 (7156)
95% CI	[11128, 13476]	[133536, 161710]
Relative effect (s.d.)	14% (0.76%)	14% (0.76%)
95% CI	[12%, 15%]	[12%, 15%]

Posterior tail-area probability p: 0.00101

Posterior prob. of a causal effect: 99.8995%

For more details, type: `summary(impact, "report")`

NULL


--- RESUMO MULTIVARIADO ---

Efeito médio: R\$ 12243.8

IC 95%: [11128.02 , 13475.86]

Probabilidade: 0.1 %

Viés vs real: R\$ 6231.51 (103.6 %)



Modelo utilizando variáveis de controle grupo tratado e controle

```
In [98]: # =====
# MULTIVARIADO (TODAS COVARIÁVEIS TRATADOS E CONTROLE)
# =====

cat("\n=== ABORDAGEM: CAUSALIMPACT MULTIVARIADO ===\n\n")
cat("Modelo: Série das tratadas + múltiplas covariáveis\n")
cat("Covariáveis: renda + internet + concorrentes\n\n")

ts_multivariado <- zoo(
  dados_ci_base %>%
    dplyr::select(
      vendas_tratadas,      # Série tratada (Y) variável de resposta
      renda_tratadas,       # Covariável 1 tratados
      internet_tratadas,    # Covariável 2 tratados
      concorrentes_tratadas, # Covariável 3 tratados
      renda_controle,       # Covariável 4 controles
      internet_controle,    # Covariável 5 controles
      concorrentes_controle, # Covariável 6 controles
    ),
  order.by = dados_ci_base$periodo
)

# Rodar modelo
impacto_multi2 <- CausalImpact(ts_multivariado, pre_period, post_period)

# Resultados
print(summary(impacto_multi2))
plot(impacto_multi2)

# Extrair métricas
efeito_multi2 <- impacto_multi2$summary$AbsEffect[1]
efeito_multi_lower2 <- impacto_multi2$summary$AbsEffect.lower[1]
efeito_multi_upper2 <- impacto_multi2$summary$AbsEffect.upper[1]
prob_multi2 <- impacto_multi2$summary$p[1]

cat("\n--- RESUMO MULTIVARIADO ---\n")
cat("Efeito médio:      R$", round(efeito_multi, 2), "\n")
cat("IC 95%:           [", round(efeito_multi_lower, 2), ", ",
  round(efeito_multi_upper2, 2), "]\n")
cat("Probabilidade:     ", round(prob_multi2 * 100, 2), "%\n")
cat("Viés vs real:      R$", round(efeito_multi2 - efeito_verdadeiro, 2),
  " (", round(100 * (efeito_multi2 - efeito_verdadeiro) / efeito_verdadeiro, 1
```


=== ABORDAGEM: CAUSALIMPACT MULTIVARIADO ===

Modelo: Série das tratadas + múltiplas covariáveis

Covariáveis: renda + internet + concorrentes

Posterior inference {CausalImpact}

	Average	Cumulative
Actual	101115	1213376
Prediction (s.d.)	88867 (619)	1066404 (7428)
95% CI	[87706, 90141]	[1052469, 1081691]
Absolute effect (s.d.)	12248 (619)	146972 (7428)
95% CI	[10974, 13409]	[131685, 160907]
Relative effect (s.d.)	14% (0.79%)	14% (0.79%)
95% CI	[12%, 15%]	[12%, 15%]

Posterior tail-area probability p: 0.001

Posterior prob. of a causal effect: 99.8996%

For more details, type: `summary(impact, "report")`

NULL


--- RESUMO MULTIVARIADO ---

Efeito médio: R\$ 12243.8

IC 95%: [11002.18 , 13408.92]

Probabilidade: 0.1 %

Viés vs real: R\$ 6235.36 (103.7 %)



Modelo utilizando somente as vendas do grupo de controle

```

In [99]: # =====
# BIVARIADO (VENDAS CONTROLE)
# =====

cat("\n=== ABORDAGEM: CAUSALIMPACT BIVARIADO ===\n\n")
cat("Modelo: Série das tratadas + vendas das controles\n")
cat("Covariáveis: Vendas médias das lojas controle\n\n")

# Vendas tratadas + vendas controle
ts_bivariado <- zoo(
  dados_ci_base %>%
    select(
      vendas_tratadas, # Série tratada (Y) variável de resposta
      vendas_controle # Covariável 1 controles
    ),
  order.by = dados_ci_base$periodo
)

# Rodar modelo
impacto_bi <- CausalImpact(ts_bivariado, pre_period, post_period)

# Resultados
print(summary(impacto_bi))
plot(impacto_bi)

# Extrair métricas
efeito_bi <- impacto_bi$summary$AbsEffect[1]
efeito_bi_lower <- impacto_bi$summary$AbsEffect.lower[1]
efeito_bi_upper <- impacto_bi$summary$AbsEffect.upper[1]
prob_bi <- impacto_bi$summary$p[1]

cat("\n--- RESUMO BIVARIADO ---\n")
cat("Efeito médio:      R$", round(efeito_bi, 2), "\n")
cat("IC 95%:           [", round(efeito_bi_lower, 2), ",",
  round(efeito_bi_upper, 2), "]\n")
cat("Probabilidade:     ", round(prob_bi * 100, 2), "%\n")
cat("Viés vs real:      R$", round(efeito_bi - efeito_verdadeiro, 2),
  " (" , round(100*(efeito_bi - efeito_verdadeiro)/efeito_verdadeiro, 1), "%)\n")

```

=== ABORDAGEM: CAUSALIMPACT BIVARIADO ===

Modelo: Série das tratadas + vendas das controles

Covariáveis: Vendas médias das lojas controle

Posterior inference {CausalImpact}

	Average	Cumulative
Actual	101115	1213376
Prediction (s.d.)	93994 (782)	1127931 (9386)
95% CI	[92509, 95541]	[1110112, 1146491]

Absolute effect (s.d.)	7120 (782)	85445 (9386)
95% CI	[5574, 8605]	[66885, 103263]

Relative effect (s.d.)	7.6% (0.9%)	7.6% (0.9%)
95% CI	[5.8%, 9.3%]	[5.8%, 9.3%]

Posterior tail-area probability p: 0.00101

Posterior prob. of a causal effect: 99.8993%

For more details, type: `summary(impact, "report")`

NULL


--- RESUMO BIVARIADO ---

Efeito médio: R\$ 7120.42

IC 95%: [5573.75 , 8605.28]

Probabilidade: 0.1 %

Viés vs real: R\$ 1108.14 (18.4 %)



In [111...

```
# =====  
# COMPARAÇÃO DAS ABORDAGENS
```

```
# =====

cat("\n\n=== COMPARAÇÃO: 3 ABORDAGENS CAUSALIMPACT ===\n\n")

comparacao_ci <- data.frame(
  Abordagem = c(
    "Bivariado (vendas controle)",
    "Multivariado (somente grupo tratado)",
    "Multivariado (grupo tratado e controle)",
    "Efeito Verdadeiro"
  ),
  Efeito = c(efeito_bi, efeito_multi, efeito_multi2, efeito_
  IC_Lower = c(efeito_bi_lower, efeito_multi_lower, efeito_multi_lower2, NA),
  IC_Upper = c(efeito_bi_upper, efeito_multi_upper, efeito_multi_upper2, NA),
  Probabilidade = c(prob_bi, prob_multi, prob_multi2, NA)
) %>%
mutate(
  Vies = Efeito - efeito_verdadeiro,
  Erro_Pct = round(100 * Vies / efeito_verdadeiro, 1),
  Amplitude_IC = IC_Upper - IC_Lower
)

print(comparacao_ci)
```

=== COMPARAÇÃO: 3 ABORDAGENS CAUSALIMPACT ===

	Abordagem	Efeito	IC_Lower	IC_Upper	Probabili
1	Bivariado (vendas controle)	7120.424	5573.753	8605.285	0.00100
7049					
2	Multivariado (somente grupo tratado)	12243.795	11128.021	13475.863	0.00100
5025					
3	Multivariado (grupo tratado e controle)	12247.641	10973.764	13408.924	0.00100
4016					
4	Efeito Verdadeiro	6012.281	NA	NA	
NA					

In [112...

```
# =====
# INTERPRETAÇÃO BAYESIANA
# =====

cat("\n\n=== INTERPRETAÇÃO BAYESIANA ===\n\n")

cat("Probabilidade de efeito positivo:\n")
cat("  Bivariado:      ", round((1 - prob_bi) * 100, 2), "%\n")
cat("  Multivariado tratado:      ", round((1 - prob_multi) * 100, 2), "%\n")
cat("  Multivariado tratado controle: ", round((1 - prob_multi2) * 100, 2), "%\n")

cat("Interpretação:\n")
cat("'Há X% de probabilidade posterior de que o efeito seja positivo,\n")
cat("dados os dados observados e o modelo especificado'\n")
```

=== INTERPRETAÇÃO BAYESIANA ===

Probabilidade de efeito positivo:

Bivariado: 99.9 %

Multivariado tratado: 99.9 %

Multivariado tratado controle: 99.9 %

Interpretação:

'Há X% de probabilidade posterior de que o efeito seja positivo, dados os dados observados e o modelo especificado'

Análise dos Resultados: CausalImpact (Google)

Comparação das 3 Abordagens

Abordagem	Efeito (R\$)	IC 95%	Prob. efeito positivo	Viés	Erro %
Bivariado (vendas controle)	7.120,42	[5.574, 8.605]	99.9%	+1.108	+18.4%
Multivariado (somente grupo tratado)	12.243,80	[11.002, 13.446]	99.9%	+6.231	+103.6%
Multivariado (tratado + controle)	12.247,64	[10.974, 13.409]	99.9%	+6.235	+103.7%
Efeito Verdadeiro	6.012,28	-	-	0	0%

Melhor Especificação: Bivariado

Modelo:

Vendas_tratadas_t = f(Vendas_controle_t, tendência, sazonalidade)

Resultados:

- **Efeito médio:** R\$ 7.120 por mês
- **Efeito relativo:** +7.6%
- **IC 95%:** [5.574, 8.605]
- **Probabilidade de efeito positivo:** 99.9%
- **p-valor (tail-area):** 0.001

Contrafactual:

- **Vendas observadas (pós):** R\$ 101.115
- **Vendas preditas sem campanha:** R\$ 93.995
- **Diferença (efeito):** R\$ 7.120

Por Que Bivariado é Superior?

- Utiliza vendas de controle para construir um contrafactual temporalmente consistente

- Captura tendências comuns do mercado
- Reduz substancialmente o viés
- Produz intervalo de credibilidade com boa precisão
- Mantém estabilidade e coerência entre o pré e o pós-intervenção

Modelos multivariados apresentam estimativas excessivamente elevadas porque utilizam covariáveis que **não variam no tempo**, o que impede o ajuste adequado da dinâmica temporal exigida pelo CausalImpact.

Limitação: Viés Residual de +18.4%

Mesmo com covariáveis temporais de controle, o modelo assume uma relação fixa entre tratado e controle no período pós. Como a trajetória do grupo tratado exibe um crescimento mais acentuado, parte do aumento é atribuído incorretamente como efeito da intervenção.

Métodos com balanceamento explícito (como Entropy) eliminam esse viés ao alinhar níveis e tendências antes da estimativa do efeito.

Inferência Bayesiana

Probabilidade posterior de efeito positivo:

- **Bivariado:** 99.9%
- **Multivariado (tratado):** 99.9%
- **Multivariado (tratado + controle):** 99.9%

Interpretação:

“Há 99.9% de probabilidade de que o efeito seja positivo, dados os dados observados e o modelo especificado.”

Conclusão

CausalImpact Bivariado é a especificação mais adequada:

- **Efeito estimado:** R\$ 7.120/mês
- **Viés:** +18.4%
- **Pontos fortes:** contrafactual bem definido, inferência bayesiana clara, IC consistente
- **Limitação:** ainda apresenta superestimação moderada, tratável com métodos de balanceamento explícito

Tabela: Ranking Modelos Causal Impact

Ranking	Método	Efeito (R\$)	Viés (R\$)	Erro %	Amplitude IC	Probabilidade	Abordagem
1º	Bivariado (vendas controle)	7.120,42	+1.108,14	+18,4%	3.031,53	0,001007	Bivariado

Ranking	Método	Efeito (R\$)	Viés (R\$)	Erro %	Amplitude IC	Probabilidade	Abordagem
2º	Multivariado (grupo tratado e controle)	12.247,64	+6.235,36	+103,7%	2.435,16	0,001004	Multivariado
3º	Multivariado (somente grupo tratado)	12.243,80	+6.231,51	+103,6%	2.347,84	0,001005	Multivariado
—	Efeito Verdadeiro (Referência)	6.012,28	0,00	0,0%	—	—	—

Synthetic Control Methods: Controle Sintético

O Que é Synthetic Control (SC)

Synthetic Control (SC) cria uma unidade "**sintética**" apartir de uma combinação ponderada de unidades controle, que replica perfeitamente a unidade tratada antes da intervenção. Em outras palavras, para um comportamento das vendas de uma loja tratada, o controle sintético combina varias lojas do grupo de controle, de maneira que reproduza exatamente o coportamento das vendas das lojas tratadas antes da campanha de marketing.

Ideia central:

"Se não temos um controle perfeito, vamos criar um combinando vários controles imperfeitos."

Exemplo:

$$\text{Lojas_tratadas_sintéticas} = 0.15 \cdot \text{Loja_2} + 0.08 \cdot \text{Loja_5} + 0.12 \cdot \text{Loja_8} + \dots + 0.05 \cdot \text{Loja_95}$$

Onde os pesos são escolhidos para que o sintético **replique exatamente** as vendas das tratadas nos meses 1-12 (pré-campanha).

Mecânica em 3 Passos

- **1. Período Pré (meses 1-12):** Encontrar combinação de lojas controle que melhor replica lojas tratadas
- **2. Período Pós (meses 13-24):** Projetar o que aconteceria com o sintético (sem campanha)
- **3. Efeito = Real - Sintético:** Diferença é o efeito causal

Por Que é Bom?

1. Transparência Total

- Vemos exatamente quais lojas contribuem e com que peso
- Nada de "caixa-preta"
- Validação substantiva: "faz sentido usar essas lojas?"

2. Balanceamento Automático

- Não precisa especificar modelo
- Algoritmo encontra pesos ótimos
- Balanceia múltiplas dimensões simultaneamente (vendas + covariáveis)

3. Não Assume Linearidade

- Não requer regressão
- Não assume efeito constante
- Data-driven puro

4. Visualização Clara

- Gráfico mostra trajetória real vs sintética
- Comunicação intuitiva para stakeholders
- Gap temporal completo

Intuição: SC vs CausalImpact

Ambos constroem contrafactual sintético, mas diferem na abordagem:

Aspecto	CausalImpact	Synthetic Control
O que combina	Séries temporais correlacionadas	Unidades similares
Analogia	"Séries que se movem juntas"	"Lojas que se parecem"
Modelo	BSTS (Bayesian time series)	Otimização convexa
Pesos	Aprendidos por correlação temporal	Otimizados para ajuste pré
Inferência	Bayesiana (probabilidades)	Frequentista (placebo tests)
Flexibilidade	Efeito varia livremente	Efeito varia livremente
Interpretação	"Prevejo baseado em correlações"	"Copio trajetória de similares"

Exemplo:

CausalImpact diz:

"Lojas tratadas historicamente se movem com vendas das controles. Vou usar essa correlação para prever o contrafactual."

Synthetic Control diz:

"Vou encontrar quais lojas controle, quando combinadas, replicam perfeitamente as tratadas. Essa combinação é o contrafactual."

As 3 Variações Modernas do SC

1. SC Tradicional (Abadie, 2010)

- Método original estabelecido
- Pesos otimizados para ajuste pré perfeito

2. Augmented SC (Ben-Michael, 2021)

- SC + Ridge regression para correção
- Mais robusto quando ajuste pré não é perfeito

3. Synthetic DiD (Arkhangelsky, 2021)

- Combina SC (pondera unidades) + DiD (pondera tempo)
- Relaxa suposições de ambos

Suposição Chave

SC: Interpolação convexa (tratada está "dentro" do espaço dos controles)

- Se posso replicar tratada como combinação de controles no pré, essa combinação é válida no pós (sem tratamento)

Quando falha: Se tratada é outlier extremo que nenhuma combinação de controles consegue replicar.

Conclusão

- **Cria contrafactual transparente**
- **Não assume forma funcional** (data-driven)
- **Intuitivo para comunicar**

```
In [ ]: # =====  
# PREPARAR DADOS  
# =====  
# Para Synthetic Control, vamos agregar as lojas tratadas em uma única unidade e  
  
dados_sc <- dados %>%  
  mutate(  
    # Criar ID único: 1 = agregado tratadas, 2-96 = lojas controle individuais  
    unit_id = ifelse(tratamento == 1, 1, as.numeric(loja_id) + 1),  
    # Criar nome descritivo
```

```

    unit_name = ifelse(tratamento == 1, "Tratadas", paste0("Controle_", loja_id)
  ) %>%
# Agregar lojas tratadas
group_by(unit_id, periodo, tratamento) %>%
summarise(
  vendas = mean(vendas),
  renda_per_capita = mean(renda_per_capita),
  penetracao_internet = mean(penetracao_internet),
  n_concorrentes = mean(n_concorrentes),
  potencial_crescimento = mean(potencial_crescimento),
  .groups = "drop"
)

```

Controle Sintético (Ben-Michael et al., 2021)

- Método mais recente e robusto (Ben-Michael et al., 2021)
- Combina SC com ridge regression para melhorar ajuste

In [115...

```

# =====
# ABORDAGEM 1: AUGMENTED SYNTHETIC CONTROL
# =====
cat("=== AUGMENTED SYNTHETIC CONTROL ===\n\n")

# Preparar dados no formato wide para augsynth
dados_wide <- dados_sc %>%
  select(unit_id, periodo, tratamento, vendas,
         renda_per_capita, penetracao_internet, n_concorrentes, potencial_cresci
  tidy::pivot_wider(
    names_from = periodo,
    values_from = c(vendas, renda_per_capita, penetracao_internet,
                   n_concorrentes, potencial_crescimento),
    names_sep = "_"
  )

# Criar matriz de outcomes (vendas por período)
outcome_cols <- grep("^vendas_", names(dados_wide), value = TRUE)
Y_matrix <- as.matrix(dados_wide[, outcome_cols])
rownames(Y_matrix) <- dados_wide$unit_id

# Identificar tratado e controles
treated_unit <- 1
control_units <- dados_wide$unit_id[dados_wide$unit_id != treated_unit]

# Modelo 1: Augmented SC com covariáveis
aug_sc <- augsynth(
  form = vendas ~ tratamento | renda_per_capita + penetracao_internet +
                                n_concorrentes + potencial_crescimento,

  unit = unit_id,
  time = periodo,
  data = dados_sc,
  t_int = 13, # Período de intervenção
  progfunc = "Ridge", # Usa Ridge regression para augmentation
  scm = TRUE # Incluir SC tradicional
)

# Resultados
print(summary(aug_sc))

```

```
#plot(aug_sc)

# Extrair ATT
att_aug_sc <- summary(aug_sc)$average_att$Estimate

cat("\nATT Augmented SC: R$", round(att_aug_sc, 2), "\n")
```

=== AUGMENTED SYNTHETIC CONTROL ===

One outcome and one treatment time found. Running single_augsynth.

Call:

```
single_augsynth(form = form, unit = !!enquo(unit), time = !!enquo(time),
  t_int = t_int, data = data, progfunc = "Ridge", scm = TRUE)
```

Average ATT Estimate (p Value for Joint Null): 5955 (0.21)

L2 Imbalance: 0.000

Percent improvement from uniform weights: 100%

Covariate L2 Imbalance: 0.001

Percent improvement from uniform weights: 100%

Avg Estimated Bias: 0.000

Inference type: Conformal inference

	Time Estimate	95% CI Lower Bound	95% CI Upper Bound	p Value
13	5695.110	-6234.344	17624.56	0.070
14	6475.342	-5454.112	18404.79	0.071
15	6224.072	-5705.381	18153.53	0.078
16	5702.929	-6226.524	17632.38	0.082
17	6015.353	-5914.100	17944.81	0.086
18	6560.430	-5369.023	18489.88	0.076
19	6139.867	-5789.586	18069.32	0.072
20	5484.381	-6445.072	17413.83	0.067
21	6092.850	-5836.603	18022.30	0.074
22	5894.311	-6035.143	17823.76	0.071
23	5671.964	-6257.490	17601.42	0.081
24	5501.978	-6427.475	17431.43	0.080

ATT Augmented SC: R\$ 5954.88

Controle Sintético com DiD (Arkhangelsky et al., 2021)

In [116...

```
# =====
# ABORDAGEM 2: SYNTHETIC DIFFERENCE-IN-DIFFERENCES
# =====
cat("\n\n=== SYNTHETIC DIFFERENCE-IN-DIFFERENCES ===\n\n")

sdid_model <- augsynth(
  form = vendas ~ tratamento,
  unit = unit_id,
  time = periodo,
  data = dados_sc,
  t_int = 13,
  progfunc = "None",
  scm = FALSE,
```

```

fixedeff = TRUE # Usa método SDID
)

print(summary(sdid_model))
#plot(sdid_model)

att_sdid <- summary(sdid_model)$average_att$Estimate

cat("\nATT Synthetic DiD: R$", round(att_sdid, 2), "\n")

```

=== SYNTHETIC DIFFERENCE-IN-DIFFERENCES ===

One outcome and one treatment time found. Running single_augsynth.

Call:

```

single_augsynth(form = form, unit = !!enquo(unit), time = !!enquo(time),
  t_int = t_int, data = data, progfunc = "None", scm = FALSE,
  fixedeff = TRUE)

```

Average ATT Estimate (p Value for Joint Null): 6280 (0.6)

L2 Imbalance: 0.000

Percent improvement from uniform weights: 100%

Avg Estimated Bias: NA

Inference type: Conformal inference

	Time Estimate	95% CI Lower Bound	95% CI Upper Bound	p Value
13	5796.333	-6781.688	18374.35	0.076
14	6584.267	-5993.754	19162.29	0.071
15	6370.080	-6207.941	18948.10	0.080
16	5847.688	-6730.333	18425.71	0.071
17	6366.513	-6211.508	18944.53	0.065
18	6633.116	-5944.905	19211.14	0.079
19	6338.231	-6239.790	18916.25	0.079
20	5725.250	-6852.771	18303.27	0.087
21	6736.928	-5841.093	19314.95	0.064
22	6695.247	-5882.774	19273.27	0.074
23	6149.989	-6428.032	18728.01	0.086
24	6113.846	-6464.175	18691.87	0.068

ATT Synthetic DiD: R\$ 6279.79

Controle Sintético Tradicional (Abadie, 2010)

In [117...

```

# =====
# ABORDAGEM 3: SYNTHETIC CONTROL TRADICIONAL
# =====
cat("\n\n=== SYNTHETIC CONTROL TRADICIONAL ===\n\n")

# Preparar dados com unit_name como character
dados_sc_synth <- dados_sc %>%
  mutate(
    unit_name = as.character(unit_id) # Criar variável character para unit.name
  )

# Preparar dados para Synth package

```

```

dataprep_out <- dataprep(
  foo = as.data.frame(dados_sc_synth),
  predictors = c("renda_per_capita", "penetracao_internet",
                 "n_concorrentes", "potencial_crescimento"),
  predictors.op = "mean",
  time.predictors.prior = 1:12,
  dependent = "vendas",
  unit.variable = "unit_id",
  unit.names.variable = "unit_name", # Agora usa a variável character
  time.variable = "periodo",
  treatment.identifier = 1,
  controls.identifier = control_units,
  time.optimize.ssr = 1:12,
  time.plot = 1:24
)

# Rodar SC
synth_out <- synth(dataprep_out)

# Gaps (diferença tratado vs sintético)
gaps <- dataprep_out$Y1plot - (dataprep_out$Y0plot %*% synth_out$solution.w)

# ATT médio pós-intervenção
att_sc_trad <- mean(gaps[13:24, ])

cat("\nATT SC Tradicional: R$", round(att_sc_trad, 2), "\n")

# Plot
path.plot(synth.res = synth_out, dataprep.res = dataprep_out,
          Ylab = "Vendas", Xlab = "Período",
          Legend = c("Tratadas", "Sintético"),
          Legend.position = "bottomright")
abline(v = 12.5, lty = 2, col = "red")

# Gaps plot
# gaps.plot(synth.res = synth_out, dataprep.res = dataprep_out,
#           Ylab = "Gap (Tratado - Sintético)", Xlab = "Período",
#           Main = "")
# abline(v = 12.5, lty = 2, col = "red")
# abline(h = 0, lty = 2, col = "gray")

# =====
# PESOS DOS DOADORES
# =====

cat("\n\n=== PESOS DOS DOADORES (SC Tradicional) ===\n\n")

pesos_sc <- data.frame(
  unit_id = control_units,
  peso = as.vector(synth_out$solution.w)
) %>%
  filter(peso > 0.001) %>% # Apenas pesos relevantes
  arrange(desc(peso))

# print(pesos_sc)

cat("\nNúmero de doadores com peso > 0.001:", nrow(pesos_sc), "\n")
cat("Soma dos pesos:", sum(synth_out$solution.w), "\n")

# =====

```

```
# QUALIDADE DO AJUSTE PRÉ-INTERVENÇÃO
# =====

cat("\n\n== QUALIDADE DO AJUSTE (Período Pré) ==\n\n")

# RMSPE (Root Mean Squared Prediction Error)
rmspe_pre <- sqrt(mean((gaps[1:12, ])^2))
rmspe_pos <- sqrt(mean((gaps[13:24, ])^2))
```

=== SYNTHETIC CONTROL TRADICIONAL ===

X1, X0, Z1, Z0 all come directly from dataprep object.

```
*****
searching for synthetic control unit
```

```
*****
*****
*****
```

MSPE (LOSS V): 135145

```
solution.v:
0.3634445 0.1882265 0.229338 0.218991
```


```
solution.w:
0.006992316 0.006695793 0.006183174 0.006912726 0.006747358 0.006218515 0.008098
753 0.007483257 0.006436465 0.01028381 0.006031804 0.007024474 0.0111528 0.008054
722 0.007594659 0.005959215 0.007898191 0.01008194 0.009820981 0.01066016 0.00793
7395 0.006721175 0.1011132 0.01167528 0.01768629 0.00987281 0.005989854 0.0143966
9 0.0114097 0.007342632 0.00649152 0.006766456 0.008848027 0.005835995 0.014359
0.00848633 0.06726759 0.007097145 0.008170059 0.009387673 0.008877806 0.005919361
0.006508241 0.007608524 0.006923578 0.00647077 0.007532218 0.007626975 0.00899278
8 0.006242894 0.04071937 0.01050092 0.007952902 0.008596566 0.008592793 0.0094970
2 0.006788193 0.0165226 0.008519497 0.006278893 0.008056184 0.006889543 0.0092644
86 0.01021831 0.01320193 0.008877642 0.006699552 0.006805799 0.005870359 0.007687
574 0.006635039 0.01056876 0.005302467 0.007018153 0.006890829 0.01258586 0.00871
2486 0.01191589 0.008153934 0.01099353 0.008594656 0.0113783 0.009841713 0.006657
273 0.008266541 0.007656283 0.008573784 0.005276316 0.01141849 0.006242611 0.0053
70856 0.006503824 0.02386276 0.009350533 0.008799906
```

ATT SC Tradicional: R\$ 5953.4

=== PESOS DOS DOADORES (SC Tradicional) ===

Número de doadores com peso > 0.001: 95
Soma dos pesos: 1

=== QUALIDADE DO AJUSTE (Período Pré) ===



In [120...

```
# =====
# COMPARAÇÃO DAS 3 ABORDAGENS SC
# =====

efeito_verdadeiro <- mean(dados$efeito_verdadeiro[dados$efeito_verdadeiro > 0])

cat("\n=== COMPARAÇÃO: MÉTODOS SYNTHETIC CONTROL ===\n\n")

comparacao_sc <- data.frame(
  Metodo = c(
    "SC Tradicional (Abadie)",
    "Augmented SC (Ridge)",
    "Synthetic DiD",
    "Efeito Verdadeiro"
  ),
  Efeito = c(att_sc_trad, att_aug_sc, att_sdidd, efeito_verdadeiro)
) %>%
  mutate(
    Vies = Efeito - efeito_verdadeiro,
    Erro_Pct = round(Vies / efeito_verdadeiro, 4)
  )

print(comparacao_sc)
```

=== COMPARAÇÃO: MÉTODOS SYNTHETIC CONTROL ===

	Metodo	Efeito	Vies	Erro_Pct
1	SC Tradicional (Abadie)	5953.403	-58.87857	-0.0098
2	Augmented SC (Ridge)	5954.882	-57.39891	-0.0095
3	Synthetic DiD	6279.791	267.50966	0.0445
4	Efeito Verdadeiro	6012.281	0.00000	0.0000

Resultados: Synthetic Control - 3 Abordagens

Resumo Executivo

Método	Efeito (R\$)	Viés (R\$)	Erro %
SC Tradicional (Abadie)	5.953,40	-58,88	-0,98%
Augmented SC (Ridge)	5.954,88	-57,40	-0,95%
Synthetic DiD	6.279,79	+267,51	+4,45%
Efeito Verdadeiro	6.012,28	0	0%

1. SC Tradicional (Abadie)

Efeito: R\$ 5.953,40 (erro: -0,98%)

Cria unidade sintética como combinação ponderada de lojas controle que melhor replica as tratadas no pré-intervenção. Minimiza diferenças entre tratado observado e sintético antes da campanha.

Por que funciona bem:

- 95 lojas controle disponíveis
- Ajuste pré-intervenção excelente
- Transparente: identifica quais lojas contribuem

2. Augmented SC (Ridge)

Efeito: R\$ 5.954,88 (erro: -0,95%)

Adiciona correção via Ridge regression ao SC tradicional. Útil quando SC puro não replica perfeitamente o tratado.

Resultado: Praticamente idêntico ao SC tradicional (diferença de R\$ 1,48), indicando que o ajuste do SC puro já era ótimo e não precisou de correção adicional.

3. Synthetic DiD

Efeito: R\$ 6.279,79 (erro: +4,45%)

Combina ideias de SC e DiD com ponderação bidimensional (unidades + tempo). Mais flexível, permite ajuste temporal adicional.

Performance: Erro de 4,45% permanece muito bom, embora maior que os métodos anteriores.

Consenso e Robustez

Os três métodos convergem para a faixa R\$ 5.950-6.280:

- **Amplitude:** Apenas R\$ 327 entre estimativas
- **SC e Augmented:** Praticamente idênticos (Δ R\$ 1,48)
- **Synthetic DiD:** Ligeiramente superior, mas dentro de margem aceitável

Conclusão: Métodos diferentes com suposições distintas convergem para resultados similares, reforçando confiança nas estimativas.

Tabela: Ranking Modelos Controle Sintético

Ranking	Método	Efeito (R\$)	Viés (R\$)	Erro %	Abordagem
1º	Augmented SC (Ridge)	5.954,88	-57,40	-0,95%	Augmented SC
2º	SC Tradicional (Abadie)	5.953,40	-58,88	-0,98%	SC Clássico
3º	Synthetic DiD	6.279,79	+267,51	+4,45%	Synthetic DiD
—	Efeito Verdadeiro (Referência)	6.012,28	0,00	0,0%	—

Causal Forest

0 Que é Causal Forest?

Método de machine learning desenvolvido por Wager & Athey (2018) que:

- Estima efeitos heterogêneos do tratamento
- Usa Random Forest adaptado para inferência causal
- Não assume forma funcional (não-paramétrico)
- Identifica subgrupos com efeitos diferentes

Diferença vs métodos anteriores:

- Causal Forest: Descobre padrões complexos nos dados
- Permite **efeito diferente para cada loja** (ITE)

Intuição da Floresta Causal

A floresta causal aplica os princípios da random forest para encontrar unidades de controle semelhantes às tratadas, e estima o efeito do tratamento com base nas diferenças observadas entre esses grupos similares.

Construção das Árvores

Cada árvore da floresta divide os dados com base nas covariáveis, mas o critério de divisão não é o erro de predição (como na Random Forest tradicional), e sim a diferença

de efeito do tratamento entre os grupos nas folhas.


A floresta busca **identificar subgrupos onde o efeito do tratamento é diferente**.

Estimativa do Efeito

Para cada observação nova, a floresta:

- Analisa em quais folhas ela cai (em várias árvores diferentes).
- Estima o efeito do tratamento nessas folhas.
- Calcula a **média ponderada dos efeitos** → isso gera o **ITE estimado** para cada unidade.

Imagem ilustrativa do Causal Forest



{width="600", height="350"}

Resultados Típicos

- É o Efeito médio do tratamento para toda a população.
- *Responde:* "Qual o efeito médio da campanha considerando todas as lojas?"
- É o Efeito médio do tratamento condicional a características (subgrupos).
- *Responde:* "Qual o efeito médio da campanha para lojas com características X?"
- É o Efeito do tratamento para cada unidade específica.
- *Responde:* "Qual o efeito da campanha na Loja 42 especificamente?"
- Identifica quais variáveis mais influenciam a heterogeneidade do efeito.
- *Responde:* "Quais características mais determinam diferenças no efeito?"

Selecionar variáveis relevantes com `variable_importance()`

Estimar o ITE (*Individual Treatment Effect*)

Estimar o CATE (*Conditional Average Treatment Effect*) por subgrupo

Estimar o ATE (*Average Treatment Effect*) com
`average_treatment_effect()`

Por que floresta causal é diferente?

- Porque a floresta causal **não tenta prever o contrafactual diretamente** (como o causal impacto, regressões lineares ou redes neurais). Ele usa grupos de comparação formados **dentro da floresta**, com lojas **parecidas entre si, mas que receberam tratamentos diferentes**.
- A floresta causal constrói o contrafactual de forma **implícita**, usando **unidades semelhantes separadas por tratamento**, e **combina os resultados de muitas árvores honestas** para estimar quanto o tratamento teria mudado o resultado.

Comparação do Floresta Causal com Propensity Score Matching (PSM)

A floresta causal compartilha a **intuição básica** do PSM: ajustar para viés de seleção usando covariáveis e encontrar grupos comparáveis.

Semelhanças

- Ambos comparam **tratados com controles "parecidos"**.
- Ambos usam **covariáveis para controlar confusão**.
- Ambos assumem **ignorabilidade condicional** (*unconfoundedness*).

Diferenças Fundamentais

Aspecto	Propensity Score Matching (PSM)	Floresta Causal (Causal Forest)
Etapas	Usa score $P(W = 1 X)$ para parear	Usa divisões baseadas em heterogeneidade
Construção do contrafactual	Média dos controles mais próximos	Diferença média dentro das folhas
Heterogeneidade do efeito	Estima um único efeito médio por par	Estima ITE (efeito individualizado)
Flexibilidade	Menos adaptável a interações complexas	Captura interações e não linearidades
Estimativa paramétrica	Requer modelo para o score	Modelo não paramétrico via ML

A floresta causal é uma evolução moderna e robusta para **inferência causal individualizada**, especialmente útil em contextos com muitos preditores, interações e efeitos variados.

In [122...

```
# =====  
# PREPARAR DADOS  
# =====  
  
dados_pos <- dados %>%  
  filter(pos == 1) %>%  
  group_by(loja_id) %>%
```

```

summarise(
  vendas_pos = mean(vendas),
  tratamento = first(tratamento),
  renda_per_capita = first(renda_per_capita),
  penetracao_internet = first(penetracao_internet),
  n_concorrentes = first(n_concorrentes),
  potencial_crescimento = first(potencial_crescimento)
)

# Matriz de covariáveis
X <- as.matrix(dados_pos %>%
  select(renda_per_capita, penetracao_internet, n_concorrentes, potencial_cresci

# Variável de tratamento
W <- dados_pos$tratamento

# Variável de resultado
Y <- dados_pos$vendas_pos

```

In [133...

```

#-----
# Treinar floresta causal
#-----
cf_model <- causal_forest(X, Y, W)

#-----
# --- 1. ATE (Average Treatment Effect) ---
#-----
ate <- average_treatment_effect(cf_model)
cat("\n=== ATE (Average Treatment Effect) ===\n")
cat("Estimativa:", round(ate[1], 2), "\n")
cat("Erro Padrão:", round(ate[2], 2), "\n")
cat("IC 95%: [", round(ate[1] - 1.96*ate[2], 2), ",",
  round(ate[1] + 1.96*ate[2], 2), "]\n")

#-----
# --- 2. ITE (Individual Treatment Effects) ---
#-----
ite <- predict(cf_model)$predictions
dados_pos$ite <- ite

cat("\n=== ITE (Individual Treatment Effects) ===\n")
cat("Mínimo:", round(min(ite), 2), "\n")
cat("Q25:", round(quantile(ite, 0.25), 2), "\n")
cat("Mediana:", round(median(ite), 2), "\n")
cat("Média:", round(mean(ite), 2), "\n")
cat("Q75:", round(quantile(ite, 0.75), 2), "\n")
cat("Máximo:", round(max(ite), 2), "\n")
cat("Desvio Padrão:", round(sd(ite), 2), "\n")

```

=== ATE (Average Treatment Effect) ===

Estimativa: 6227.89

Erro Padrão: 483.78

IC 95%: [5279.68 , 7176.1]

=== ITE (Individual Treatment Effects) ===

Mínimo: 5588.29

Q25: 6075.84

Mediana: 6239.36

Média: 6260.89

Q75: 6397.2

Máximo: 6962.23

Desvio Padrão: 267.17

In [137...

```
#-----  
# --- 3. CATE por Quartis de Renda ---  
#-----  
dados_pos$quartil_renda <- cut(dados_pos$renda_per_capita,  
                               breaks = quantile(dados_pos$renda_per_capita,  
                                                  probs = c(0, 0.25, 0.5, 0.75,  
                                                  labels = c("Q1", "Q2", "Q3", "Q4"),  
                                                  include.lowest = TRUE)  
                                 
cate_renda <- dados_pos %>%  
  group_by(quartil_renda) %>%  
  summarise(  
    CATE = mean(ite),  
    SE = sd(ite) / sqrt(n()),  
    n = n()  
  )  
  
cat("\n=== CATE por Quartil de Renda ===\n")  
print(cate_renda)  
  
#-----  
# --- 4. CATE por Quartis de Internet ---  
#-----  
dados_pos$quartil_internet <- cut(dados_pos$penetracao_internet,  
                                  breaks = quantile(dados_pos$penetracao_intern  
                                                  probs = c(0, 0.25, 0.5, 0.7  
                                                  labels = c("Q1", "Q2", "Q3", "Q4"),  
                                                  include.lowest = TRUE)  
                                    
cate_internet <- dados_pos %>%  
  group_by(quartil_internet) %>%  
  summarise(  
    CATE = mean(ite),  
    SE = sd(ite) / sqrt(n()),  
    n = n()  
  )  
  
cat("\n=== CATE por Quartil de Internet ===\n")  
print(cate_internet)  
  
#-----  
# --- 5. Variable Importance ---  
#-----  
var_imp <- variable_importance(cf_model)  
var_names <- c("renda_per_capita", "penetracao_internet",  
               "n_concorrentes", "potencial_crescimento")
```

```
importance_df <- data.frame(
  Variavel = var_names,
  Importancia = var_imp
) %>%
  arrange(desc(Importancia))

cat("\n=== Variable Importance ===\n")
print(importance_df)
```

=== CATE por Quartil de Renda ===

A tibble: 4 × 4

	quartil_renda	CATE	SE	n
	<fct>	<dbl>	<dbl>	<int>
1	Q1	6143.	38.1	63
2	Q2	6183.	35.7	62
3	Q3	6301.	26.2	62
4	Q4	6416.	21.5	63

=== CATE por Quartil de Internet ===

A tibble: 4 × 4

	quartil_internet	CATE	SE	n
	<fct>	<dbl>	<dbl>	<int>
1	Q1	6549.	31.9	63
2	Q2	6131.	25.0	62
3	Q3	6105.	23.5	62
4	Q4	6254.	20.1	63

=== Variable Importance ===

	Variavel	Importancia
1	penetracao_internet	0.33213466
2	renda_per_capita	0.30202554
3	potencial_crescimento	0.28571761
4	n_concorrentes	0.08012218

In [138...

```
#-----
# --- 6. Diagnósticos do Modelo ---
#-----
cat("\n=== Diagnósticos do Modelo ===\n")
cat("Número de árvores:", cf_model$_num_trees, "\n")
cat("Tamanho da amostra:", nrow(X), "\n")
cat("Número de variáveis:", ncol(X), "\n")

#-----
# --- 7. Best Linear Projection ---
#-----
blp <- best_linear_projection(cf_model, X)
cat("\n=== Best Linear Projection ===\n")
print(summary(blp))
```

=== Diagnósticos do Modelo ===

Número de árvores: 2000

Tamanho da amostra: 250

Número de variáveis: 4

=== Best Linear Projection ===

Estimate	Std. Error	t value	Pr(> t)
Min. : -8269.9969	Min. : 1.629	Min. : -0.7057	Min. : 0.3347
1st Qu.: -0.3166	1st Qu.: 546.105	1st Qu.: -0.1944	1st Qu.: 0.4811
Median : 282.5575	Median : 3058.742	Median : 0.5174	Median : 0.6048
Mean : 1185.5919	Mean : 5616.723	Mean : 0.2204	Mean : 0.5744
3rd Qu.: 1585.0067	3rd Qu.: 11719.686	3rd Qu.: 0.5182	3rd Qu.: 0.6053
Max. : 12330.7090	Max. : 12757.454	Max. : 0.9665	Max. : 0.8460

```
In [ ]: # =====
# VISUALIZAÇÕES
# =====
# --- Plot 1: Distribuição dos ITEs ---
p1 <- ggplot(dados_pos, aes(x = ite)) +
  geom_histogram(bins = 30, fill = "steelblue", alpha = 0.7) +
  geom_vline(xintercept = mean(ite), color = "red", linetype = "dashed", size =
  labs(title = "Distribuição dos Efeitos Individuais (ITE)",
        x = "ITE", y = "Frequência") +
  theme_minimal()

# --- Plot 2: ITE vs Renda ---
p2 <- ggplot(dados_pos, aes(x = renda_per_capita, y = ite)) +
  geom_point(alpha = 0.5, color = "steelblue") +
  geom_smooth(method = "loess", color = "red", se = TRUE) +
  labs(title = "ITE vs Renda per Capita",
        x = "Renda per Capita", y = "ITE") +
  theme_minimal()

# --- Plot 3: ITE vs Internet ---
p3 <- ggplot(dados_pos, aes(x = penetracao_internet, y = ite)) +
  geom_point(alpha = 0.5, color = "steelblue") +
  geom_smooth(method = "loess", color = "red", se = TRUE) +
  labs(title = "ITE vs Penetração Internet",
        x = "Penetração Internet", y = "ITE") +
  theme_minimal()

# --- Plot 4: CATE por Quartil de Renda ---
p4 <- ggplot(cate_renda, aes(x = quartil_renda, y = CATE)) +
  geom_col(fill = "steelblue", alpha = 0.7) +
  geom_errorbar(aes(ymin = CATE - 1.96*SE, ymax = CATE + 1.96*SE),
                width = 0.2, color = "red") +
  labs(title = "CATE por Quartil de Renda",
        x = "Quartil de Renda", y = "CATE") +
  theme_minimal()

# --- Plot 5: Variable Importance ---
p5 <- ggplot(importance_df, aes(x = reorder(Variavel, Importancia), y = Importan
  geom_col(fill = "steelblue", alpha = 0.7) +
  coord_flip() +
  labs(title = "Importância das Variáveis",
        x = "", y = "Importância") +
  theme_minimal()

# --- Plot 6: Ranking de Lojas por ITE ---
top_bottom <- dados_pos %>%
```

```

arrange(desc(ite)) %>%
mutate(rank = row_number()) %>%
filter(rank <= 10 | rank > (n() - 10))

p6 <- ggplot(top_bottom, aes(x = reorder(loja_id, ite), y = ite,
                                fill = rank <= 10)) +

  geom_col() +
  coord_flip() +
  scale_fill_manual(values = c("steelblue", "coral"),
                    labels = c("Bottom 10", "Top 10")) +
  labs(title = "Top 10 e Bottom 10 Lojas por ITE",
        x = "Loja ID", y = "ITE", fill = "") +
  theme_minimal()

grid.arrange(p1, p2, p3, p4, p5, p6, ncol = 2)

```

Attaching package: 'gridExtra'

The following object is masked from 'package:bayesAB':





combine

The following object is masked from 'package:dplyr':

combine

`geom\_smooth()` using formula = 'y ~ x'

`geom\_smooth()` using formula = 'y ~ x'



Análise dos Resultados do Causal Forest

ATE (Average Treatment Effect)

Efeito médio da campanha: R\$ 6.227,89

- **Erro Padrão:** R\$ 483,78
- **Intervalo de Confiança 95%:** [R5.279, 68 — R 7.176,10]
- **Interpretação:** A campanha aumentou as vendas em média R\$ 6.228 por loja
- **Significância:** IC não cruza zero, efeito causal confirmado

ITE (Individual Treatment Effects)

Distribuição dos efeitos individuais:

Estatística	Valor (R\$)
Mínimo	5.588,29
Q25	6.075,84
Mediana	6.239,36
Média	6.260,89
Q75	6.397,20
Máximo	6.962,23
Desvio Padrão	267,17

Principais insights:

- Heterogeneidade moderada: amplitude de R\$ 1.374 (máx - mín)
- 50% das lojas têm efeito entre R6.076eR 6.397
- Desvio padrão de apenas 4,3% da média indica efeitos homogêneos
- Campanha funciona bem para todas as lojas

CATE por Quartil de Renda

Quartil	CATE (R\$)	SE	n	Perfil
Q1	6.143	38,1	63	Baixa renda
Q2	6.183	35,7	62	Média-baixa
Q3	6.301	26,2	62	Média-alta
Q4	6.416	21,5	63	Alta renda

Padrão identificado:

- Efeito cresce monotonicamente com a renda
- Diferença de R\$ 273 entre Q1 e Q4 (+4,4%)
- Lojas de alta renda respondem melhor à campanha
- Efeito positivo em todos os quartis

CATE por Quartil de Internet

Quartil	CATE (R\$)	SE	n	Perfil
Q1	6.549	31,9	63	Baixa penetração
Q2	6.131	25,0	62	Média-baixa
Q3	6.105	23,5	62	Média-alta
Q4	6.254	20,1	63	Alta penetração

Padrão identificado:

- Relação não-linear (U invertido)
- Maior efeito em lojas com baixa penetração de internet (Q1: R\$ 6.549)
- Menor efeito em Q2-Q3 (média penetração)
- Recuperação moderada em Q4 (alta penetração)
- Possível explicação: menor saturação digital em áreas de baixa internet

Variable Importance

Ranking de variáveis que explicam heterogeneidade do efeito:

Posição	Variável	Importância	%
1º	Penetração Internet	0,332	33,2%
2º	Renda per Capita	0,302	30,2%
3º	Potencial Crescimento	0,286	28,6%
4º	Nº Concorrentes	0,080	8,0%

Principais insights:

- Top 3 variáveis explicam 92% da heterogeneidade
- Internet e Renda são os principais moderadores (63,4% combinados)
- Concorrentes têm impacto marginal (8%)
- Segmentação futura deve priorizar renda e acesso à internet

Diagnósticos do Modelo

Configuração técnica:

- **Número de árvores:** 2.000
- **Tamanho da amostra:** 250 lojas
- **Número de variáveis:** 4 covariáveis
- **Avaliação:** Modelo robusto com estimativas estáveis

Best Linear Projection

Teste de linearidade dos efeitos:

- P-valores altos indicam ausência de interações lineares fortes
- Efeitos são relativamente homogêneos

- Heterogeneidade capturada é sutil, não detectável por regressão linear
- Confirma necessidade de método não-paramétrico (Causal Forest)

Análise das Visualizações

Distribuição dos ITEs

- Concentrada ao redor de R\$ 6.240 (linha vermelha)
- Distribuição aproximadamente normal
- Poucos outliers confirmam homogeneidade

ITE vs Renda per Capita

- Tendência crescente clara (linha vermelha LOESS)
- Maior dispersão em rendas baixas
- Efeito mais estável em rendas altas

ITE vs Penetração Internet

- Tendência decrescente até ~0,7, depois recupera
- Forma de "U invertido"
- Confirma análise CATE por quartil

CATE por Quartil de Renda

- Crescimento monotônico de Q1 para Q4
- Barras de erro pequenas indicam estimativas precisas

Importância das Variáveis

- Internet e Renda com magnitude similar
- Potencial Crescimento relevante
- Concorrentes pouco influente

Top 10 e Bottom 10 Lojas

- **Top 10:** ITEs entre R\$ 6.500-6.962 (alta renda, baixa internet)
- **Bottom 10:** ITEs entre R\$ 5.588-5.900 (baixa renda, alta internet)
- Amplitude de R\$ 1.374 entre melhor e pior desempenho

Síntese e Recomendações

Efeito global:

- Campanha gerou R\$ 6.228 em média (robusta e significativa)

Heterogeneidade:

- Moderada: efeitos variam 4,3% ao redor da média
- Renda: maior impacto em lojas de alta renda (+4,4%)
- Internet: padrão não-linear, maior efeito em baixa penetração

Drivers principais:

- Penetração de internet (33%)
- Renda per capita (30%)
- Potencial de crescimento (29%)

Implicações estratégicas:

- Campanha funciona bem universalmente
- Priorizar lojas de alta renda para maximizar ROI
- Explorar lojas com baixa internet (menor saturação digital)
- Segmentação por renda + internet otimiza alocação de recursos

System GMM (Blundell-Bond (1998))

Método para Painéis Dinâmicos com Endogeneidade

O Que é System GMM?

Método econométrico desenvolvido por Blundell & Bond (1998) que:

- Estima modelos dinâmicos em painel (com defasagens da variável dependente)
- Controla endogeneidade, efeitos fixos e causalidade reversa simultaneamente
- Combina equações em diferenças e em níveis (daí "System")
- Usa lags como instrumentos via GMM (Generalized Method of Moments)

Diferença vs métodos anteriores:

- System GMM: Lida com **persistência temporal** e **endogeneidade dinâmica**
- Permite vendas passadas como preditor sem viés

Intuição do System GMM

O System GMM resolve: **como estimar efeitos quando vendas de hoje dependem de vendas de ontem, e o tratamento pode ser endógeno?**

Modelo:

$$\text{vendas}_t = \alpha \cdot \text{vendas}_{t-1} + \beta \cdot \text{tratamento}_t + \mu_i + \lambda_t + \varepsilon_t$$

Onde:

- vendas_{t-1} : persistência (dinâmica)
- μ_i : efeitos fixos da loja
- λ_t : efeitos fixos de tempo

Construção do Estimador

Duas equações simultâneas:

Equação 1: Diferenças (elimina μ_i)

$$\Delta \text{vendas}_t = \alpha \cdot \Delta \text{vendas}_{t-1} + \beta \cdot \Delta \text{tratamento}_t + \Delta \varepsilon_t$$

Instrumentos: vendas_{t-2} , vendas_{t-3} , ... (em níveis)

Equação 2: Níveis (aumenta eficiência)

$$\text{vendas}_t = \alpha \cdot \text{vendas}_{t-1} + \beta \cdot \text{tratamento}_t + \mu_i + \lambda_t + \varepsilon_t$$

Instrumentos: $\Delta \text{vendas}_{t-1}$, $\Delta \text{vendas}_{t-2}$, ... (em diferenças)

System GMM = Equação 1 + Equação 2 estimadas conjuntamente.

Resultados Típicos

- Efeito causal após controlar dinâmica e endogeneidade
- *Responde*: "Qual o efeito da campanha dado o histórico de vendas?"
- Coeficiente da variável dependente defasada
- *Responde*: "Quanto das vendas atuais vêm de vendas passadas?"
- **Sargan/Hansen**: Valida instrumentos ($p > 0.10$ = bom)
- **AR(2)**: Ausência de autocorrelação ($p > 0.10$ = bom)

Testes diagnósticos

Persistência (α)

Efeito do tratamento (β)

Por Que System GMM é Diferente?

Não compara tratados vs controles como matching/SC.

Usa história temporal da própria unidade como fonte de identificação:

- Lags como instrumentos garantem exogeneidade
- Sistema de equações aumenta eficiência
- Controla endogeneidade dinâmica automaticamente

Vantagens

- Controle robusto de endogeneidade e causalidade reversa
- Modela persistência temporal explicitamente
- Mais eficiente que Difference GMM (Arellano-Bond)
- Testes de especificação validam modelo

Limitações

- Requer múltiplos períodos ($T \geq 3$, ideal $T \geq 5$)
- Melhor com N grande ($N > 50$)
- Proliferação de instrumentos (usar "collapse")

- Mais complexo que DiD

Quando Usar System GMM?

Use quando:

- Modelo é dinâmico (Y_{t-1} importa)
- Há endogeneidade ou causalidade reversa
- Múltiplos períodos ($T \geq 3$)
- Paineis com N moderado/grande

Não use quando:

- $T = 2$ (use DiD)
- Modelo estático (use FE/TWFE)
- N pequeno ($N < 50$)

Aplicação no Contexto da Campanha

Modelo:

$$\text{vendas}_{it} = \alpha \cdot \text{vendas}_{i,t-1} + \beta \cdot \text{tratamento}_{it} + \gamma' X_{it} + \mu_i + \lambda_t + \varepsilon_{it}$$

Por que System GMM:

- Vendas são persistentes (hoje depende de ontem)
- Campanha pode ter sido direcionada a lojas com boa performance
- Temos 24 períodos (suficiente para múltiplos lags)

Resultado esperado:

- **β** : Efeito causal da campanha controlando dinâmica
- **α** : Persistência das vendas
- **Testes**: Validam especificação

In [144...

```
# =====
# Preparar Dados
# =====

# 1. Preparar dados em formato painel
dados_panel <- pdata.frame(dados, index = c("loja_id", "periodo"))

# 2. Criar variável de tratamento dinâmica
#   treated = 1 se está no período pós-tratamento E é do grupo tratado
dados_panel$treated <- dados_panel$tratamento * dados_panel$pos
```

In [145...

```
# =====
# MODELO 1: System GMM Blundell-Bond
# =====
cat("\n\n== SYSTEM GMM (Blundell-Bond) ==\n\n")

# Mais eficiente quando T é pequeno
```

```
# Combina equações em diferenças E em níveis

modelo_sys_gmm <- pgmm(
  vendas ~ lag(vendas, 1) + treated +
    renda_per_capita + penetracao_internet + n_concorrentes |
    lag(vendas, 2:4) + lag(treated, 1:3), # mais instrumentos
  data = dados_panel,
  effect = "twoways",
  model = "twosteps",
  transformation = "ld"
)

summary(modelo_sys_gmm, robust = TRUE)

efeito_sys_gmm <- coef(modelo_sys_gmm)["treated"]
cat("\nEfeito causal (System GMM):", round(efeito_sys_gmm, 2), "\n")
```

=== SYSTEM GMM (Blundell-Bond) ===

Warning messages:

```
1: In pgmm(vendas ~ lag(vendas, 1) + treated + renda_per_capita + penetracao_inte
rnet + :
  the first-step matrix is singular, a general inverse is used
2: In pgmm(vendas ~ lag(vendas, 1) + treated + renda_per_capita + penetracao_inte
rnet + :
  the second-step matrix is singular, a general inverse is used
Warning message:
In vcovHC.pgmm(object) : a general inverse is used
Efeito causal (System GMM): 6378.91
```

In [147... summary(modelo_sys_gmm, robust = TRUE)

Warning message:

```
In vcovHC.pgmm(object) : a general inverse is used
```

Out[147... Twoways effects Two-steps model System GMM

Call:

```
pgmm(formula = vendas ~ lag(vendas, 1) + treated + renda_per_capita +  
      penetracao_internet + n_concorrentes | lag(vendas, 2:4) +  
      lag(treated, 1:3), data = dados_panel, effect = "twoways",  
      model = "twosteps", transformation = "ld")
```

Balanced Panel: n = 250, T = 24, N = 6000

Number of Observations Used: 11250

Residuals:

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-10636.21	-1791.76	-12.85	-10.57	1753.84	11505.31

Coefficients:

	Estimate	Std. Error	z-value	Pr(> z)
lag(vendas, 1)	-3.0065e-03	2.6072e-02	-0.1153	0.9082
treated	6.3789e+03	4.7361e+02	13.4687	< 2.2e-16 ***
renda_per_capita	1.1550e+01	3.6611e-01	31.5475	< 2.2e-16 ***
penetracao_internet	2.8008e+04	3.2641e+03	8.5808	< 2.2e-16 ***
n_concorrentes	-1.9769e+03	2.4726e+02	-7.9950	1.296e-15 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Sargan test: chisq(173) = 90.52462 (p-value = 1)

Autocorrelation test (1): normal = -11.9795 (p-value = < 2.22e-16)

Autocorrelation test (2): normal = 0.9189038 (p-value = 0.35815)

Wald test for coefficients: chisq(5) = 6910.13 (p-value = < 2.22e-16)

Wald test for time dummies: chisq(22) = 5380.018 (p-value = < 2.22e-16)

In [146...

```
# =====  
# TESTES DE DIAGNÓSTICO  
# =====  
cat("\n\n=== TESTES DE VALIDADE GMM ===\n")  
  
# 1. Teste de Sargan/Hansen (sobre-identificação)  
# H0: Instrumentos são válidos  
# Se p > 0.05 → instrumentos OK  
cat("\n1. Teste de Hansen (validade dos instrumentos):\n")  
cat(" H0: Instrumentos são exógenos\n")  
cat(" Se p > 0.10 → Instrumentos válidos \n")  
  
# 2. Teste de Autocorrelação Arellano-Bond  
# AR(1): deve rejeitar (correlação em diferenças é esperada)  
# AR(2): NÃO deve rejeitar (sem correlação de 2ª ordem)  
cat("\n2. Teste de Autocorrelação:\n")  
cat(" AR(1): p < 0.05 esperado (OK)\n")  
cat(" AR(2): p > 0.05 necessário (modelo válido) \n")
```

=== TESTES DE VALIDADE GMM ===

1. Teste de Hansen (validade dos instrumentos):

H0: Instrumentos são exógenos

Se p > 0.10 → Instrumentos válidos

2. Teste de Autocorrelação:

AR(1): p < 0.05 esperado (OK)

AR(2): p > 0.05 necessário (modelo válido)

Análise dos Resultados: System GMM (Blundell-Bond 1998)

Efeito Causal da Campanha

Efeito estimado: R\$ 6.378,91

- **Interpretação:** A campanha aumentou vendas em R\$ 6.379 por loja, controlando para:
 - Persistência temporal (vendas passadas)
 - Endogeneidade do tratamento
 - Efeitos fixos de loja e tempo
- **Altamente significativo:** $p < 0.001$
- **Resultado robusto:** Similar aos outros métodos (ATE = R6.012 no CF, R 6.228 no CF puro)

Coeficientes Estimados

Variável	Coeficiente	Erro Padrão	z-value	p-value	Sig
lag1(vendas)	-0,003	0,026	-0,12	0,908	.
treated	6.378,91	473,61	13,47	<0,001	***
renda_per_capita	11,55	0,37	31,55	<0,001	***
penetracao_internet	28.008	3.264	8,58	<0,001	***
n_concorrentes	-1.976,9	247,3	-8,00	<0,001	***

Interpretação dos Coeficientes

1. lag(vendas, 1): -0,003 (não significativo)

- **Esperado:** Persistência positiva (vendas passadas predizem vendas atuais)
- **Resultado:** Coeficiente próximo de zero e não significativo
- **Interpretação:** Após controlar para covariáveis e efeitos fixos, vendas passadas não têm efeito incremental
- **Possível razão:** As covariáveis (renda, internet) já capturam toda a persistência

2. treated: 6.378,91

- **Efeito da campanha:** R\$ 6.379 de aumento nas vendas
- **Altamente significativo:** $z = 13,47$
- **Controlado para:** Dinâmica temporal, endogeneidade, efeitos fixos

3. renda_per_capita: 11,55

- **Interpretação:** Cada R1 de aumento na renda aumenta as vendas em R 11,55
- **Exemplo:** Loja em área com renda R100 maior $\rightarrow +R 1.155$ em vendas

4. penetracao_internet: 28.008

- **Interpretação:** Cada 1 ponto percentual de aumento na penetração de internet aumenta vendas em R\$ 28.008
- **Exemplo:** Aumento de 0,1 (10%) na internet → +R\$ 2.801 em vendas

5. n_concorrentes: -1.976,9

- **Interpretação:** Cada concorrente adicional reduz vendas em R\$ 1.977
- **Competição:** Efeito negativo esperado da concorrência

Testes Diagnósticos

1. Teste de Sargan/Hansen (Validade dos Instrumentos)

- Sargan test: $\chi^2(173) = 90.52$, p-value = 1.000

Interpretação:

- H_0 : Instrumentos são exógenos (válidos)
- $p = 1.000$: Não rejeita H_0 → Instrumentos parecem válidos
- *Atenção:* p-value = 1 é extremamente alto, pode indicar instrumentos fracos ou sobre-identificação

Diagnóstico: Instrumentos válidos, mas teste pode estar com pouco poder

2. Teste de Autocorrelação

$AR(1)$: normal = -11,98, $p < 0,001$ ✓

- *Esperado:* $p < 0,05$ (OK)
- *Interpretação:* Correlação de 1ª ordem nos resíduos em diferenças (normal)

$AR(2)$: normal = 0,92, $p = 0,358$ ✓✓

- *Crítico:* $p > 0,05$ necessário
- *Interpretação:* **Sem autocorrelação de 2ª ordem** → Modelo bem especificado!

Diagnóstico: Modelo passa nos testes de autocorrelação

3. Teste de Wald

Coeficientes: $\chi^2(5) = 6910,13$, $p < 0,001$

- **Interpretação:** Coeficientes conjuntamente significativos

Time dummies: $\chi^2(22) = 5380,02$, $p < 0,001$

- *Interpretação:* Efeitos fixos de tempo conjuntamente significativos
- *Conclusão:* Choques temporais comuns são importantes

Avisos (Warnings)

- Warning: the first-step matrix is singular, a general inverse is used
- Warning: the second-step matrix is singular, a general inverse is used

O que significa:

- Matriz de covariância dos instrumentos é singular (não-invertível)
- Algoritmo usou inversa generalizada (pseudo-inversa)

Resumo e Diagnóstico Final

Efeito Causal

- R\$ 6.378,91 (robusto, significativo, consistente com outros métodos)

Validade do Modelo

- *AR(2)*: $p = 0,358$ (modelo bem especificado)
- *Sargan*: $p = 1,000$ (válido, mas suspeito de instrumentos fracos)
- *Matriz singular*: Problema de identificação

Persistência Temporal

- *lag(vendas)*: Não significativo (inesperado, mas pode ser válido se covariáveis capturam toda persistência)

Covariáveis

Todas altamente significativas e com sinais corretos:

- Renda: +
- Internet: +
- Concorrentes: -

Conclusão

Resultado principal:

- Campanha gerou R\$ 6.379 de aumento nas vendas
- Efeito robusto e consistente com métodos anteriores

Qualidade do modelo:

- Passa no teste de autocorrelação *AR(2)*
- Instrumentos válidos (mas possivelmente fracos)
- Avisos sobre matriz singular sugerem ajuste da especificação.

O Que São Meta-Learners?

Meta-Learners são estratégias para usar algoritmos de machine learning (como XGBoost, Random Forest, Neural Networks) para estimar **efeitos causais heterogêneos**.

A palavra "meta" vem do fato de que **não são algoritmos em si**, mas sim **frameworks** que dizem **como** usar algoritmos de ML para responder perguntas causais.

Cada Meta-Learner tem uma **filosofia diferente** sobre como abordar o problema, resultando em estimativas potencialmente diferentes.

S-Learner

Como Funciona:

- 1º Treina **um único modelo** que aprende a prever as vendas usando todas as variáveis, incluindo se a loja recebeu tratamento ou não.
- 2º Com o Modelo treinado podemos prever os valores das vendas para todas as lojas (quando a dummy de tratamento é 1 para todas as lojas e 0 para todas as lojas)
- 3º Calculamos a diferença das vendas previstas pelo modelo quando todos são tratados e quando todos são controles, a diferença é o efeito causal
- O modelo aprende padrões como: *"Lojas com alta renda vendem mais"* e *"Lojas que receberam campanha vendem X a mais"*.

Vantagens:

- **Simples:** Um modelo apenas
- **Eficiente:** Usa todos os dados juntos
- **Rápido:** Treina mais rápido que outros métodos

Desvantagens:

- **Regularization bias:** Se o algoritmo de ML "regulariza" muito (penaliza complexidade), pode subestimar o efeito do tratamento
- **Tratamento como feature comum:** O modelo pode não dar atenção suficiente à variável de tratamento

Quando Usar:

- Prototipagem rápida
- Quando o efeito é relativamente uniforme
- Como baseline para comparação

T-Learner

Como Funciona:

- 1º Sepamos os dados somente os tratados e somente os controles
- 2º treina **dois modelos separados**, um para lojas tratadas e outro para lojas controle. Cada grupo aprende seus próprios padrões."
- 3º Utilizamos o modelo treinado somente nos tratados para prever as vendas do grupo de controle, e o modelo treinado com dados de controle para prever as vendas do grupo tratado
- 4º Calculamos a diferença das vendas previstas pelo modelo e obtemos o efeito causal

Vantagens:

- **Sem regularization bias:** Cada modelo é livre para aprender sem penalizar o tratamento
- **Flexível:** Permite padrões completamente diferentes entre grupos
- **Interpretável:** Fácil entender o que cada modelo faz

Desvantagens:

- **Desbalanceamento:** Se há muito mais controles que tratados (ou vice-versa), um modelo aprende com poucos dados
- **Dois modelos:** Mais complexo que S-Learner
- **Extrapolação:** Cada modelo precisa fazer previsões para lojas "do outro grupo"

Quando Usar:

- Quando tratados e controles parecem muito diferentes
 - Dados balanceados (número similar de tratados e controles)
 - Quando quer entender padrões específicos de cada grupo
-

X-Learner

Como Funciona:

Etapa 1 - Modelos Base: *(Igual ao T-learn)*

- 1º Sepamos os dados somente os tratados e somente os controles
- 2º Treinamos **dois modelos separados** (μ_0 para controles e μ_1 para tratados)

Etapa 2 - Imputação de Contrafactuais:

- 3º Usamos μ_0 para prever vendas dos **tratados** se fossem controles (**Igual ao T-learn**)

- 4º Usamos μ_1 para prever vendas dos **controles** se fossem tratados (**Igual ao T-learn**)
- 5º Calculamos **pseudo-efeitos individuais**: *(extraí somente o desvio entre real - previsto)*
 - Para cada tratado: **Efeito = Venda Real - Venda Prevista como Controle**
 - Para cada controle: **Efeito = Venda Prevista como Tratado - Venda Real**

Etapa 3 - Modelos de Efeito: Com os desvios = (real - previsto), o X-Learner estima mais dois modelos utilizando os desvios como variável dependente, esses modelos tem como objetivo explicar como o efeito varia com as características X.

- 6º Treinamos **dois novos modelos** (τ_0 e τ_1) para prever esses pseudo-efeitos:
 - τ_0 aprende efeitos usando dados de **controles**
 - τ_1 aprende efeitos usando dados de **tratados**

Etapa 4 - Combinação Final:

- 7º Estimamos o propensity score $e(X)$ = probabilidade de tratamento
- 8º Combinamos τ_0 e τ_1 ponderando pelo propensity: *(aqui é basicamente uma média ponderada fixa)* **ITE = (peso_do_controle x efeito_dos_controles) + (peso_do_tratado x efeito_dos_tratados)**
 - Damos **mais peso** ao modelo treinado no grupo com **mais dados**

Vantagens:

- **Ótimo com desbalanceamento:** Funciona bem mesmo com 80% tratados e 20% controles
- **Usa toda informação:** Combina múltiplos modelos de forma inteligente
- **Reduz variância:** Estimativas mais estáveis que T-Learner

Desvantagens:

- **Complexidade:** 4 modelos + propensity score
- **Difícil de interpretar:** Muitas etapas intermediárias
- **Computacionalmente caro:** Mais lento que S/T-Learner

Quando Usar:

- **Desbalanceamento severo** (ex: 80% tratados, 20% controles)
- Quando quer extrair máxima informação dos dados
- Decisões importantes que justificam complexidade adicional

Como Funciona:

Etapa 1 - Estimar Propensity Score:

- 1º Treinamos um modelo de **classificação** $e(X)$ para prever a probabilidade de tratamento dado X

Etapa 2 - Modelos de Outcome:

- 2º Separamos dados em tratados e controles (*Igual ao T-learn*)
- 3º Treinamos **dois modelos de regressão**: (*Igual ao T-learn*)
 - $\mu_0(X)$: Prever vendas dos **controles**
 - $\mu_1(X)$: Prever vendas dos **tratados**

Etapa 3 - Combinar via AIPW (Augmented IPW):

- 4º Para cada loja, calculamos o ITE usando a **fórmula AIPW**:

$$\begin{aligned} \text{ITE}(X) = & \\ & (1 - e(X)) \times [\mu_1(X) - Y] \quad \leftarrow \text{peso_do_tratado} \quad \times \\ & \text{erro_dos_tratados} \\ & + e(X) \times [Y - \mu_0(X)] \quad \leftarrow \text{peso_do_controle} \quad \times \\ & \text{erro_dos_controles} \\ & + [\mu_1(X) - \mu_0(X)] \quad \leftarrow \text{diferença_bruta_dos_modelos} \end{aligned}$$

onde:

$W = 1$ se tratado, 0 se controle

$e(X)$ = propensity score (limitado entre 0.05 e 0.95)

$\mu_1(X)$ = previsão para tratados

$\mu_0(X)$ = previsão para controles

Etapa 4 - Interpretação:

- 5º A **Parte 1** é o efeito via outcome regression (como T-Learner)
- 6º A **Parte 2** corrige erros do modelo μ_1 usando pesos IPW nos tratados
- 7º A **Parte 3** corrige erros do modelo μ_0 usando pesos IPW nos controles
- 8º Se **qualquer um** (outcome models OU propensity) está correto → ITE está correto

Vantagens:

- **Double Robustness**: Proteção contra má especificação - precisa de apenas UMA das duas estratégias correta
- **Fundamentação teórica forte**: Propriedades estatísticas bem estudadas
- **Combinação inteligente**: Usa informação de outcome E propensity
- **Decomposição clara**: Vemos contribuição de cada componente

Desvantagens:

- **Sensível a propensity extremo**: Se $e(X)$ muito perto de 0 ou 1, pesos IPW explodem
- **Requer trimming**: Precisa limitar propensity (ex: 0.05 a 0.95)

- **Variância maior:** Se overlap é fraco, IPW adiciona ruído
- **3 modelos:** Mais complexo que S/T-Learner

Quando Usar:

- Quer **máxima robustez** contra erros de especificação
- Bom overlap (propensity não extremo)
- Interesse em propriedades teóricas fortes
- Pode estimar propensity score razoavelmente bem
- Decisões críticas que exigem validação teórica

U-Learner

Como Funciona:

Abordagem 1 - Transformação Uplift:

- 1º Transformamos a variável de tratamento: $Z = 2 \times W - 1$ (converte 0/1 em -1/+1)
 - Tratados ($W=1$) ficam $Z = +1$
 - Controles ($W=0$) ficam $Z = -1$
- 2º Criamos o target transformado: $Y_{\text{uplift}} = Z \times Y$
 - Tratados: $Y_{\text{uplift}} = +\text{Vendas}$
 - Controles: $Y_{\text{uplift}} = -\text{Vendas}$
- 3º Criamos **features aumentadas**: X original + $X \times Z$ (interações com tratamento)
- 4º Treinamos **um único modelo** para prever Y_{uplift} usando as features aumentadas
- 5º Para calcular ITE, predizemos usando $Z = +1$ para todos

Abordagem 2 - Interações Explícitas (mais comum):

- 1º Criamos **features com interações**: $[W, X, W \times X_1, W \times X_2, \dots, W \times X_n]$
 - Exemplo: [tratamento, renda, internet, tratamento×renda, tratamento×internet, ...]
- 2º Treinamos **um único modelo** para prever vendas Y usando essas features
- 3º Para calcular ITE de cada loja:
 - Predizemos com $W=1$ (como tratado)
 - Predizemos com $W=0$ (como controle)
 - $\text{ITE} = \text{Predição}(W=1) - \text{Predição}(W=0)$

A diferença chave:

- O modelo aprende **explicitamente** como o tratamento **modera** o efeito de cada variável
- Termos de interação ($W \times \text{renda}$, $W \times \text{internet}$) capturam: "O efeito da campanha é diferente para lojas ricas vs pobres?"

Vantagens:

- **Simples:** Um modelo apenas (como S-Learner)
- **Foco em uplift:** Aprende diretamente o incremento, não outcomes separados

- **Interações explícitas:** Captura automaticamente como tratamento modera covariáveis
- **Conecta com marketing:** Base da literatura clássica de uplift modeling

Desvantagens:

- **Transformação confusa:** Abordagem 1 ($Z = 2W - 1$) é menos intuitiva
- **Menos estudado:** Teoria menos desenvolvida que S/T/X/DR
- **Não tem double robustness:** Como S-Learner, pode sofrer com regularization bias
- **Requer especificar interações:** Precisa decidir quais $W \times X$ incluir

Quando Usar:

- Quer simplicidade (1 modelo) mas capturar heterogeneidade
- Background em uplift modeling (marketing/CRM)
- Suspeita que **efeito é moderado** por covariáveis (ex: campanha funciona diferente para ricos vs pobres)
- Quer interpretação de quais features **interagem** com tratamento

Comparação Completa: Todos os Meta-Learners

Método	Modelos	Filosofia	Melhor Para
S-Learner	1	Tratamento = feature	Rapidez, uniformidade
T-Learner	2	Grupos separados	Grupos diferentes, balanceamento
X-Learner	4 + e	Imputação + ponderação	Desbalanceamento severo
DR-Learner	3	Outcome + IPW	Robustez teórica
U-Learner	1	Interações explícitas	Moderação por covariáveis

Na Prática: O Que Fazer?

1. **Sempre rode TODOS os 4 métodos**
2. Compare os resultados
3. Se convergem (ATEs similares) → Confiança alta
4. Se divergem → Investigue:
 - Checar overlap (propensity extremo?)
 - Checar balanceamento (muitos tratados vs controles?)
 - Checar fit dos modelos (R^2 bom?)
5. Use consenso entre métodos para decisão final

Lembre-se: A verdade está na **triangulação** entre múltiplas abordagens, não em um método único!

Intalar Reticulate para rodar python

```
In [ ]: # Instalar reticulate
# install.packages("reticulate")

# Criar ambiente virtual Python
# library(reticulate)
# virtualenv_create("r-econml")
# use_virtualenv("r-econml")

# Instalar pacotes Python necessários
# py_install(c("econml", "numpy", "pandas", "scikit-learn"),
#            envname = "r-econml")
```

Importar bibliotecas python

```
In [5]: library(reticulate)
use_virtualenv("r-econml", required = TRUE)

# Verificar se está usando o ambiente correto
py_config()

# Importar bibliotecas Python
np <- import("numpy")
pd <- import("pandas")
econml <- import("econml")
sklearn_ensemble <- import("sklearn.ensemble")

cat("Python e EconML carregados com sucesso!\n")
```

Python e EconML carregados com sucesso!

```
In [7]: #-----
# --- PREPARAR DADOS (SEM PESOS) ---
#-----

cat("\n=== Preparando Dados ===\n")

dados_econml <- dados %>% # MUDEI AQUI
  filter(pos == 1) %>%
  select(
    loja_id,
    vendas,
    tratamento,
    renda_per_capita,
    penetracao_internet,
    n_concorrentes,
    potencial_crescimento
  )

cat("Número de observações:", nrow(dados_econml), "\n")

# Separar em matrizes
X <- as.matrix(dados_econml %>%
  select(renda_per_capita, penetracao_internet,
         n_concorrentes, potencial_crescimento))

Y <- dados_econml$vendas
W <- dados_econml$tratamento
```

```
# Converter para numpy arrays
X_np <- np$array(X)
Y_np <- np$array(Y)
W_np <- np$array(as.integer(W))

cat("\nDimensões:\n")
cat("X:", dim(X), "\n")
cat("Y:", length(Y), "\n")
cat("W:", length(W), "| Tratados:", sum(W), "| Controles:", sum(1-W), "\n")
```

=== Preparando Dados ===

Número de observações: 3000

Dimensões:

X: 3000 4

Y: 3000

W: 3000 | Tratados: 1860 | Controles: 1140

```
In [8]: #-----
# --- CONFIGURAR BASE LEARNERS ---
#-----

cat("\n=== Configurando Base Learners ===\n")

base_learner <- sklearn_ensemble$GradientBoostingRegressor(
  n_estimators = 100L,
  max_depth = 6L,
  learning_rate = 0.1,
  random_state = 123L
)

propensity_learner <- sklearn_ensemble$GradientBoostingClassifier(
  n_estimators = 100L,
  max_depth = 4L,
  learning_rate = 0.1,
  random_state = 123L
)

cat("Base learners configurados\n")
```

=== Configurando Base Learners ===

Base learners configurados

S-LEARNER

```
In [9]: #-----
# --- S-LEARNER ---
#-----

cat("\n=== [1/5] S-Learner ===\n")

SLearner <- import("econml.metalearners")$SLearner
s_learner <- SLearner(overall_model = base_learner)
s_learner$fit(Y = Y_np, T = W_np, X = X_np)

ate_s <- s_learner$ate(X = X_np)
ite_s <- s_learner$effect(X = X_np)

cat("S-Learner treinado | ATE:", round(ate_s, 2), "\n")
```

```
=== [1/5] S-Learner ===  
S-Learner treinado | ATE: 3790.29
```

T-LEARNER

```
In [10]: #-----  
# --- T-LEARNER ---  
#-----  
  
cat("\n=== [2/5] T-Learner ===\n")  
  
TLearner <- import("econml.metalearners")$TLearner  
t_learner <- TLearner(models = list(base_learner, base_learner))  
t_learner$fit(Y = Y_np, T = W_np, X = X_np)  
  
ate_t <- t_learner$ate(X = X_np)  
ite_t <- t_learner$effect(X = X_np)  
  
cat("T-Learner treinado | ATE:", round(ate_t, 2), "\n")
```

```
=== [2/5] T-Learner ===  
T-Learner treinado | ATE: 6115.55
```

X-LEARNER

```
In [11]: #-----  
# --- X-LEARNER ---  
#-----  
  
cat("\n=== [3/5] X-Learner ===\n")  
  
XLearner <- import("econml.metalearners")$XLearner  
x_learner <- XLearner(  
  models = list(base_learner, base_learner),  
  cate_models = list(base_learner, base_learner),  
  propensity_model = propensity_learner  
)  
x_learner$fit(Y = Y_np, T = W_np, X = X_np)  
  
ate_x <- x_learner$ate(X = X_np)  
ite_x <- x_learner$effect(X = X_np)  
  
cat("X-Learner treinado | ATE:", round(ate_x, 2), "\n")
```

```
=== [3/5] X-Learner ===  
X-Learner treinado | ATE: 6486.46
```

DR-LEARNER

```
In [12]: #-----  
# --- DR-LEARNER ---  
#-----  
  
cat("\n=== [4/5] DR-Learner ===\n")  
  
DRLearner <- import("econml.dr")$DRLearner  
dr_learner <- DRLearner(  
  model_propensity = propensity_learner,
```

```

    model_regression = base_learner,
    model_final = base_learner
  )
dr_learner$fit(Y = Y_np, T = W_np, X = X_np)

ate_dr <- dr_learner$ate(X = X_np)
ite_dr <- dr_learner$effect(X = X_np)

cat("DR-Learner | ATE:", round(ate_dr, 2), "\n")

```

```

=== [4/5] DR-Learner ===
DR-Learner | ATE: 4073.62

```

U-LEARNER

```

In [13]: #-----
# --- 5. U-LEARNER (IMPLEMENTAÇÃO MANUAL) ---
#-----

cat("\n=== [5/5] U-Learner (Interações) ===\n")

# Criar features com interações W×X
X_interact <- cbind(
  W,                # Tratamento
  X,                # Features originais
  W * X[, 1],       # W × renda
  W * X[, 2],       # W × internet
  W * X[, 3],       # W × concorrentes
  W * X[, 4]        # W × potencial
)

colnames(X_interact) <- c(
  "W", "renda", "internet", "concorrentes", "potencial",
  "W_x_renda", "W_x_internet", "W_x_concorrentes", "W_x_potencial"
)

# Converter para numpy
X_interact_np <- np$array(X_interact)

# Treinar modelo com interações
u_model <- sklearn_ensemble$GradientBoostingRegressor(
  n_estimators = 100L,
  max_depth = 6L,
  learning_rate = 0.1,
  random_state = 123L
)

u_model$fit(X_interact_np, Y_np)

# Predizer ITE via diferença marginal
# ITE = f(W=1, X) - f(W=0, X)
X_w1 <- cbind(1, X, 1 * X[, 1], 1 * X[, 2], 1 * X[, 3], 1 * X[, 4])
X_w0 <- cbind(0, X, 0 * X[, 1], 0 * X[, 2], 0 * X[, 3], 0 * X[, 4])

pred_w1 <- u_model$predict(np$array(X_w1))
pred_w0 <- u_model$predict(np$array(X_w0))

ite_u <- pred_w1 - pred_w0
ate_u <- mean(ite_u)

```

```
cat(" U-Learner | ATE:", round(ate_u, 2), "\n")
```

```
=== [5/5] U-Learner (Interações) ===  
U-Learner | ATE: 5290.16
```

```
In [15]: #-----  
# --- CONSOLIDAR RESULTADOS ---  
#-----  
  
resultados_ate <- tibble(  
  Metodo = c("S-Learner", "T-Learner", "X-Learner", "DR-Learner", "U-Learner"),  
  ATE = c(ate_s, ate_t, ate_x, ate_dr, ate_u)  
)  
  
cat("\n=== Resultados Consolidados ===\n")  
print(resultados_ate)  
  
#-----  
# --- CONSOLIDAR E COMPARAR ---  
#-----  
  
efeito_verdadeiro <- 6012.28  
  
resultados_ate <- tibble(  
  Metodo = c("S-Learner", "T-Learner", "X-Learner", "DR-Learner", "U-Learner"),  
  ATE = c(ate_s, ate_t, ate_x, ate_dr, ate_u)  
)  
  
resultados_completo <- resultados_ate %>%  
  mutate(  
    Efeito_Verdadeiro = efeito_verdadeiro,  
    Viés = ATE - efeito_verdadeiro,  
    Viés_Abs = abs(Viés),  
    Erro_Pct = (Viés / efeito_verdadeiro) * 100,  
    Erro_Abs_Pct = abs(Erro_Pct)  
  ) %>%  
  arrange(Viés_Abs)  
  
print(resultados_completo)  
  
melhor_metodo <- resultados_completo$Metodo[1]  
menor_erro <- resultados_completo$Viés_Abs[1]  
menor_erro_pct <- resultados_completo$Erro_Abs_Pct[1]  
  
cat("\n=== MELHOR MÉTODO ===\n")  
cat("Método:", melhor_metodo, "\n")  
cat("Erro absoluto:", round(menor_erro, 2), "\n")  
cat("Erro percentual:", round(menor_erro_pct, 2), "%\n")  
  
ranking <- resultados_completo %>%  
  select(Metodo, ATE, Viés, Erro_Pct) %>%  
  mutate(  
    Ranking = row_number(),  
    Status = case_when(  
      abs(Erro_Pct) < 5 ~ "Excelente",  
      abs(Erro_Pct) < 10 ~ "Bom",  
      abs(Erro_Pct) < 20 ~ "Aceitável",  
      TRUE ~ "Alto"  
    )  
  )
```

```
)

print(ranking)

=== Resultados Consolidados ===
# A tibble: 5 × 2
  Metodo      ATE
  <chr>      <dbl>
1 S-Learner  3790.
2 T-Learner  6116.
3 X-Learner  6486.
4 DR-Learner 4074.
5 U-Learner  5290.
# A tibble: 5 × 7
  Metodo      ATE Efeito_Verdadeiro Viés Viés_Abs Erro_Pct Erro_Abs_Pct
  <chr>      <dbl>      <dbl> <dbl> <dbl> <dbl> <dbl>
1 T-Learner  6116.      6012.  103.  103.  1.72  1.72
2 X-Learner  6486.      6012.  474.  474.  7.89  7.89
3 U-Learner  5290.      6012. -722.  722. -12.0  12.0
4 DR-Learner 4074.      6012. -1939. 1939. -32.2  32.2
5 S-Learner  3790.      6012. -2222. 2222. -37.0  37.0

=== MELHOR MÉTODO ===
Método: T-Learner
Erro absoluto: 103.27
Erro percentual: 1.72 %
# A tibble: 5 × 6
  Metodo      ATE Viés Erro_Pct Ranking Status
  <chr>      <dbl> <dbl> <dbl> <int> <chr>
1 T-Learner  6116.  103.  1.72     1 Excelente
2 X-Learner  6486.  474.  7.89     2 Bom
3 U-Learner  5290. -722. -12.0     3 Aceitável
4 DR-Learner 4074. -1939. -32.2     4 Alto
5 S-Learner  3790. -2222. -37.0     5 Alto
```

```
In [16]: #-----
# --- MÉTRICAS DE PERFORMANCE ---
#-----

cat("\n===== \n")
cat("MÉTRICAS DE PERFORMANCE\n")
cat("===== \n")

metricas <- data.frame(
  Metodo = resultados_completo$Metodo,
  MAE = abs(resultados_completo$Viés), # Mean Absolute Error
  MAPE = abs(resultados_completo$Erro_Pct), # Mean Absolute Percentage Error
  Acurácia = 100 - abs(resultados_completo$Erro_Pct)
) %>%
  arrange(MAE)

print(metricas)

# Consenso entre métodos
cat("\n===== \n")
cat("CONSENSO ENTRE MÉTODOS\n")
cat("===== \n")

consenso <- mean(resultados_completo$ATE)
sd_consenso <- sd(resultados_completo$ATE)
```

```

cv_consenso <- (sd_consenso / consenso) * 100

cat("Média dos 5 métodos:", round(consenso, 2), "\n")
cat("Desvio padrão:", round(sd_consenso, 2), "\n")
cat("Coeficiente de variação:", round(cv_consenso, 2), "%\n")
cat("Efeito verdadeiro:", round(efeito_verdadeiro, 2), "\n")
cat("Diferença (consenso - verdadeiro):", round(consenso - efeito_verdadeiro, 2))

if (abs(consenso - efeito_verdadeiro) < sd_consenso) {
  cat("Efeito verdadeiro está dentro do intervalo de consenso\n")
} else {
  cat("Efeito verdadeiro está fora do intervalo de consenso\n")
}

```

=====

MÉTRICAS DE PERFORMANCE

```

=====
          Metodo      MAE      MAPE  Acurácia
1  T-Learner   103.2688   1.717631  98.28237
2  X-Learner   474.1760   7.886791  92.11321
3  U-Learner   722.1158  12.010682  87.98932
4 DR-Learner  1938.6564  32.244945  67.75505
5  S-Learner  2221.9899  36.957525  63.04247

```

=====

CONSENSO ENTRE MÉTODOS

```

=====
Média dos 5 métodos: 5151.22
Desvio padrão: 1198.48
Coeficiente de variação: 23.27 %
Efeito verdadeiro: 6012.28
Diferença (consenso - verdadeiro): -861.06
Efeito verdadeiro está dentro do intervalo de consenso

```

```

In [17]: #-----
# --- CATE POR SUBGRUPOS ---
#-----

# Por Quartil de Renda
dados_econml$quartil_renda <- cut(
  dados_econml$renda_per_capita,
  breaks = quantile(dados_econml$renda_per_capita, c(0, 0.25, 0.5, 0.75, 1)),
  labels = c("Q1", "Q2", "Q3", "Q4"),
  include.lowest = TRUE
)

cate_renda <- dados_econml %>%
  group_by(quartil_renda) %>%
  summarise(
    n = n(),
    S_Learner = mean(ite_s),
    T_Learner = mean(ite_t),
    X_Learner = mean(ite_x),
    DR_Learner = mean(ite_dr),
    U_Learner = mean(ite_u),
    .groups = "drop"
  )

cat("\n=== CATE por Quartil de Renda ===\n")
print(cate_renda)

```



```

# Por Quartil de Internet
dados_econml$quartil_internet <- cut(
  dados_econml$penetracao_internet,
  breaks = quantile(dados_econml$penetracao_internet, c(0, 0.25, 0.5, 0.75, 1)),
  labels = c("Q1", "Q2", "Q3", "Q4"),
  include.lowest = TRUE
)

cate_internet <- dados_econml %>%
  group_by(quartil_internet) %>%
  summarise(
    n = n(),
    S_Learner = mean(ite_s),
    T_Learner = mean(ite_t),
    X_Learner = mean(ite_x),
    DR_Learner = mean(ite_dr),
    U_Learner = mean(ite_u),
    .groups = "drop"
  )

cat("\n=== CATE por Quartil de Internet ===\n")
print(cate_internet)

```

=== CATE por Quartil de Renda ===

A tibble: 4 × 7

	quartil_renda	n	S_Learner	T_Learner	X_Learner	DR_Learner	U_Learner
	<fct>	<int>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	Q1	756	3790.	6116.	6486.	4074.	5290.
2	Q2	744	3790.	6116.	6486.	4074.	5290.
3	Q3	756	3790.	6116.	6486.	4074.	5290.
4	Q4	744	3790.	6116.	6486.	4074.	5290.

=== CATE por Quartil de Internet ===

A tibble: 4 × 7

	quartil_internet	n	S_Learner	T_Learner	X_Learner	DR_Learner	U_Learner
	<fct>	<int>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	Q1	756	3790.	6116.	6486.	4074.	5290.
2	Q2	744	3790.	6116.	6486.	4074.	5290.
3	Q3	756	3790.	6116.	6486.	4074.	5290.
4	Q4	744	3790.	6116.	6486.	4074.	5290.

```

In [19]: #-----
# --- CORRELAÇÕES ENTRE MÉTODOS ---
#-----

cat("\n=== Correlação entre Métodos ===\n")

ite_df <- data.frame(
  ite_s = as.numeric(ite_s),
  ite_t = as.numeric(ite_t),
  ite_x = as.numeric(ite_x),
  ite_dr = as.numeric(ite_dr),
  ite_u = as.numeric(ite_u)
)

cor_matrix <- cor(ite_df)
colnames(cor_matrix) <- rownames(cor_matrix) <- c("S", "T", "X", "DR", "U")
print(round(cor_matrix, 3))

```

```

=== Correlação entre Métodos ===
      S      T      X      DR      U
S  1.000  0.389  0.145  0.846  0.519
T  0.389  1.000 -0.046  0.479  0.709
X  0.145 -0.046  1.000  0.203  0.012
DR 0.846  0.479  0.203  1.000  0.581
U  0.519  0.709  0.012  0.581  1.000

```

Análise dos Resultados dos Meta-Learning

Ranking de Performance

Posição	Método	ATE Estimado	Erro	Erro %
1º	T Learner	R\$ 6.115.55	+R\$ 103.27	+1.72%
2º	X Learner	R\$ 6.486.46	+R\$ 474.18	+7.89%
3º	U Learner	R\$ 5.290.16	-R\$ 722.12	-12.01%
4º	DR Learner	R\$ 3.993.66	-R\$ 2.018.62	-33.57%
5º	S Learner	R\$ 3.790.29	-R\$ 2.221.99	-36.96%

Principais Achados

Melhor Método: T-Learner

- **Acurácia:** 98,28% (erro de apenas 1,72%)
- **Explicação:** Modelos separados para tratados e controles capturam diferenças estruturais entre grupos
- **Implicação:** Tratamento **modifica** a relação entre covariáveis e vendas, não apenas adiciona constante

Consenso dos Métodos

- **Média dos 5 métodos:** R\$ 5.135,22
- **Desvio padrão:** R\$ 1.216,85
- **Coefficiente de variação:** 23,7%
- **Interpretação:** Efeito verdadeiro está dentro do intervalo de consenso, mas há divergência significativa entre métodos

Por Que S-Learner e DR-Learner Falharam?

S-Learner (Erro: -36,96%)

- **Problema:** Regularization bias severo
- **Causa:** Tratou tratamento como feature comum → algoritmo penalizou complexidade → subestimou efeito
- **Conclusão:** Inadequado quando efeito é heterogêneo e forte

DR-Learner (Erro: -33,57%)

- **Problema:** Propensity extremo ou overlap fraco

- **Causa:** Pesos IPW instáveis inflaram variância e introduziram viés
- **Conclusão:** Requer bom overlap e propensity bem especificado

Heterogeneidade: CATE por Subgrupos

Por Quartil de Renda

Quartil	T-Learner	X-Learner	U-Learner	Interpretação
Q1 (Baixa)	R\$ 4.769	R\$ 5.222	R\$ 3.894	Menor efeito em regiões pobres
Q2	R\$ 6.536	R\$ 6.458	R\$ 5.653	Efeito intermediário
Q3	R\$ 5.953	R\$ 6.907	R\$ 4.538	Efeito próximo à média
Q4 (Alta)	R\$ 7.228	R\$ 7.372	R\$ 7.110	Maior efeito em regiões ricas

Insight: Campanha funciona **+51% melhor** em lojas de alta renda (Q4) vs baixa renda (Q1)

Por Quartil de Internet

Quartil	T-Learner	X-Learner	U-Learner	Interpretação
Q1 (Baixa)	R\$ 5.779	R\$ 5.979	R\$ 4.433	Efeito moderado
Q2	R\$ 5.254	R\$ 6.853	R\$ 5.037	Efeito reduzido
Q3	R\$ 6.020	R\$ 6.400	R\$ 5.233	Efeito próximo à média
Q4 (Alta)	R\$ 7.416	R\$ 6.723	R\$ 6.473	Maior efeito em alta penetração

Insight: Campanha funciona **+28% melhor** em regiões com alta penetração de internet (Q4) vs baixa (Q1)

Correlação Entre Métodos

Nodel	S	T	X	DR	U
S	1.00	0.39	0.15	0.86	0.52
T	0.39	1.00	-0.05	0.47	0.71
X	0.15	-0.05	1.00	0.17	0.01
DR	0.86	0.47	0.17	1.00	0.59
U	0.52	0.71	0.01	0.59	1.00

Observações:

- **S ↔ DR (0.86):** Ambos subestimam fortemente → compartilham viés sistemático
- **T ↔ U (0.71):** Convergem na captura de heterogeneidade
- **X isolado:** Baixa correlação com todos → metodologia divergente (imputação)

Conclusão

O efeito causal da campanha é R\$ 6.012,28 (ground truth), sendo o *T-Learner* (R\$ 6.115,55) o método que melhor aproximou esse valor com erro de apenas 1,72%.

Heterogeneidade confirmada: Efeito varia de R\$ 4.769 (Q1renda) até R\$ 7.416 (Q4 internet), indicando necessidade de **segmentação estratégica** para maximizar ROI da campanha.

Triangulação dos métodos: Embora haja divergência (CV = 23,7%), o consenso (R\$ 5.135) está próximo do verdadeiro, validando a abordagem de múltiplos meta-learners.

DML (Double/Debiased Machine Learning)

Inferência Causal Rigorosa com Machine Learning

Como funciona o DML - Double Machine Learning?

Etapa 1 - Modelagem do resultado ($Y \sim X$)

Estimamos um modelo:

$$Y = \text{intercepto} + f(X) + \text{erro}$$

O objetivo é prever **o componente de Y explicado pelas covariáveis X**, sem ainda considerar o tratamento. Depois, calculamos o **resíduo de Y**:

$$\text{resíduo}_Y = Y \text{ observado} - Y \text{ previsto}$$

Para evitar overfitting, o DML aplica **cross-fitting**: divide os dados em partes, treina o modelo em uma e prevê na outra. Assim, cada previsão vem de um modelo que **nunca viu aqueles dados**. O resultado é um Y "limpo", representando o que **não é explicável** por X.

Etapa 2 - Modelagem do tratamento ($D \sim X$)

Estimamos agora:

$$D = \text{intercepto} + g(X) + \text{erro}$$

O objetivo é prever **a probabilidade de ser tratado** com base nas mesmas variáveis X. Como D é binário (0/1), o modelo deve ser **probabilístico**, como:

- Logit, Probit
- Random Forest Classifier
- XGBoost Classifier

Geramos então o **resíduo de D**:

$$\text{resíduo}_D = D \text{ observado} - D \text{ previsto}$$

Assim como na Etapa 1, aplica-se **cross-fitting** para evitar viés por sobreajuste.

Etapa 3 – Estimação do efeito causal

Agora comparamos as variações “limpas” de Y e D, livres da influência de X:

$$\text{resíduo}_Y = \theta * \text{resíduo}_D$$

Essa é uma **regressão linear simples sem intercepto** (pois os resíduos têm média zero). O coeficiente θ é o **efeito causal médio** do tratamento sobre o resultado.

Principais cuidados e limitações

1. **Exogeneidade:** Todas as variáveis X devem ser **pré-tratamento** e **não endógenas**. Se houver variáveis omitidas que influenciam D e Y, o efeito estimado será viesado.
2. **Ampla base de controles:** É essencial incluir o máximo de covariáveis que expliquem tanto o tratamento quanto o resultado.
3. **Ausência de multicolinearidade severa:** Covariáveis altamente correlacionadas dificultam a identificação da parte independente de cada uma.
4. **Modelo adequado à variável:**
 - Y contínuo → regressão (OLS, RF Regressor etc.)
 - D binário → classificação (Logit, Probit, RF Classifier etc.)

Resumo intuitivo

O DML “residualiza” tanto o resultado quanto o tratamento, removendo tudo que pode ser explicado por X. Depois mede o quanto essas partes imprevisíveis se movem juntas. Essa co-variação limpa é a **melhor aproximação do efeito causal**, desde que o conjunto de controles seja suficientemente rico e exógeno.

```
In [ ]: library(reticulate)
#use_virtualenv("r-econml", required = TRUE)

py_config()

# Instalar e importar DoubleML
py_install("doubleml", pip = TRUE, envname = "r-econml")
doubleml <- import("doubleml")

cat("Python e EconML carregados com sucesso!\n")
cat("DoubleML versão:", doubleml$__version__, "\n")
```

```
In [27]: #-----
# --- DOUBLE MACHINE LEARNING (DML) ---
#-----

cat("\n=== Double Machine Learning ===\n")
```

```

# Preparar dados no formato DoubleML
dml_data <- doubleml$DoubleMLData$from_arrays(
  x = X_np,
  y = Y_np,
  d = W_np
)

cat("Dados preparados para DoubleML\n")

#-----
# --- PLR (Partially Linear Regression) ---
#-----

cat("\n=== [1/3] PLR Model ===\n")

plr <- doubleml$DoubleMLPLR(
  obj_dml_data = dml_data,
  ml_l = base_learner,
  ml_m = propensity_learner,
  n_folds = 5L,
  n_rep = 1L
)

plr$fit()

ate_plr <- as.numeric(plr$coef)
se_plr <- as.numeric(plr$se)
ci_plr <- as.matrix(plr$confint())

cat("PLR | ATE:", round(ate_plr, 2),
    "| SE:", round(se_plr, 2),
    "| IC95%: [", round(ci_plr[1,1], 2), ",", round(ci_plr[1,2], 2), "]\n")

#-----
# --- IRM (Interactive Regression Model) ---
#-----

cat("\n=== [2/3] IRM Model ===\n")

irm <- doubleml$DoubleMLIRM(
  obj_dml_data = dml_data,
  ml_g = base_learner,
  ml_m = propensity_learner,
  n_folds = 5L,
  n_rep = 1L
)

irm$fit()

ate_irm <- as.numeric(irm$coef)
se_irm <- as.numeric(irm$se)
ci_irm <- as.matrix(irm$confint())

cat("IRM | ATE:", round(ate_irm, 2),
    "| SE:", round(se_irm, 2),
    "| IC95%: [", round(ci_irm[1,1], 2), ",", round(ci_irm[1,2], 2), "]\n")

#-----
# --- PLR com Cross-Fitting Robusto ---
#-----

```

```

cat("\n=== [3/3] PLR Robusto (10-fold, 3 rep) ===\n")

plr_robust <- doubleml$DoubleMLPLR(
  obj_dml_data = dml_data,
  ml_l = base_learner,
  ml_m = propensity_learner,
  n_folds = 10L,
  n_rep = 3L
)

plr_robust$fit()

ate_plr_robust <- as.numeric(plr_robust$coef)
se_plr_robust <- as.numeric(plr_robust$se)
ci_plr_robust <- as.matrix(plr_robust$conint())

cat("PLR Robust | ATE:", round(ate_plr_robust, 2),
    "| SE:", round(se_plr_robust, 2),
    "| IC95%: [", round(ci_plr_robust[1,1], 2), ", ", round(ci_plr_robust[1,2], 2)

#-----
# --- CONSOLIDAR RESULTADOS DML ---
#-----

resultados_dml <- tibble(
  Metodo = c("DML-PLR", "DML-IRM", "DML-PLR-Robust"),
  ATE = c(ate_plr, ate_irm, ate_plr_robust),
  SE = c(se_plr, se_irm, se_plr_robust),
  IC_Lower = c(ci_plr[1,1], ci_irm[1,1], ci_plr_robust[1,1]),
  IC_Upper = c(ci_plr[1,2], ci_irm[1,2], ci_plr_robust[1,2])
)

cat("\n=== Resultados DML ===\n")
print(resultados_dml)

# Comparar com efeito verdadeiro
resultados_dml_completo <- resultados_dml %>%
  mutate(
    Efeito_Verdadeiro = efeito_verdadeiro,
    Viés = ATE - efeito_verdadeiro,
    Viés_Abs = abs(Viés),
    Erro_Pct = (Viés / efeito_verdadeiro) * 100,
    Erro_Abs_Pct = abs(Erro_Pct),
    Contém_Verdadeiro = IC_Lower <= efeito_verdadeiro & IC_Upper >= efeito_verdadeiro
  )

cat("\n=== Comparação DML vs Efeito Verdadeiro ===\n")
print(resultados_dml_completo)

#-----
# --- COMPARAÇÃO GERAL: META-LEARNERS + DML ---
#-----

resultados_geral <- bind_rows(
  resultados_dml_completo %>% select(Metodo, ATE, Viés, Erro_Pct)
) %>%
  arrange(abs(Erro_Pct))

```

```
cat("\n=== RANKING GERAL (Meta-Learners + DML) ===\n")
print(resultados_geral)
```

```
=== Double Machine Learning ===
Dados preparados para DoubleML
```

```
=== [1/3] PLR Model ===
PLR | ATE: 783.38 | SE: 326.53 | IC95%: [ 143.39 , 1423.36 ]
```

```
=== [2/3] IRM Model ===
IRM | ATE: 6111.11 | SE: 99.49 | IC95%: [ 5916.12 , 6306.1 ]
```

```
=== [3/3] PLR Robusto (10-fold, 3 rep) ===
PLR Robust | ATE: 904.08 | SE: 325.97 | IC95%: [ 265.19 , 1542.98 ]
```

```
=== Resultados DML ===
```

```
# A tibble: 3 × 5
```

	Metodo	ATE	SE	IC_Lower	IC_Upper
	<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1	DML-PLR	783.	327.	143.	1423.
2	DML-IRM	6111.	99.5	5916.	6306.
3	DML-PLR-Robust	904.	326.	265.	1543.

```
=== Comparação DML vs Efeito Verdadeiro ===
```

```
# A tibble: 3 × 11
```

	Metodo	ATE	SE	IC_Lower	IC_Upper	Efeito_Verdadeiro	Viés	Viés_Abs
	<chr>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	DML-PLR	783.	327.	143.	1423.	6012.	-5229.	5229.
	-87.0	87.0	FALSE					
2	DML-IRM	6111.	99.5	5916.	6306.	6012.	98.8	98.8
	1.64	1.64	TRUE					
3	DML-PLR-Robust	904.	326.	265.	1543.	6012.	-5108.	5108.
	-85.0	85.0	FALSE					

```
=== RANKING GERAL (Meta-Learners + DML) ===
```

```
# A tibble: 3 × 4
```

	Metodo	ATE	Viés	Erro_Pct
	<chr>	<dbl>	<dbl>	<dbl>
1	DML-IRM	6111.	98.8	1.64
2	DML-PLR-Robust	904.	-5108.	-85.0
3	DML-PLR	783.	-5229.	-87.0

Análise dos Resultados: Double Machine Learning

Comparação das 3 Abordagens

Método	Efeito (R\$)	IC 95%	SE	Viés	Erro %	Contém Verdadeiro
DML-IRM	6.111,11	[5.916, 6.306]	99,49	+98,83	+1,64%	✓ Sim
DML-PLR-Robust (10-fold)	904,08	[265, 1.543]	325,97	-5.108,20	-85,0%	X Não
DML-PLR	783,38	[143, 1.423]	326,53	-5.228,90	-87,0%	X Não

Método	Efeito (R\$)	IC 95%	SE	Viés	Erro %	Contém Verdadeiro
Efeito Verdadeiro	6.012,28	-	-	0	0%	-

Melhor Especificação: DML-IRM

Modelo:

$$E[Y|X, W=1] - E[Y|X, W=0] = \theta(X)$$

com:

- Outcome models: $E[Y|X, W=w]$
- Propensity model: $P(W=1|X)$
- Cross-fitting: 5-fold
- Debiasing: Neyman orthogonality

Resultados:

- **Efeito médio (ATE):** R\$ 6.111 por loja
- **Erro padrão:** R\$ 99,49
- **IC 95%:** [5.916, 6.306]
- **Viés absoluto:** R\$ 98,83
- **Erro percentual:** 1,64%
- **Precisão:** 98,36%

Estimativa robusta:

- Intervalo de confiança contém o efeito verdadeiro (6.012,28)
- Erro padrão baixo indica alta precisão
- Debiasing via cross-fitting remove viés de overfitting
- Neyman orthogonality garante convergência rápida

Por Que IRM é Superior ao PLR?

DML-IRM:

- Modela diretamente $E[Y|X, W]$ para cada grupo
- Captura heterogeneidade não-linear do efeito
- Menos restritivo (não assume linearidade parcial)
- Robusto a misspecification do modelo de outcome

DML-PLR (Problema):

- Assume que $Y = \theta W + g(X) + \varepsilon$ (linearidade parcial em W)
- Violação da linearidade parcial leva a viés massivo (-85%)
- Efeito do tratamento varia com X de forma complexa
- Modelo inadequado para este cenário de dados

Garantias Teóricas do DML

Cross-fitting (5-fold):

- Evita overfitting: previsões feitas em dados out-of-sample
- Remove viés de regularização (Chernozhukov et al., 2018)

Neyman Orthogonality:

- Momento score insensível a pequenos erros nos nuisance parameters
- Convergência $\sqrt{n}$ mesmo com ML não-paramétrico

Double Robustness:

- Estimativa consistente se outcome OU propensity model estiver correto
- No IRM, ambos foram bem especificados

Diagnóstico: Por Que PLR Falhou?

Teste de linearidade parcial:

```
# Efeito heterogêneo detectado
cor(X, ite_irm) # Alta correlação entre X e ITE
```

Violação:

- O efeito varia substancialmente com renda_per_capita e potencial_crescimento
- PLR força θ constante → viés de misspecification
- IRM permite $\theta(X)$ flexível → captura heterogeneidade

Inferência e Intervalos de Confiança

DML-IRM fornece inferência assintoticamente válida:

IC 95%: [5.916, 6.306]

- Baseado em distribuição normal assintótica
- Erro padrão robusto a heterocedasticidade
- Válido sob regularidade conditions (Chernozhukov et al., 2018)

Interpretação:

"Com 95% de confiança, o efeito causal da campanha está entre R 5.916 e R 6.306 por loja."

Recomendações

Para este conjunto de dados:

1. **Usar DML-IRM** como estimador principal (erro 1,64%)
2. X-Learner e DR-Learner como robustness checks
3. Evitar PLR devido à violação de linearidade parcial

Vantagens do DML-IRM:

- Estimativa quase perfeita do efeito verdadeiro
- Inferência estatística rigorosa com ICs válidos

- Robusto a misspecification
- Captura heterogeneidade complexa

Próximos passos:

- Estimar CATE (efeitos heterogêneos) por subgrupo
- Validar com policy learning
- Testar sensibilidade a confounders não-observados

Conclusão

DML-IRM é o método mais preciso e teoricamente fundamentado:

- **Efeito estimado:** R\$ 6.111/loja
- **Viés:** +1,64%
- **Pontos fortes:** debiasing automático, inferência válida, captura heterogeneidade
- **Limitação:** requer sample size adequado para cross-fitting efetivo

Considerações Finais

Considerações Finais

O propósito central deste material não é apenas determinar o impacto causal da campanha de marketing, mas sim **demonstrar, comparar e interpretar o desempenho de diferentes métodos de inferência causal** diante de um cenário controlado, com dados simulados e efeito verdadeiro conhecido. A simulação, ao incorporar seleção não aleatória, tendências distintas e heterogeneidade de efeito, permite observar como cada método reage quando as condições ideais de um experimento randomizado são violadas, algo extremamente comum em aplicações reais.

Os resultados mostram que métodos simples, como o **A/B ingênuo**, são altamente sensíveis ao viés de seleção, superestimando o efeito em quase 40%. Isso evidencia que significância estatística por si só não assegura validade causal. Métodos que incorporam informação pré-tratamento ou realizam ajustes estruturados, como o **PrePost com correção**, o **DiD ponderado** e especialmente o **Entropy Balancing**, aproximam-se muito mais do efeito verdadeiro, cada um utilizando princípios distintos: correção Bayesiana, ajuste de tendências ou reponderação ótima das covariáveis.

O exercício demonstra de forma clara que:

1. **Métodos de inferência causal diferem enormemente em robustez**, dependendo da estrutura do viés e da qualidade dos controles disponíveis.
2. **Balanceamento explícito** (como Entropy Balancing) é altamente eficaz em cenários com forte seleção não aleatória.

3. **Modelos que utilizam estrutura temporal** (como PrePost e DiD) reduzem viés quando conseguem capturar corretamente as tendências prévias.
4. **Conhecer o efeito verdadeiro** nos permite avaliar diretamente o erro, ilustrando a importância do desenho empírico na prática.

Assim, a principal contribuição deste estudo é mostrar como diferentes métodos, frequentistas, bayesianos, balanceamento, aprendizado estatístico e técnicas de painel, respondem a um mesmo problema causal. Mais do que obter um número final, o exercício evidencia **como escolher o método adequado muda completamente a interpretação**, reforçando que decisões baseadas em causalidade exigem ferramentas apropriadas, compreensão dos pressupostos e atenção ao processo de seleção.

Em síntese, o trabalho serve como um guia prático de aplicação de inferência causal na avaliação de uma campanha de marketing sobre as vendas.

Tabela Ranqueada – Menor Desvio em Relação ao Efeito Verdadeiro

Tabela Ranqueada – Menor Desvio em Relação ao Efeito Verdadeiro

Ranking	Modelo	Impacto (R\$)	Desvio (R\$)	Desvio %	Método
1º	TWFE + Cov×Período	6.015.00	+3.00	+0.05%	Diff-in-Diff (DID)
2º	A/B + Entropy Balancing	5.981.77	-30.52	-0.5%	A/B Test
3º	C&S Doubly Robust	6.040.40	+28.00	+0.5%	Diff-in-Diff (DID)
4º	TWFE + Entropy Pesos	6.046.60	+34.32	+0.6%	Diff-in-Diff (DID)
5º	Gardner + Cov×Período	6.052.00	+40.00	+0.7%	Synthetic Control (SC)
6º	Augmented SC (Ridge)	5.954.88	-57.40	-0.95%	Synthetic Control (SC)
7º	SC Tradicional (Abadie)	5.953.40	-58.88	-0.98%	Synthetic Control (SC)
8º	AOSS/WAOSS (DR)	6.088.91	+76.63	+1.3%	Diff-in-Diff (DID)
9º	DML-IRM	6.111.00	+98.72	+1.64%	Double Machine Learning
10º	Meta-Learner — T-Learner	6.115.55	+103.27	+1.72%	T-Learner
11º	Meta-Learner — U-Learner	5.290.16	-722.12	-12.0%	U-Learner
12º	S&A + Cov×Período	6.276.60	+264.32	+4.4%	Diff-in-Diff (DID)
13º	Synthetic DiD	6.279.79	+267.51	+4.45%	(SC) + (DID)

Ranking	Modelo	Impacto (R\$)	Desvio (R\$)	Desvio %	Método
14º	Causal Forest (média CATE)	6.260.89	+248.61	+4.1%	Causal Forest
15º	DCD&H Com Pesos	6.321.08	+308.80	+5.1%	Diff-in-Diff (DID)
16º	S&A + Pesos	6.351.80	+339.52	+5.6%	Diff-in-Diff (DID)
17º	C&S IPW + Cov	6.394.00	+381.72	+6.4%	Diff-in-Diff (DID)
18º	System GMM (Blundell-Bond)	6.378.91	+366.63	+6.1%	System GMM
19º	DCD&H Sem Pesos	6.457.24	+444.96	+7.4%	Diff-in-Diff (DID)
20º	PrePost Com Correção Pré	6.513.59	+501.59	+8.3%	A/B Test
21º	PrePost BH	6.513.59	+501.59	+8.3%	A/B Test
22º	Gardner + Pesos	6.181.00	+168.72	+2.8%	Diff-in-Diff (DID)
23º	Gardner + Cov	6.615.00	+602.72	+10.0%	Diff-in-Diff (DID)
24º	S&A + Cov	6.667.60	+655.32	+10.9%	Diff-in-Diff (DID)
25º	S&A Simples	6.667.60	+655.32	+10.9%	Diff-in-Diff (DID)
26º	C&S Reg Simples	6.667.60	+655.32	+10.9%	Diff-in-Diff (DID)
27º	TWFE + Cov	6.737.31	+725.03	+12.1%	Diff-in-Diff (DID)
28º	TWFE Simples	6.737.31	+725.03	+12.1%	Diff-in-Diff (DID)
29º	Gardner Simples	6.737.00	+724.72	+12.1%	Diff-in-Diff (DID)
30º	Meta-Learner — X-Learner	6.486.46	+474.18	+7.9%	X-Learner
31º	Meta-Learner — DR-Learner	3.993.66	-2.018.62	-33.6%	DR-Learner
32º	Meta-Learner — S-Learner	3.790.29	-2.221.99	-37.0%	S-Learner
33º	Causal Impact — Bivariado	7.120.42	+1.108.14	+18.4%	BSTS (CausalImpact)
34º	PréPost Sem Correção	8.310.23	+2.298.23	+38.2%	A/B Test
35º	A/B Simples (Ingênuo)	8.310.23	+2.297.95	+38.2%	A/B Test
36º	Causal Impact — Multivariado (T+C)	12.247.64	+6.235.36	+103.7%	BSTS (CausalImpact)
37º	Causal Impact — Multivariado (Tratado)	12.243.80	+6.231.51	+103.6%	BSTS (CausalImpact)