

Endogeneidade e Suas Consequências: Estimativas Enviesadas de Elasticidade-Preço

Silvio da Rosa Paula

O Problema

Este exercício demonstra os efeitos nocivos da **endogeneidade** na estimação de elasticidades preço-demanda. Quando preço e quantidade são determinados simultaneamente no mercado, a correlação entre o preço e o termo de erro viola o pressuposto fundamental de MQO, gerando **estimativas enviesadas**.

Simulação dos Dados

Criamos dados sintéticos onde:

- **Variável dependente:** $\log(\text{vendas})$
 - **Variável endógena:** $\log(\text{preço})$
 - **Variáveis exógenas:** $\log(\text{renda})$, sazonalidade
 - **Instrumento:** tempo (tendência temporal)
-

A Fonte da Endogeneidade

O **choque de demanda** afeta simultaneamente: 1. As vendas (aumenta demanda) 2. O preço (empresas ajustam preços conforme demanda)

Esta simultaneidade cria correlação entre preço e erro, violando $E[\varepsilon|X] = 0$.

Elasticidade Verdadeira vs Estimada

- **Coefficiente Verdadeiro:** -1.8 (definida na simulação)
-

Por Que o modelo de regressão linear (Mínimos Quadrados Ordinários - MQO) Falha?

O MQO captura tanto: - O efeito causal do preço nas vendas (que queremos) - A resposta endógena do preço à demanda (confundidor)

Resultado: subestima drasticamente a elasticidade em magnitude.

A Solução: Variáveis Instrumentais

Usamos **tempo** como instrumento porque: - É relevante: correlacionado com preço (tendência) - É exógeno: não correlacionado com choques de demanda - Satisfaz restrição de exclusão: afeta vendas apenas via preço

O método IV/2SLS isola a variação exógena no preço, recuperando o efeito causal.

Teste de Hausman

Confirma presença de endogeneidade comparando estimadores OLS e IV. P-valor baixo rejeita H_0 de exogeneidade.

Implicações Práticas

Ignorar endogeneidade leva a: - Elasticidades subestimadas - Previsões erradas - Decisões de precificação equivocadas - Perda de receita potencial

Importar bibliotecas

```
# Instalar e carregar packages  
if (!require(pacman)) install.packages("pacman")
```

```
## Carregando pacotes exigidos: pacman
```

```
p_load(tidyverse, AER, plotly, lubridate, stargazer, Metrics)
```

Simulação dos dados

Criamos dados sintéticos onde:

- **Variável dependente:** $\log(\text{vendas})$
- **Variável endógena:** $\log(\text{preço})$
- **Variáveis exógenas:** $\log(\text{renda})$, sazonalidade
- **Instrumento:** tempo (tendência temporal)

```

# Define semente para reprodutibilidade
set.seed(456)

# Número de observações (dias)
n <- 500

# Criação da base de dados simulada
dados <- tibble(
  # Sequência de datas diárias a partir de 2020-01-01
  data = seq.Date(as.Date("2020-01-01"), by = "day", length.out = n),

  # Índice de tempo (1 a 500)
  tempo = 1:n,

  # Renda média simulada (distribuição normal com média 50 e desvio 10)
  renda = rnorm(n, 50, 10),

  # Sazonalidade anual simulada com função seno
  sazonalidade = sin(2 * pi * tempo / 365),

  # Choques aleatórios de demanda
  choque_demanda = rnorm(n, 0, 0.5)
) %>%
mutate(
  # Preço determinado por tempo, sazonalidade e choques
  preco = exp(4.5 + 0.8 * choque_demanda + 0.001 * tempo + 0.1 * sazonalidade + rnorm(n, 0,
0.08)),

  # Vendas dependem negativamente do preço e positivamente da renda e sazonalidade
  vendas = exp(6 - 1.8 * log(preco) + 0.5 * log(renda) + 0.2 * sazonalidade + choque_demanda + rnorm(n, 0, 0.1))
) %>%
mutate(
  # Versões log das variáveis principais para modelos log-lineares
  log_vendas = log(vendas),
  log_preco = log(preco),
  log_renda = log(renda)
)

# Visualiza a base de dados resultante
dados

```

data	te...	renda	sazonalidade	choque_dema...	preco	vendas	log_ve
<date>	<int>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	
2020-01-01	1	36.56479	1.721336e-02	0.0726449115	94.45959	0.6620487	-0.412416
2020-01-02	2	56.21776	3.442161e-02	-0.1909092949	77.80610	1.0624237	0.060552
2020-01-03	3	58.00875	5.161967e-02	-0.2811253902	75.42369	0.9626529	-0.038062
2020-01-04	4	36.11108	6.880243e-02	0.6346838359	132.23839	0.6732417	-0.395650
2020-01-05	5	42.85643	8.596480e-02	-0.6092569819	71.26782	0.6175744	-0.481955
2020-01-06	6	46.75939	1.031017e-01	-0.5943392501	54.16998	1.2507128	0.223713

data	te...	renda	sazonalidade	choque_dema...	preco	vendas	log_ve
<date>	<int>	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>	
2020-01-07	7	56.90643	1.202080e-01	-0.3949236419	60.79216	1.4024066	0.338189
2020-01-08	8	52.50548	1.372788e-01	0.1089901709	104.40314	0.8475562	-0.165398
2020-01-09	9	60.07352	1.543088e-01	-0.9030460076	47.65360	1.3078658	0.268396
2020-01-10	10	55.73235	1.712931e-01	0.3487136690	127.75306	0.7960471	-0.228096

1 10 of 500 rows | 1 0 of 10 columns

Previous 1 2 3 4 5 6 50 Next

Estatísticas descritivas

```
# Calcula média, desvio padrão, mínimo e máximo das variáveis numéricas
dados %>%
  select(renda, preco, vendas, log_vendas, log_preco, log_renda, sazonalidade, choque_demanda) %>%
  summary()
```

```
##      renda      preco      vendas      log_vendas
## Min.   :26.18   Min.   : 30.58   Min.   :0.1743   Min.   : -1.7469
## 1st Qu.:43.98   1st Qu.: 86.88   1st Qu.:0.4234   1st Qu.: -0.8595
## Median :50.85   Median :118.05   Median :0.5545   Median : -0.5897
## Mean   :50.98   Mean   :130.85   Mean   :0.5930   Mean   : -0.5969
## 3rd Qu.:58.14   3rd Qu.:165.32   3rd Qu.:0.7219   3rd Qu.: -0.3258
## Max.   :80.09   Max.   :375.80   Max.   :1.6669   Max.   : 0.5110
## log_preco log_renda sazonalidade choque_demanda
## Min.   :3.420   Min.   :3.265   Min.   : -1.0000   Min.   : -1.482130
## 1st Qu.:4.465   1st Qu.:3.784   1st Qu.: -0.4731   1st Qu.: -0.327403
## Median :4.771   Median :3.929   Median : 0.3817   Median : 0.009125
## Mean   :4.781   Mean   :3.912   Mean   : 0.1964   Mean   : 0.007414
## 3rd Qu.:5.108   3rd Qu.:4.063   3rd Qu.: 0.8588   3rd Qu.: 0.367466
## Max.   :5.929   Max.   :4.383   Max.   : 1.0000   Max.   : 1.528529
```

Matriz de correlação

```
# Calcula correlação entre variáveis numéricas selecionadas
dados %>%
  select(log_vendas, log_preco, log_renda, sazonalidade, choque_demanda) %>%
  cor() %>%
  round(3)
```

```
##      log_vendas log_preco log_renda sazonalidade choque_demanda
## log_vendas      1.000    -0.793     0.255      0.024     -0.575
## log_preco      -0.793     1.000    -0.039     0.165      0.915
## log_renda       0.255    -0.039     1.000    -0.012     -0.066
## sazonalidade     0.024     0.165    -0.012     1.000      0.013
## choque_demanda  -0.575     0.915    -0.066     0.013      1.000
```

A matriz de correlação revela relações econômicas coerentes: as vendas caem quando o preço aumenta (forte correlação negativa), aumentam com a renda (correlação positiva moderada) e são pouco afetadas pela sazonalidade. Choques de demanda elevam os preços e reduzem as vendas, mostrando seu efeito direto sobre o mercado. No geral, os resultados refletem um comportamento típico de oferta e demanda, com renda exógena e sazonalidade pouco relevante.

Estimação dos modelos

Mínimos Quadrados Ordinários (MQO) * Modelo linear simples onde $\log_vendas$ é explicado por $\log_preco$, $\log_renda$ e sazonalidade * Assume que todas as variáveis explicativas são exógenas (não correlacionadas com o erro)

```
# Mínimos Quadrados Ordinários (MQO)
mqo <- lm(log_vendas ~ log_preco + log_renda + sazonalidade, data = dados)

# summary
stargazer(mqo, type = "text")
```

```
##
## =====
##                      Dependent variable:
##                      -----
##                      log_vendas
## -----
## log_preco              -0.726***
##                      (0.022)
##
## log_renda              0.440***
##                      (0.048)
##
## sazonalidade           0.089***
##                      (0.014)
##
## Constant              1.132***
##                      (0.219)
##
## -----
## Observations           500
## R2                     0.704
## Adjusted R2            0.702
## Residual Std. Error    0.212 (df = 496)
## F Statistic            393.180*** (df = 3; 496)
## =====
## Note:                  *p<0.1; **p<0.05; ***p<0.01
```

- O modelo estimado por Mínimos Quadrados Ordinários (MQO) mostra resultados consistentes com o comportamento teórico da demanda.
- O coeficiente de $\log_preco$ (-0.726) é negativo e estatisticamente significativo ($p < 0.01$), indicando que um aumento de 1% no preço reduz as vendas em aproximadamente 0,73%, em média. Essa é a elasticidade-preço da demanda, confirmando a relação inversa entre preço e quantidade demandada.

- O coeficiente de `log_renda` (0.440) é positivo e também altamente significativo, sugerindo que um aumento de 1% na renda aumenta as vendas em cerca de 0,44% — sinal esperado para bens normais, cujo consumo cresce com o poder de compra.
- A variável sazonalidade (0.089) tem um coeficiente positivo e significativo, indicando que, em períodos sazonais favoráveis (picos do ciclo senoidal), as vendas crescem ligeiramente.
- O $R^2 = 0.704$ indica que o modelo explica cerca de 70% da variação nas vendas.

Modelo de Variáveis Instrumentais (IV) * Usa o método de Mínimos Quadrados em Dois Estágios (2SLS) via função `ivreg()` * `log_preco` é potencialmente endógeno (correlacionado com o erro) * `tempo` é usado como instrumento — ele afeta o preço, mas não afeta diretamente as vendas além do efeito via preço * `log_renda` e `sazonalidade` permanecem como variáveis exógenas

```
# Modelo de Variáveis Instrumentais (IV)
iv <- ivreg(log_vendas ~ log_preco + log_renda + sazonalidade |
            tempo + log_renda + sazonalidade,
            data = dados)

# summary
summary(iv, diagnostics = TRUE)
```

```
##
## Call:
## ivreg(formula = log_vendas ~ log_preco + log_renda + sazonalidade |
##       tempo + log_renda + sazonalidade, data = dados)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.39551 -0.29118 -0.00851  0.29887  1.21194
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   6.01692    0.79981   7.523 2.54e-13 ***
## log_preco    -1.68727    0.13518  -12.482 < 2e-16 ***
## log_renda     0.36207    0.10527   3.440 0.000632 ***
## sazonalidade  0.18667    0.03261   5.725 1.80e-08 ***
##
## Diagnostic tests:
##              df1 df2 statistic p-value
## Weak instruments    1 496    73.45 <2e-16 ***
## Wu-Hausman          1 495   633.21 <2e-16 ***
## Sargan              0 NA        NA      NA
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4633 on 496 degrees of freedom
## Multiple R-Squared:  -0.4179, Adjusted R-squared:  -0.4265
## Wald test: 59.58 on 3 and 496 DF,  p-value: < 2.2e-16
```

Interpretação do Modelo de Variáveis Instrumentais (IV)

O modelo de **Variáveis Instrumentais (IV)** foi estimado por meio do método de **Mínimos Quadrados em Dois Estágios (2SLS)**, usando `tempo` como instrumento para `log_preco`.

Estrutura do Modelo

A equação estimada é:

$$\text{log_vendas} = \beta_0 + \beta_1\text{log_preco} + \beta_2\text{log_renda} + \beta_3\text{sazonalidade} + \varepsilon$$

O instrumento `tempo` é utilizado para corrigir a **endogeneidade** do preço, assumindo que `tempo` afeta o preço, mas não afeta as vendas diretamente (exceto via preço).

Principais Resultados

Variável	Coefficiente	Interpretação
Intercepto (6.02)	Valor médio de <code>log_vendas</code> quando as variáveis explicativas são zero (sem interpretação direta).	
log_preco (-1.69)	Elasticidade-preço estimada. Um aumento de 1% no preço reduz as vendas em 1,69% , indicando demanda elástica .	
log_renda (0.36)	Elasticidade-renda positiva. Um aumento de 1% na renda eleva as vendas em 0,36% , coerente com bens normais.	
sazonalidade (0.19)	Efeito positivo e significativo. Períodos sazonais favoráveis aumentam as vendas em torno de 0,19%.	

Comparado ao MQO (elasticidade-preço ≈ -0.73), o IV mostra um efeito de preço mais forte, sugerindo que o MQO estava **enviesado para cima** por endogeneidade (preços correlacionados com choques de demanda).

Diagnósticos do Modelo

Teste	Interpretação
Weak instruments (F = 73.45, p < 0.001)	O instrumento <code>tempo</code> é forte , explicando bem a variação em <code>log_preco</code> (F > 10).
Wu–Hausman (p < 0.001)	Rejeita a hipótese de exogeneidade do preço. O uso de IV é necessário .
Sargan (NA)	Não aplicável, pois há apenas um instrumento para uma variável endógena (modelo exatamente identificado).

Ajuste do Modelo

- **Erro padrão residual:** 0.463 — maior que no MQO (0.212), refletindo a maior incerteza ao corrigir endogeneidade.
- **R² negativo:** comum em modelos IV; não é interpretado da mesma forma que no MQO.
- **Wald test:** significativo ($p < 0.001$), indicando que o conjunto das variáveis explicativas é relevante.

Conclusão

O modelo IV revela que: - **O preço é endógeno**, e o MQO subestimava sua elasticidade.

- Após a correção, a **elasticidade-preço** é **-1,69**, mostrando que a demanda é **altamente sensível ao preço**.

- **Renda (0,36)** e **sazonalidade (0,19)** mantêm efeitos positivos e significativos.

- O instrumento **tempo** é estatisticamente forte e adequado, tornando o modelo IV confiável para estimar o verdadeiro impacto do preço sobre as vendas.

Visualizar elasticidades

```
# Mínimos Quadrados Ordinários (MQO)
elasticidade_mqo <- coef(mqo)["log_preco"]

# Modelo de Variáveis Instrumentais (IV)
elasticidade_iv <- coef(iv)["log_preco"]

# print
cat("\n\n=== ELASTICIDADES-PREÇO DA DEMANDA ===\n")
```

```
##
##
## === ELASTICIDADES-PREÇO DA DEMANDA ===
```

```
cat(sprintf("Coeficiente Verdadeiro:      -1.8000\n"))
```

```
## Coeficiente Verdadeiro:      -1.8000
```

```
cat(sprintf("OLS (Enviesado): %.4f\n", elasticidade_mqo))
```

```
## OLS (Enviesado): -0.7255
```

```
cat(sprintf("IV (Corrigido):  %.4f\n", elasticidade_iv))
```

```
## IV (Corrigido):  -1.6873
```

```
cat(sprintf("\nViés MQO: %.4f (%.1f%%)\n",
            elasticidade_mqo - (-1.8),
            100 * abs(elasticidade_mqo - (-1.8)) / 1.8))
```


##

Viés MQO: 1.0745 (59.7%)

Análise

O modelo MQO apresenta um **viés de +1,07 pontos (59,7%)**, indicando que ele **subestima fortemente o efeito do preço** sobre as vendas.

Em outras palavras, o MQO sugere que o consumidor reage pouco a variações de preço, quando na realidade a demanda é **altamente elástica**.

Implicações para Negócios

Usar um **coeficiente enviesado** pode gerar **decisões equivocadas e prejuízos econômicos**:

- Uma empresa pode **aumentar preços acreditando que as vendas cairão pouco**, quando na verdade a redução no volume será muito maior — **diminuindo a receita e o lucro**.
- Estratégias baseadas nesse coeficiente incorreto (como precificação, previsão de demanda e gestão de estoques) se tornam **inconsistentes e arriscadas**.
- Em políticas públicas, um viés semelhante pode levar a **erros de previsão de arrecadação e distorções de mercado**.

Conclusão

A correção via **modelo IV** é essencial para revelar o verdadeiro comportamento da demanda.

Neste caso, a elasticidade corrigida (-1.69) mostra que o mercado é **muito sensível a variações de preço**.

Ignorar a endogeneidade e usar o valor enviesado do MQO poderia levar a **decisões estratégicas incorretas e perdas financeiras significativas**.

Impacto da Endogeneidade nas Previsões: OLS vs IV, qual

modelo se sai melhor e porquê?

```
# realizar as previsões
dados$pred_log_ols <- predict(mqo, dados)
dados$pred_log_iv <- predict(iv, dados)
dados$pred_ols <- exp(dados$pred_log_ols)
dados$pred_iv <- exp(dados$pred_log_iv)

# Métricas na escala original (vendas)
metricas_nivel <- tibble(
  modelo = c("OLS", "IV"),
  RMSE = c(
    rmse(dados$vendas, dados$pred_ols),
    rmse(dados$vendas, dados$pred_iv)
  ),
  MAE = c(
    mae(dados$vendas, dados$pred_ols),
    mae(dados$vendas, dados$pred_iv)
  ),
  MAPE = c(
    mape(dados$vendas, dados$pred_ols),
    mape(dados$vendas, dados$pred_iv)
  ),
  R2 = c(
    cor(dados$vendas, dados$pred_ols)^2,
    cor(dados$vendas, dados$pred_iv)^2
  )
)


# Exibir resultados
metricas_nivel
```

modelo <chr>	RMSE <dbl>	MAE <dbl>	MAPE <dbl>	R2 <dbl>
OLS	0.1293273	0.09961124	0.1735037	0.6991404
IV	0.4579464	0.26136380	0.3952781	0.6163509

2 rows

```
# plotar
plot_ly(dados) %>%
  add_trace(x = ~data, y = ~vendas, type = "scatter", mode = "lines",
    name = "Vendas Reais", line = list(width = 1.5, color = "black")) %>%
  add_trace(x = ~data, y = ~pred_ols, type = "scatter", mode = "lines",
    name = "OLS (Enviesado)", line = list(width = 1.5, color = "red")) %>%
  add_trace(x = ~data, y = ~pred_iv, type = "scatter", mode = "lines",
    name = "IV (Corrigido)", line = list(width = 1.5, color = "green")) %>%
  layout(title = "Vendas: Real vs Projeções",
    xaxis = list(title = "Data"),
    yaxis = list(title = "Vendas"),
    hovermode = "x unified")
```

Vendas: Real vs Projeções



Os resultados mostram as métricas de desempenho preditivo para os dois modelos:

- O MQO apresenta melhores métricas de ajuste preditivo — menor erro (RMSE, MAE, MAPE) e maior R^2 , porquê?

Por Que Isso Acontece?

1. **OLS “aprende” a endogeneidade:** Captura a correlação espúria entre preço e erro, melhorando o ajuste mas distorcendo a interpretação causal
2. **IV “ignora” parte dos dados:** Usa apenas a variação exógena do preço (via instrumento), descartando informação correlacionada com o erro
3. **Trade-off viés-variância:**
 - OLS: baixa variância, alto viés (quando há endogeneidade)
 - IV: alta variância, baixo viés (assintoticamente)

Referências na Literatura

- **Angrist & Pischke (2009, 2015):** “Mostly Harmless Econometrics” - discutem extensivamente esse trade-off
- **Wooldridge (2010):** Cap. 5 “Instrumental Variables” - formalmente demonstra
- **Stock & Watson (2015):** “Introduction to Econometrics” - exemplos aplicados

Quando Usar Cada Um?

Use OLS se: - Objetivo é predição pura (forecasting) - Não há necessidade de interpretação dos coeficientes - Exogeneidade é plausível

Use IV se: - Objetivo é inferência causal (efeito de X em Y) - Há endogeneidade conhecida/suspeita - Decisões dependem de entender relações causais (ex: elasticidades para pricing)

Métricas de Ajuste em IV São Enganosas

R^2 e RMSE **não são apropriados** para avaliar IV porque: - IV não minimiza soma dos quadrados - R^2 pode ser negativo (fitted values não são projeção ortogonal) - Melhor ajuste $\neq$ melhor estimador causal
