

A armadilha do p-valor: por que seu resultado não significativo pode estar enganando você

Introdução

Quando analisamos o impacto de uma campanha, política pública ou intervenção usando métodos como Difference-in-Differences, experimentos A/B ou modelos de uplift, é comum nos depararmos com um resultado “não significativo”. A interpretação automática costuma ser: *“então não houve efeito.”* Mas essa conclusão é, muitas vezes, precipitada.

Em muitos casos, o problema não está na campanha, está na **sensibilidade do estudo**. Se o desenho da análise não tem poder estatístico suficiente, ele simplesmente não consegue enxergar efeitos pequenos ou moderados, mesmo quando eles existem. É como tentar identificar detalhes finos com uma câmera desfocada: a informação está lá, mas o instrumento não tem resolução para capturá-la.

Por isso, entender **poder estatístico (power)** e **Minimum Detectable Effect (MDE)** é fundamental. Eles respondem uma pergunta crítica que quase nunca é feita: *“meu estudo teria capacidade de detectar o tipo de efeito que eu realmente espero ver?”* Sem essa resposta, interpretar um resultado não significativo pode levar a decisões erradas, como descartar campanhas eficazes ou assumir que políticas públicas não funcionam.

Essa é a diferença entre ausência de evidência e evidência de ausência.

poder estatístico (power)

Power é a chance de você perceber um efeito real, caso ele realmente exista.

Pense num detector de metais na praia:

- Se o detector for bom, ele apita sempre que tem uma moeda ali → power alto.
- Se for ruim, ele só apita para objetos grandes → power baixo.

Ou seja: **Power** diz o quanto seu estudo é “sensível” para detectar efeitos reais.

Minimum Detectable Effect (MDE)

MDE é o menor efeito que seu estudo consegue enxergar com segurança (ex.: 90% de chance).

Voltando ao exemplo do detector de metais na praia:

- Se o detector só encontra objetos maiores que uma moeda de R\$1,
 - MDE = “tamanho de uma moeda”.
- Se o estudo só detecta efeitos acima de +5 p.p.,
 - MDE = 5 p.p.

Isso significa: **“Se o efeito for menor que o MDE, seu estudo praticamente não tem chance de encontrá-lo.”**

Conclusão intuitiva

- POWER → quão boa é sua “visão” para enxergar efeitos reais.
- MDE → o menor efeito que você consegue enxergar com essa visão.
- Se seu MDE for maior que o efeito esperado: -você está usando um microscópio ruim para ver algo pequeno.
- Se seu power for baixo:
 - mesmo efeitos relevantes passam despercebidos.

Standard Error (SE)

O SE é o Erro-Padrão do estimador, uma medida de incerteza do coeficiente estimado. Basicamente o SE indica o quanto essa estimativa varia devido ao ruído dos dados

- O SE também pode ser entendido como, o quanto o seu coeficiente poderia mudar se você repetisse o estudo muitas vezes.

Intuição rápida:

- **SE baixo** → sua estimativa é precisa, pouco ruidosa.
- **SE alto** → sua estimativa é imprecisa, muito ruidosa.

Por que SE importa?

Porque o **p-valor, o intervalo de confiança, o power e o MDE** dependem totalmente dele.

Em um modelo por exemplo de Difference-in-Differences (DiD), o SE costuma ser influenciado por:

- variação residual;
 - número de unidades e períodos;
 - clusterização (muito importante em painel);
 - heterogeneidade entre as unidades.
-

Exemplo prático: campanha com pouco budget (orçamento)

Você roda um DiD para ver se o envio de SMS aumenta a recompra.

- Seu resultado estimado foi +1,2 p.p. (não significativo), logo o pesquisador conclui “A campanha não funcionou”, **PORÉM**
- SE (Standard Error ou seja, O Erro-Padrão do estimador) indica que o MDE = 4 p.p., ou seja, “A campanha pode ter funcionado, mas meu estudo não tem sensibilidade para enxergar efeitos menores que 4 p.p.”, logo a conclusão correta é que amostra foi pequena demais para capturar esse impacto.

Cálculo do MDE — passo a passo

A fórmula geral do MDE é:

$$\text{MDE} = (z_{1-\alpha/2} + z_{1-\beta}) \cdot SE$$

1. Valores utilizados

$$\alpha = 0.05$$

$$1 - \beta = 0.80$$

$$SE = 0.09$$

2. Cálculo dos quantis

$$z_{1-\alpha/2} = z_{0.975} = 1.96$$

$$z_{1-\beta} = z_{0.80} = 0.84$$

3. Soma dos quantis

$$1.96 + 0.84 = 2.80$$

4. Multiplicação pelo SE

$$\text{MDE} = 2.80 \cdot 0.09$$

Abrindo a conta:

$$2.80 \cdot 0.09 = 2.80 \cdot \frac{9}{100}$$

$$= \frac{2.80 \cdot 9}{100}$$

$$= \frac{25.2}{100}$$

$$= 0.252$$

Resultado final

$$\boxed{\text{MDE} \approx 0.252}$$

Exemplo Aplicado

Packages

```
In [27]: # install.packages("fixest")
# install.packages("dplyr")
library(tidyverse)
library(fixest)
```

Simulação de dados em painel e modelo DiD TWFE

- N unidades (ex.: municípios)
- T períodos (ex.: anos)
- Metade das unidades tratadas a partir de um certo período
- Geramos um outcome com efeito verdadeiro τ_{true} aplicado após o tratamento

```
In [28]: # seed
set.seed(2025)

# parâmetros da simulação
N <- 200      # número de unidades
Tt <- 10      # períodos
tau_true <- 2 # efeito verdadeiro do tratamento

# painel balanceado
df <- expand.grid(
  id   = 1:N,
  time = 1:Tt
)

# define tratados e início do tratamento
treated_units <- sample(1:N, size = N/2, replace = FALSE)
treat_start   <- 6

df <- df %>%
  mutate(
    treated = ifelse(id %in% treated_units, 1, 0),
    post     = ifelse(time >= treat_start, 1, 0),
    D        = treated * post
  )

# efeitos fixos verdadeiros
alpha_i <- rnorm(N, mean = 0, sd = 1) # FE unidade
gamma_t <- rnorm(Tt, mean = 0, sd = 0.5) # FE tempo

df <- df %>%
  mutate(
    fe_i = alpha_i[id],
    fe_t = gamma_t[time],
    eps  = rnorm(n(), mean = 0, sd = 1),
```

```

    y = 5 + fe_i + fe_t + tau_true * D + eps
  )

# visualizar
head(df)

```

```

Out[28]:   id time treated post D      fe_i      fe_t      eps      y
1  1  1      0      0 0  0.5843897 0.1110744 -1.53427362 4.161190
2  2  1      0      0 0  1.3904459 0.1110744 -1.21833918 5.283181
3  3  1      0      0 0  1.7537552 0.1110744  0.41953561 7.284365
4  4  1      1      0 0  0.4667391 0.1110744  1.62654061 7.204354
5  5  1      1      0 0 -0.4227943 0.1110744  0.05583129 4.744111
6  6  1      0      0 0  0.6340245 0.1110744 -0.02753179 5.717567

```

Difference-in-Differences (TWFE)

```

In [29]: # modelo TWFE DiD: y ~ D + FE de id e tempo
mod_twfe <- feols(y ~ D | id + time, data = df)
etable(mod_twfe)

```

```

Out[29]:                                mod_twfe
Dependent Var.:                        y

D                                2.018*** (0.0903)
Fixed-Effects:  -----
id                                Yes
time                             Yes

-----
S.E.: Clustered                    by: id
Observations                      2,000
R2                                0.70574
Within R2                          0.22262
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Resumo da interpretação

Você estimou um modelo TWFE DiD e encontrou: - Efeito estimado (D): 2.018 - Erro-padrão (SE): 0.0903

Esse SE é muito baixo, o que significa que o estudo é muito preciso.

Funções para calcular o Power e Minimum Detectable Effect (MDE)

Usaremos uma aproximação normal:

- Power: probabilidade de rejeitar H_0 para um efeito δ dado o SE;
- MDE: efeito mínimo que garante um power alvo (ex.: 80%).

```

In [30]: # Função para estimar o power
power_did <- function(effect, se, alpha = 0.05) {
  z_alpha <- qnorm(1 - alpha / 2)
  z0 <- effect / se

```

```

power <- pnorm(-z_alpha - z0) + (1 - pnorm(z_alpha - z0))
return(power)
}

# Função para calcular Minimum Detectable Effect (MDE)
mde_did <- function(se, power_target = 0.80, alpha = 0.05) {
  z_alpha <- qnorm(1 - alpha / 2)
  z_beta <- qnorm(power_target)
  mde <- (z_alpha + z_beta) * se
  return(mde)
}

```

Para calcular o Power e MDE a partir do modelo TWFE estimado

- 1. Pegamos o erro-padrão estimado do coeficiente **D** ;
- 2. Calculamos:
 - Power para certos efeitos-alvo;
 - MDE para um power desejado.

```

In [31]: # erro-padrão do coeficiente D
se_D <- se(mod_twfe)["D"]
se_D

```

```

Out[31]:      D
0.09033511

```

Calcular o **Power** para um efeito-alvo de 0.5

Por que usar um efeito-alvo de 0.5?

Quando calculamos power, precisamos escolher um efeito hipotético para testar. Como no mundo real não sabemos qual é o efeito verdadeiro, trabalhamos com um efeito-alvo: um tamanho de efeito que gostaríamos de conseguir detectar.

- O 0.5 não tem nada de mágico, ele é apenas um exemplo numérico. Mas ele serve para ilustrar o seguinte raciocínio:

“Se o efeito real fosse 0.5, qual seria a chance de meu estudo detectá-lo?”

Como escolher esse efeito-alvo?

Pesquisadores usam três critérios principais:

- **1. O menor efeito economicamente relevante**

Pergunta central: “Qual é o menor efeito que, se realmente existir, já justificaria a política ou a campanha?”

- **2. Efeitos observados em estudos anteriores (literatura)**

Se estudos semelhantes encontraram determinados resultados, então esses números são bons candidatos para efeito-alvo

- **3. Efeito esperado pelos especialistas (conhecimento de domínio)**

O grupo de pesquisadores experientes, acreditam que o efeito esperado é 0.5, então esse é um bom valor para testar.

Como pesquisadores fazem geralmente? (o workflow real)

1. Definem um intervalo plausível de efeitos. (Ex.: 0.1, 0.25, 0.5, 1.0)
2. Calculam o power para cada um e criam uma tabela ou gráfico.
3. Escolhem como referência o menor efeito que seria relevante. (Ex.: “Queremos pelo menos detectar efeitos maiores que 0.3.”)
4. Interpretam o resultado não significativo à luz do power. (Ex.: Se o MDE = 0.4 e o efeito estimado = 0.2 → “o estudo não tem sensibilidade para captar 0.2.”)

```
In [32]: # exemplo 1: power para um efeito-alvo de 0.5
effect_target <- 0.5
power_05 <- power_did(effect = effect_target, se = se_D, alpha = 0.05)
power_05
```

```
Out[32]:      D
0.9998249
```

Interpretação resumida

Se o verdadeiro efeito fosse 0.5, seu modelo teria aproximadamente 99,98% de chance de detectá-lo como significativo.

Calcular o MDE para 80% de power

Níveis de Power mais comuns

Power = 80% (0.80) → Padrão internacional

- É o nível mais comum em economia, marketing, ciências sociais e A/B testing.
- Interpretação: **“Se o efeito existir, tenho 80% de chance de detectá-lo.”**
- Perde 1 em cada 5 efeitos verdadeiros (erro tipo II = 20%).
- Bom compromisso entre rigor e viabilidade de amostra.

Power = 90% (0.90) → Mais rigoroso

- Usado quando é importante **não perder efeitos relevantes**.
- Interpretação: **“Tenho 90% de chance de detectar o efeito se ele existir.”**

- Perde 1 em cada 10 efeitos verdadeiros.
- Exige amostras maiores e reduz o MDE.

Power = 95% (0.95) → Muito rigoroso, raro em economia

- Comum em ensaios clínicos e áreas críticas.
- Interpretação: **“Tenho 95% de chance de detectar o efeito se ele existir.”**
- Perde 1 em cada 20 efeitos.
- Requer amostras enormes para efeitos pequenos.

Resumo final

Power	O que significa	Uso típico
80%	Detecta a maioria dos efeitos relevantes; falha 20% das vezes	padrão em economia, marketing, causal ML
90%	Falha apenas 10% das vezes	políticas caras, saúde, avaliações robustas
95%	Falha só 5% das vezes	regulatório, clinical trials

```
In [33]: # exemplo 2: MDE para 80% de power
mde_80 <- mde_did(se = se_D, power_target = 0.80, alpha = 0.05)
mde_80
```

```
Out[33]:      D
0.2530815
```

Interpretação do MDE para 80% de power

Isso significa:

O menor efeito que este estudo consegue detectar com 80% de chance é aproximadamente 0.253

Ou seja:

- Se o efeito verdadeiro for **maior ou igual a ~0.25**, o modelo tem **pelo menos 80% de probabilidade** de identificá-lo como significativo.
- Se o efeito verdadeiro for **menor que ~0.25**, o estudo **não tem sensibilidade suficiente**: mesmo que o impacto exista, o modelo frequentemente **não o detectaria**.

Em termos práticos:

- **0.25 é o “tamanho mínimo visível” do seu estudo.**
- Efeitos menores que isso ficam abaixo da “resolução” estatística do desenho.

Interpretação:

- `se_D` : incerteza do estimador DiD dado o desenho (N, T, variância, cluster etc.);
- `power_05` : probabilidade de detectar um efeito de 0.5 se ele existisse;
- `mde_80` : menor efeito que este estudo consegue detectar com 80% de power.
 - Se `power_05` for próximo de 1, o desenho é muito potente para efeitos de 0.5.
 - Se `mde_80` for, por exemplo, ~0.25, então:
 - Efeitos menores que 0.25 têm power < 80%;
 - Efeitos maiores que 0.25 têm power > 80%.

Curva de power para vários efeitos-alvo

- É útil ver como o power cresce conforme o efeito aumenta.
- Aqui calculamos power para uma grade de efeitos possíveis.

```
In [51]: effects_grid <- seq(0.05, 1, by = 0.05)
power_grid <- sapply(effects_grid, function(e) power_did(effect = e, se = se_D))

power_table <- data.frame(
  efeito = effects_grid,
  power = round(power_grid, 3)
)

targets <- c(0.80, 0.90, 0.95)

target_table <- data.frame(
  power_alvo = targets,
  efeito_aprox = sapply(targets, function(tp) {
    idx <- which.min(abs(power_grid - tp))
    effects_grid[idx]
  }),
  power_aprox = sapply(targets, function(tp) {
    idx <- which.min(abs(power_grid - tp))
    round(power_grid[idx], 3)
  })
)

head(power_table)
```

```
Out[51]:   efeito power
1    0.05 0.086
2    0.10 0.198
3    0.15 0.382
4    0.20 0.600
5    0.25 0.790
6    0.30 0.913
```

Gráfico - Curva de Power para Diferentes Tamanhos de Efeito

```
In [52]: ggplot(power_table, aes(x = efeito, y = power)) +
  geom_line(linewidth = 1.2, color = "#1f77b4") +
  geom_point(size = 3, color = "#1f77b4") +
```

```

# Linhas horizontais para 80%, 90%, 95%
geom_hline(yintercept = 0.80, linetype = "dashed", color = "#d62728", linewidth = 1) +
geom_hline(yintercept = 0.90, linetype = "dashed", color = "#2ca02c", linewidth = 1) +
geom_hline(yintercept = 0.95, linetype = "dashed", color = "#9467bd", linewidth = 1) +


# etiquetas
annotate("text", x = max(power_table$efeito), y = 0.80,
        label = "80% power", hjust = 1.1, vjust = -0.5, color = "#d62728") +
annotate("text", x = max(power_table$efeito), y = 0.90,
        label = "90% power", hjust = 1.1, vjust = -0.5, color = "#2ca02c") +
annotate("text", x = max(power_table$efeito), y = 0.95,
        label = "95% power", hjust = 1.1, vjust = -0.5, color = "#9467bd") +

scale_y_continuous(limits = c(0, 1), breaks = seq(0, 1, 0.1)) +
scale_x_continuous(breaks = effects_grid) +

labs(
  title = "Curva de Power para Diferentes Tamanhos de Efeito",
  x = "Tamanho do efeito-alvo",
  y = "Power"
) +

theme_minimal(base_size = 14) +
theme(
  plot.title = element_text(face = "bold", size = 16),
  axis.title.x = element_text(margin = margin(t = 10)),
  axis.title.y = element_text(margin = margin(r = 10)),
  panel.grid.minor = element_blank()
)

```



Resumo da interpretação do gráfico de power

O gráfico mostra como o **power aumenta conforme o tamanho do efeito-alvo cresce**. Com o SE obtido no modelo TWFE, o estudo:

- atinge **80% de power** quando o efeito é por volta de **0.25**
- atinge **90% de power** quando o efeito é próximo de **0.30**
- atinge **95% de power** quando o efeito chega a **0.35–0.40**

Em outras palavras:

O estudo tem boa sensibilidade apenas para efeitos maiores que aproximadamente 0.25. Efeitos menores do que isso têm baixa probabilidade de serem detectados.

Isso confirma a leitura do MDE: o “tamanho mínimo visível” deste desenho é cerca de **0.25**.

Conclusão

A análise mostrou que interpretar um resultado “não significativo” exige muito mais cuidado do que simplesmente olhar o p-valor. O erro-padrão do estimador determina diretamente o quanto o estudo é capaz de enxergar efeitos reais. Com o SE obtido no modelo TWFE, observamos que o estudo só atinge 80% de poder para detectar efeitos acima de aproximadamente 0.25. Isso significa que, caso o impacto verdadeiro fosse menor do que esse valor, o modelo teria grande chance de não identificá-lo, mesmo que ele exista.

A curva de power reforça essa leitura: à medida que o efeito-alvo cresce, o power sobe rapidamente, e efeitos moderados (0.30, 0.35, 0.40) se tornam facilmente detectáveis. Porém, efeitos pequenos permanecem abaixo do “limite de resolução” estatística do desenho.

Assim, a conclusão fundamental é:

Ausência de significância não é evidência de ausência de efeito.

Muitas vezes, o modelo simplesmente não tem poder estatístico para enxergar o impacto que se busca medir.

Em avaliações de políticas públicas, marketing e experimentos aplicados, isso significa que rejeitar uma intervenção com base apenas no p-valor pode levar a decisões equivocadas. Avaliar o poder e o MDE permite entender a sensibilidade real do estudo e evitar interpretações erradas, garantindo conclusões mais honestas, robustas e alinhadas com a magnitude dos efeitos que realmente importam.